

EÖTVÖS LORÁND TUDOMÁNYEGYETEM
Természettudományi Kar

Gyórfi Enikő

BŰNÖZÉSI GYAKORISÁG MODELLEZÉSE

Szakdolgozat
Matematika alapszak

Témavezető:
Maga Balázs



ELTE | TTK
TERMÉSZETTUDOMÁNYI KAR

Budapest, 2026

Tartalomjegyzék

1	Bevezetés	1
2	A Sztochasztikus Folyamatok Elméleti Alapjai	1
2.1	Definíciók és alapfogalmak	1
2.2	Sztochasztikus folyamatok	2
2.3	Brown-mozgás	4
3	Sztochasztikus differenciálegyenletek	6
3.1	Bevezetés	6
3.2	Itô-integrál	7
3.3	Geometriai Brown-mozgás	12
4	A gépi tanulás elméleti hátttere	15
4.1	A gépi tanulás alapjai	15
4.2	Döntési fák	19
4.2.1	A döntési fák tanítása	21
4.3	Ensemble módszerek	22
4.3.1	Random Forest	22
4.4	Idősorok elemzése	23
4.4.1	Alapfogalmak	24
4.4.2	Klasszikus idősoelemzési módszerek	25
4.4.2.1	Determinisztikus és simításos módszerek	25
4.4.2.2	Sztochasztikus módszerek	26
4.4.3	Gépi tanulási és mélytanulási módszerek idősorok elemzésére	27
5	Irodalomjegyzék	29

1 Bevezetés

2 A Sztochasztikus Folyamatok Elméleti Alapjai

2.1 Definíciók és alapfogalmak

Definíció 2.1.1

Egy valószínűségi tér $(\Omega, \mathcal{F}, P)$ hármasa tartalmazza:

- Ω (**eseménytér**): a lehetséges kimenetek halmaza.
- $\mathcal{F}$ (**σ -algebra**): Ω részhalmazainak olyan rendszere, amely tartalmazza az $\emptyset$ üres halmazt; komplementerre zárt; és megszámlálható unióra zárt. Az $(\Omega, \mathcal{F})$ párost mérhető térnek nevezzük.
- P (**valószínűségi mérték**): egy $P : \mathcal{F} \rightarrow \mathbb{R}$ függvény, amely kielégíti a $P(\emptyset) = 0$ és $P(\Omega) = 1$ feltételeket, és megszámlálható additivitással rendelkezik diszjunkt halmazok esetén.

Definíció 2.1.2

Legyen X egy Ω -n értelmezett függvényekből álló halmaz. Az X által generált σ -algebra a legkisebb σ -algebra, amelyre vonatkozóan ezen függvények mind mérhetőek. Jelölése: $\sigma(X)$.

Definíció 2.1.3

[1] Tegyük fel, hogy adott két valószínűségi mérték $\mathcal{P}$ és $\mathcal{Q}$ ugyanazon mérhető téren $(\Omega, \mathcal{F})$. Azt mondjuk, hogy a $\mathcal{Q}$ mérték abszolút folytonos a $\mathcal{P}$ -re nézve, ha létezik egy integrálható véletlen változó $f : \Omega \rightarrow \mathbb{R}$, melyre minden $A \in \mathcal{F}$ esetén

$$\mathcal{Q}(A) = \int_A f(\omega) d\mathcal{P}(\omega) \quad (1)$$

teljesül.

Ekkor f a $\mathcal{Q}$ mérték $\mathcal{P}$ -re vonatkozó sűrűségfüggvénye.

Megjegyzés. Ebben az esetben, ha $E^{\mathcal{P}}$ és $E^{\mathcal{Q}}$ a két mérték szerinti várható értékek, akkor minden $\mathcal{Q}$ szerint integrálható véletlen változóra X :

$$E^{\mathcal{Q}}[X] = \int_{\Omega} X \, d\mathcal{Q} = \int_{\Omega} X f \, d\mathcal{P} = E^{\mathcal{P}}[Xf]. \quad (2)$$

Definíció 2.1.4

[1] Legyen Ω egy nemüres halmaz. Legyen T egy rögzített pozitív szám, és tegyük fel, hogy minden $t \in [0, T]$ esetén adott egy $\mathcal{F}(t)$ σ -algebra. Tegyük fel továbbá, hogy ha $s \leq t$, akkor minden halmaz, amely eleme $\mathcal{F}(s)$ -nek, eleme $\mathcal{F}(t)$ -nek is. Ekkor a $0 \leq t \leq T$ paraméterű $\mathcal{F}(t)$ σ -algebrák gyűjteményét filtrációnak nevezzük.

Definíció 2.1.5

[1] Legyen X egy nem üres Ω mintatéren értelmezett valószínűségi változó. Legyen $\mathcal{G}$ az Ω részhalmazainak egy σ -algebrája. Ha a $\sigma(X)$ minden halmaza eleme $\mathcal{G}$ -nek is, akkor azt mondjuk, hogy X $\mathcal{G}$ -mérhető.

Definíció 2.1.6

[1] Legyen $f(t)$ egy $[0, T]$ intervallumon értelmezett függvény. Az f kvadratikus variációját a $[0, T]$ intervallumon a következő határértékkel definiáljuk:

$$[f, f](T) = \lim_{\|\Pi\| \rightarrow \infty} \sum_{i=0}^{n-1} (f(t_{i+1}) - f(t_i))^2, \quad (3)$$

ahol $\Pi = \{0 = t_0 < t_1 < \dots < t_n = T\}$ egy partíciója a $[0, T]$ intervallumnak, és $\|\Pi\| = \max_{0 \leq i \leq n-1} (t_{i+1} - t_i)$.

2.2 Sztochasztikus folyamatok

Definíció 2.2.1

[1] Legyen $(\Omega, \mathcal{F}, P)$ egy valószínűségi tér és T egy rögzített pozitív szám. Ekkor az $X = (X_t)_{t \in [0, T]}$ családot sztochasztikus folyamatnak nevezzük, ha minden $t \in [0, T]$ esetén X_t egy valószínűségi változó.

Definíció 2.2.2

[1] Legyen $(\Omega, \mathcal{F}, P)$ egy valószínűségi tér és $(\mathcal{F}(t))_{0 \leq t \leq T}$ filtráció. Legyen $X(t)$ egy valószínűségi változókból álló család, amelyet $t \in [0, T]$ paraméter indexel. Azt mondjuk, hogy $X(t)$ egy adaptált sztochasztikus folyamat az $\mathcal{F}(t)$ -re nézve, ha minden t -re az $X(t)$ valószínűségi változó $\mathcal{F}(t)$ -mérhető.

Definíció 2.2.3

[1] Legyen $(\Omega, \mathcal{F}, P)$ egy valószínűségi mező, legyen T egy rögzített pozitív szám, és legyen $(\mathcal{F}(t))_{0 \leq t \leq T}$ a $\mathcal{F}$ σ -algebráinak egy filtrációja. Tekintsünk egy adaptált sztochasztikus folyamatot $M(t)$ -t, $0 \leq t \leq T$.

(i) Ha $E[M(t) | \mathcal{F}(s)] = M(s)$ minden $0 \leq s \leq t \leq T$ esetén, akkor a folyamatot **martingálnak** nevezzük.

(ii) Ha $E[M(t) | \mathcal{F}(s)] \geq M(s)$ minden $0 \leq s \leq t \leq T$ esetén, akkor a folyamat **szubmartingál**.

(iii) Ha $E[M(t) | \mathcal{F}(s)] \leq M(s)$ minden $0 \leq s \leq t \leq T$ esetén, akkor a folyamat **supermartingál**.

Definíció 2.2.4

[1] Legyen $(\Omega, \mathcal{F}, P)$ egy valószínűségi mező, legyen T egy rögzített pozitív szám és legyen $(\mathcal{F}(t))_{0 \leq t \leq T}$ a $\mathcal{F}$ σ -algebráinak egy filtrációja. Az $X(t)_{0 \leq t \leq T}$ adaptált sztochasztikus folyamatot Markov-folyamatnak nevezzük, ha minden $0 \leq s < t \leq T$ és minden nemnegatív, Borel-mérhető f függvény esetén létezik egy g Borel-mérhető függvény, amelyre teljesül:

$$E[f(X(t)) | \mathcal{F}(s)] = g(X(s)) \quad (4)$$

Megjegyzés. Tehát a Markov-folyamat jövőbeli állapota csak a jelenlegi állapottól függ, és független a múltbeli állapotoktól. Ebből következik, hogy az együttes valószínűségi sűrűség feltételes formája felírható átmeneti sűrűségek szorzataként:

$$p(x_n, t_n \dots x_2, t_2 | x_1, t_1) = p(x_n, t_n | x_{n-1}, t_{n-1}) \dots p(x_2, t_2 | x_1, t_1). \quad (5)$$

Definíció 2.2.5

Egy folytonos Markov-folyamat időben homogén, ha az átmeneti sűrűsége csak az időbeli különbségektől függ:

$$p(x, t | y, s) = p(x, t - s | y, 0). \quad (6)$$

2.3 Brown-mozgás

Definíció 2.3.1

[2] Egy $B = (B_t)_{t \geq 0}$ sztochasztikus folyamatot Brown-mozgásnak (vagy Wiener-folyamatnak) nevezünk, ha az alábbi négy tulajdonságnak tesz eleget:

- A folyamat a $t = 0$ időpontban a nullából indul, 1 valószínűséggel, azaz $B_0 = 0$.
- A folyamat pályái, azaz a $t \mapsto B_t(\omega)$ leképezések minden egyes ω elemi eseményre, majdnem biztosan folytonosak.
- Bármely $0 \leq s_1 < t_1 \leq s_2 < t_2$ időpontosorozatra a $B_{t_1} - B_{s_1}$ és $B_{t_2} - B_{s_2}$ valószínűségi változók függetlenek egymástól.
- Bármely $s < t$ időpontpárra a $B_t - B_s$ növekmény normális eloszlású, 0 várható értékkel és $t - s$ szórásnégyzettel. Formálisan: $B_t - B_s \sim N(0, t - s)$.

Megjegyzés. A független növekmények tulajdonságából adódóan a Brown-mozgás egy Gauss–Markov-folyamat. Továbbá, mivel az átmeneti sűrűsége csak az időbeli különbségtől függ, egyben időben homogén Markov-folyamat is.

Definíció 2.3.2

[1] Legyen $(\Omega, \mathcal{A}, P)$ egy valószínűségi mező, amelyen a $B(t)$, $t \geq 0$ Brown-mozgás definiálva van. A $B(t)$ -hez tartozó filtráció egy $\mathcal{F}(t)$ szigma-algebrákból álló család, amelyre a következő feltételek teljesülnek:

- Az információ halmozódik: $\mathcal{F}(s) \subset \mathcal{F}(u)$ minden $0 \leq s < u$ esetén, vagyis az idő előrehaladtával az elérhető információ mennyisége nem csökken.
- Adaptivitás: minden $t \geq 0$ esetén a $B(t)$ $\mathcal{F}(t)$ -mérhető.
- A jövőbeli növekmények függetlensége: minden $0 \leq s < u$ esetén a $B(u) - B(s)$ növekmény független $\mathcal{F}(s)$ -től.

Tétel 2.3.3

[1] Legyen $(\Omega, \mathcal{A}, P)$ egy valószínűségi mező, amelyen a $B(t)$, $t \geq 0$ Brown-mozgás definiálva van. Ekkor a következő állítások teljesülnek:

- $B(t)$ martingál a fenti definícióban definiált filtrációval.

Bizonyítás. Elég azt bizonyítani, hogy a $B(t)$ folyamat martingál. Legyen $0 \leq s < t$ adott, és tekintsük a következő várható értéket:

$$E[B(t) \mid \mathcal{F}(s)] = E[B(t) - B(s) + B(s) \mid \mathcal{F}(s)]. \quad (7)$$

Mivel a Brown-mozgás növekményei függetlenek a múltbeli információtól, ezért

$$E[B(t) - B(s) \mid \mathcal{F}(s)] = E[B(t) - B(s)] = 0. \quad (8)$$

Ezenkívül, mivel $B(s)$ már ismert a $\mathcal{F}(s)$ -ben, ezért

$$E[B(s) \mid \mathcal{F}(s)] = B(s). \quad (9)$$

Ezeket az eredményeket összevonva kapjuk, hogy

$$E[B(t) \mid \mathcal{F}(s)] = 0 + B(s) = B(s). \quad (10)$$

Ez pontosan a martingál feltétel, így a $B(t)$ folyamat martingál. ■

3 Sztochasztikus differenciálegyenletek

3.1 Bevezetés

Egy közönséges differenciálegyenlet az alábbi formában írható fel:

$$\frac{dx(t)}{dt} = f(t, x(t)). \quad (11)$$

ahol $x(t)$ a vizsgált mennyiség időbeli változása, és $f(t, x(t))$ egy determinisztikus függvény, amely meghatározza a rendszer dinamikáját.

Integrál formában és $x(0) = x_0$ kezdeti értékkel ez az egyenlet a következőképpen néz ki:

$$x(t) = x_0 + \int_0^t f(s, x(s)) ds. \quad (12)$$

Egy SDE akkor jön létre, ha a differenciálegyenlet egy együttthatója determinisztikus paraméter helyett sztochasztikus paraméterré válik. Például tekintsük a következő KDE-t:

$$\frac{dx(t)}{dt} = a(t)x(t). \quad (13)$$

Amennyiben feltesszük, hogy $a(t)$ egy sztochasztikus folyamat, akkor az egyenlet sztochasztikus differenciálegyenletté alakul. Ekkor az $a(t)$ a következő formában írható fel:

$$a(t) = f(t) + h(t)\xi(t), \quad (14)$$

ahol $\xi(t)$ egy fehér zaj folyamat.

Ekkor az SDE a következőképpen néz ki:

$$\frac{dx(t)}{dt} = (f(t) + h(t)\xi(t))x(t) \quad (15)$$

Legyen $dB(t) = \xi(t) dt$, ahol $dB(t)$ a Brown-mozgás differenciálját jelöli, ekkor az SDE differenciál formában a következőképpen írható fel:

$$dx(t) = f(t)x(t) dt + h(t)x(t) dB(t). \quad (16)$$

Általánosabban egy Itô-típusú sztochasztikus differenciálegyenlet a következő formában írható fel:

$$dx(t, \omega) = f(t, x(t, \omega)) dt + g(t, x(t, \omega)) dB(t). \quad (17)$$

Egy általános, Itô-típusú SDE a következő szimbolikus formában írható fel:

$$dX(t) = \mu(t, X(t)) dt + \sigma(t, X(t)) dB(t). \quad (18)$$

Ez az egyenlet valójában egy integrálegyenlet rövidítése, és két fő részből áll:

- **Drift tag:** a folyamat változásának determinisztikus, előre jelezhető komponense egy infinitezimális dt időlépés alatt.
- **Diffúziós tag** $(\sigma(X_t, t) dB_t)$: ez a sztochasztikus, előre nem látható komponenst képviseli. A hatásának nagyságát a $\sigma(X_t, t)$ volatilitás- vagy diffúziós függvény skálázza, amely függhet a rendszer aktuális állapotától és az időtől is. Ez a tag visz véletlenszerűséget a rendszer leírásába.

3.2 Itô-integrál

Amikor a modellezett rendszerben véletlen hatások jelennek meg, a klasszikus integrál-fogalom már nem elegendő. Számos alkalmazási területen, például pénzügyi matematikában, fizikai rendszerek leírásában vagy biológiai folyamatok vizsgálatában, a modellek természetes módon vezetnek sztochasztikus folyamatokhoz. A Brown-mozgás pályái 1 valószínűséggel folytonosak, de sehol sem differenciálhatók, így nem rendelkeznek jól definiált deriváltakkal. Emiatt a hagyományos Riemann- vagy Lebesgue-integrál közvetlenül nem alkalmazható olyan kifejezésekre, mint például

$$\int_0^t X(s) dB(s). \quad (19)$$

Az ilyen típusú integrálok értelmezéséhez egy új integrálfogalom bevezetése szükséges. Az Itô-integrál lehetővé teszi, hogy Brown-mozgásra vonatkozóan értelmezzük a sztochasztikus integrálokat.

Az előbbi kifejezésben az integrál egyik összetevője egy $B(t)$, $t \geq 0$ Brown-mozgás, valamint az ehhez tartozó $\mathcal{F}(t)$, $t \geq 0$ filtráció. Az integrandus $X(t)$ egy adaptált sztochasztikus folyamat, amely azt jelenti, hogy minden $t \geq 0$ esetén $X(t)$ $\mathcal{F}(t)$ -mérhető. Az adaptáltság biztosítja, hogy $X(t)$ értéke csak a t időpontig ismert információtól függ.

Definíció 3.2.1

[1] Legyen a $0 = t_0 < t_1 < \dots < t_n = T$ egy partíciója a $[0, T]$ intervallumnak, és legyen $\Delta(t)$ konstans minden $t \in [t_i, t_{i+1})$ intervallumon. Ekkor $\Delta(t)$ -t elemi folyamatnak nevezzük.

Ez analóg a Lebesgue-integrál lépcsős függvényeivel, ahol a függvény értéke egy adott intervallumon állandó.

Definíció 3.2.2

[1] Egy elemi folyamat Itô-integrálja a következőképpen definiálható:

$$I(t) = \int_0^T \Delta(s) dB(s) = \sum_{j=0}^n \Delta(t_j)(B(t_j) - B(t_{j-1})) + \Delta(t_n)(B(T) - B(t_n)). \quad (20)$$

Tétel 3.2.3

[1] Legyen $\Delta(t)$ egy elemi folyamat, ekkor az Itô-izometria a következőképpen írható fel:

$$E \left[\left(\int_0^t \Delta(s) dB(s) \right)^2 \right] = E \left[\int_0^t \Delta^2(s) ds \right]. \quad (21)$$

Az elemi folyamatok integráljának felhasználásával az Itô-integrál kiterjeszthető általános adaptált sztochasztikus folyamatokra, amelyek kielégítik a megfelelő feltételeket:

- $X(t)$ adaptált a $\mathcal{F}(t)$ filtrációhoz.
- $X(t)$ kvadratikusán integrálható, azaz $\int_0^t E[X^2(s)] ds < \infty$ minden $t \geq 0$ esetén.

Az integrál definiálásához az $X(t)$ folyamatot elemi folyamatokkal közelítjük. Vesszük a $[0, T]$ intervallum egy partícióját: $0 = t_0 < t_1 < \dots < t_n = T$, és a $[t_j, t_{j+1}]$ intervallumon a közelítő $\Delta(t)$ elemi folyamat értékét az $X(t_j)$ értékére állítjuk. Így a felosztás finomításával az elemi folyamat egyre jobb közelítést ad az $X(t)$ folyamatnak. Választható tehát elemi folyamatok sorozata $\Delta_n(t)$ úgy, hogy a következő konvergencia teljesüljön, ha $n \rightarrow \infty$:

$$E \int_0^t |X(s) - \Delta_n(s)|^2 ds \rightarrow 0. \quad (22)$$

Ekkor az Itô-integrál a következőképpen definiálható:

$$\int_0^t X(s) dB(s) = \lim_{n \rightarrow \infty} \int_0^t \Delta_n(s) dB(s), \quad 0 \leq t \leq T. \quad (23)$$

Az integrál tulajdonságait a következő tétel foglalja össze:

Tétel 3.2.4

[1] Legyen T egy pozitív konstans, és legyen $X(t)$, $0 \leq t \leq T$ egy adaptált sztochasztikus folyamat, amely kielégíti a fentebb írt feltételeket. Ekkor az

$$I(t) = \int_0^t X(s) dB(s) \quad (24)$$

folyamat a következő tulajdonságokkal rendelkezik:

- **Folytonosság:** $I(t)$ pályái folytonosak.
- **Adaptáltság:** minden t -re az $I(t)$ folyamat $\mathcal{F}(t)$ -mérhető.
- **Linearitás:** ha $I(t) = \int_0^t X(s) dB(s)$ és $J(t) = \int_0^t Y(s) dB(s)$, akkor $I(t) + J(t) = \int_0^t (X(s) + Y(s)) dB(s)$. Továbbá minden c konstansra $I(t) = \int_0^t c X(s) dB(s)$.
- **Martingál tulajdonság:** az $I(t)$ folyamat martingál.
- **Itô-izometria:** $E[I^2(t)] = E\left[\int_0^t X^2(u) du\right]$.
- **Kvadratikus variáció:** $[I, I](t) = \int_0^t X^2(u) du$.

Eddig azt vizsgáltuk, hogyan lehet értelmezni egy Brown-mozgásra vonatkozó integrált, és milyen tulajdonságokkal rendelkezik ez az integrál. Most vizsgáljuk meg, hogyan lehet értelmezni egy Brown-mozgás által meghatározott folyamat megváltozását. Tekintsük a következő kifejezést:

$$\frac{d}{dt} f(B(t)). \quad (25)$$

Ez a kifejezés nem értelmezhető a klasszikus analízisben használt láncszabály szerint, mivel a Brown-mozgás pályái sehol sem differenciálhatók. Ennek értelmezéséhez az Itô–Doeblin-formula alkalmazására van szükség, amely egy sztochasztikus változókra vonatkozó általánosított láncszabály.

Tétel 3.2.5

[1] Legyen $f(t, x)$ függvény, melynek parciális deriváltjai f_t , f_x és f_{xx} léteznek és folytonosak. Legyen továbbá $B(t)$ egy Brown-mozgás. Ekkor minden $T \geq 0$ esetén teljesül a következő egyenlőség:

$$\begin{aligned} f(T, B(T)) &= f(0, B(0)) + \int_0^T f_t(t, B(t)) dt \\ &+ \int_0^T f_x(t, B(t)) dB(t) + \frac{1}{2} \int_0^T f_{xx}(t, B(t)) dt. \end{aligned} \quad (26)$$

Ahhoz, hogy megértsük az Itô–Doebelin-formula jelentőségét, tekintsük a következő példát. Legyen $f(x) = \frac{1}{2}x^2$, ekkor f nem függ az időtől, így $f_t = 0$, és a parciális deriváltakak $f_x = x$ és $f_{xx} = 1$. Legyen x_{j-1} és x_j két szomszédos pont egy partícióban, és tekintsük a Taylor-sor első két tagját:

$$f(x_j) - f(x_{j-1}) = f_x(x_{j-1})(x_j - x_{j-1}) + \frac{1}{2}f_{xx}(x_{j-1})(x_j - x_{j-1})^2. \quad (27)$$

Továbbá legyen $T > 0$ egy rögzített pozitív szám, és legyen a $[0, T]$ intervallum egy partíciója $\mathcal{P} = \{t_0, t_1, \dots, t_n\}$. Az $f(B(t))$ folyamat változását 0 és T között a következőképpen írhatjuk fel:

$$\begin{aligned} f(B(T)) - f(B(0)) &= \sum_{j=1}^n f_x(B(t_{j-1}))(B(t_j) - B(t_{j-1})) + \\ &\quad \frac{1}{2} \sum_{j=1}^n f_{xx}(B(t_{j-1}))(B(t_j) - B(t_{j-1}))^2. \end{aligned} \quad (28)$$

Ha ebbe behelyettesítjük a parciális deriváltakak értékét, akkor a következő egyenlőséget kapjuk:

$$\begin{aligned} f(B(T)) - f(B(0)) &= \sum_{j=1}^n B(t_{j-1})(B(t_j) - B(t_{j-1})) + \\ &\quad \frac{1}{2} \sum_{j=1}^n (B(t_j) - B(t_{j-1}))^2. \end{aligned} \quad (29)$$

A partíció finomításával, azaz ha $\|\mathcal{P}\| \rightarrow 0$, akkor a következő konvergencia teljesül:

$$\sum_{j=1}^n B(t_{j-1})(B(t_j) - B(t_{j-1})) \rightarrow \int_0^T B(t) dB(t) \quad (30)$$

és

$$\sum_{j=1}^n (B(t_j) - B(t_{j-1}))^2 \rightarrow [B, B](T) = T. \quad (31)$$

Ezeket az eredményeket összevonva kapjuk, hogy

$$f(B(T)) - f(B(0)) = \int_0^T B(t) dB(t) + \frac{1}{2}T. \quad (32)$$

Ez pontosan az Itô–Doebelin-formula egy speciális esete, amelyben a függvény csak a Brown-mozgás értékétől függ, és nem függ az időtől.

Eddig az Itô–Doebelin-formulát egy speciális esetre vizsgáltuk, nevezetesen a Brown-mozgásra. Azonban ez a formula általánosítható tetszőleges Itô-folyamatokra is.

Definíció 3.2.6

[1] Legyen $B(t)$ egy Brown mozgás és $\mathcal{F}$ a $B(t)$ -hez tartozó filtráció. Az $X(t)$ folyamatot Itô-folyamatnak nevezzük, ha felírható a következő alakban:

$$X(t) = X(0) + \int_0^t \mu(s) ds + \int_0^t \sigma(s) dB(s), \quad (33)$$

ahol $\mu(s)$ és $\sigma(s)$ adaptált sztochasztikus folyamatok, amelyek kielégítik a megfelelő integrálhatósági feltételeket, és $X(0)$ egy adott kezdeti érték.

Tekintsünk egy általános Itô-folyamatot $X(t)$ -t, amely kielégíti a következő SDE-t:

$$dX(t) = \mu(t) dt + \sigma(t) dB(t). \quad (34)$$

Ekkor az Itô–Doebelin-formula kiterjeszthető az $X(t)$ folyamatra is, és a következőképpen írható fel:

Tétel 3.2.7

[1] Legyen $X(t)$ egy Itô-folyamat, amely kielégíti a következő SDE-t:

$$dX(t) = \mu(t, X(t)) dt + \sigma(t, X(t)) dB(t), \quad (35)$$

és legyen $f(t, x) \in C^2([0, \infty) \times \mathbb{R})$. Ekkor az $Y(t) = f(t, X(t))$ folyamatra teljesül a következő egyenlőség:

$$dY(t) = \frac{\partial f(t, X(t))}{\partial t} dt + \frac{\partial f(t, X(t))}{\partial x} dX(t) + \frac{1}{2} \frac{\partial^2 f(t, X(t))}{\partial x^2} (dX(t))^2. \quad (36)$$

A fenti tételben a $(dX(t))^2$ kifejezés a következőképpen értelmezendő:

$$(dX(t))^2 = (\mu(t, X(t)) dt + \sigma(t, X(t)) dB(t))^2. \quad (37)$$

A következő egyenlőségek teljesülnek:

- $(dt)^2 = 0$,
- $dt dB(t) = 0$,
- $(dB(t))^2 = dt$.

Ezeket az eredményeket összevonva kapjuk, hogy

$$(dX(t))^2 = \sigma^2(t, X(t)) dt. \quad (38)$$

Ezt az eredményt visszahelyettesítve a tétel állításába kapjuk, hogy

$$dY(t) = \frac{\partial f(t, X(t))}{\partial t} dt + \frac{\partial f(t, X(t))}{\partial x} dX(t) + \frac{1}{2} \frac{\partial^2 f(t, X(t))}{\partial x^2} \sigma^2(t, X(t)) dt. \quad (39)$$

3.3 Geometriai Brown-mozgás

A pénzügyi modellezésben és más területeken, ahol a vizsgált mennyiségek (például árak vagy populációk mérete) nem vehetnek fel negatív értéket, és a növekedésük arányos a jelenlegi méretükkel, a leggyakrabban használt modell a geometriai Brown-mozgás (GBM).

Definíció 3.3.1

[1] Legyen $B(t)$ Brown-mozgás. Az $S(t)$ folyamatot geometriai Brown-mozgásnak nevezzük, ha kielégíti a következő sztochasztikus differenciálegyenletet:

$$dS(t) = \mu S(t) dt + \sigma S(t) dB(t), \quad (40)$$

ahol μ és σ konstansok.

A következő tétel megmutatja, hogy a geometriai Brown-mozgás explicit megoldással rendelkezik, amely egy exponenciális függvény formájában írható fel.

Tétel 3.3.2

[3] Legyen $S(t)$ egy geometriai Brown-mozgás, amely kielégíti a következő SDE-t:

$$dS(t) = \mu S(t) dt + \sigma S(t) dB(t), \quad (41)$$

ahol μ és σ konstansok. Ekkor az $S(t)$ folyamat explicit megoldása a következőképpen írható fel:

$$S(t) = S(0) \exp\left(\left(\mu - \frac{1}{2}\sigma^2\right)t + \sigma B(t)\right). \quad (42)$$

Bizonyítás. Legyen $Y(t) = \Phi(t, S(t)) = \ln(S(t))$. A parciális deriváltak a következők:

$$\frac{\partial \Phi(t, S)}{\partial S} = \frac{1}{S}, \quad \frac{\partial^2 \Phi(t, S)}{\partial S^2} = -\frac{1}{S^2}, \quad \frac{\partial \Phi(t, S)}{\partial t} = 0. \quad (43)$$

Ekkor az Itô–Doebelin-formula alkalmazásával kapjuk, hogy:

$$dY(t) = \left(\frac{\partial \Phi(t, S)}{\partial t} + \mu S(t) \frac{\partial \Phi(t, S)}{\partial S} + \frac{1}{2} \sigma^2 S^2(t) \frac{\partial^2 \Phi(t, S)}{\partial S^2} \right) dt + \sigma S(t) \frac{\partial \Phi(t, S)}{\partial S} dB(t). \quad (44)$$

Ebbe a parciális deriváltak értékét behelyettesítve kapjuk, hogy

$$dY(t) = \left(\mu - \frac{1}{2}\sigma^2 \right) dt + \sigma dB(t). \quad (45)$$

Integrálva ezt az egyenletet 0 és t között kapjuk, hogy:

$$Y(t) = Y_0 + \int_0^t \left(\mu - \frac{1}{2}\sigma^2 \right) ds + \int_0^t \sigma dB, \quad (46)$$

$$Y(t) = Y_0 + \left(\mu - \frac{1}{2}\sigma^2 \right) t + \sigma B(t). \quad (47)$$

Visszahelyettesítve $Y(t) = \ln(S(t))$, kapjuk az $S(t)$ folyamat explicit megoldását:

$$\ln(S(t)) = \ln(S(0)) + \left(\mu - \frac{1}{2}\sigma^2 \right) t + \sigma B(t), \quad (48)$$

$$S(t) = S(0) \exp \left(\left(\mu - \frac{1}{2}\sigma^2 \right) t + \sigma B(t) \right). \quad (49)$$

■

Mivel $\ln S(t)$ normális eloszlású, ezért a geometriai Brown.mozgás eloszlásáról a következő állítás tehető:

Állítás 3.3.3

[3] A geometriai Brown-mozgás $S(t)$ minden $t > 0$ esetén lognormális eloszlású.

Állítás 3.3.4

[3] Legyen $S(t)$ egy geometriai Brown-mozgás, amely kielégíti a következő SDE-t:

$$dS(t) = \mu S(t) dt + \sigma S(t) dB(t), \quad (50)$$

ahol μ és σ konstansok. Ekkor az $S(t)$ folyamat várható értéke a következőképpen írható fel:

$$E[S(t)] = S(0) \exp(\mu t). \quad (51)$$

Bizonyítás. Az $S(t)$ folyamat explicit megoldása a következőképpen írható fel:

$$S(t) = S(0) \exp \left(\left(\mu - \frac{1}{2}\sigma^2 \right) t + \sigma B(t) \right). \quad (52)$$

Mivel $B(t)$ normális eloszlású, ezért $\sigma B(t)$ is normális eloszlású, 0 várható értékkel és $\sigma^2 t$ szórásnégyzettel. Ezért a következő egyenlőség teljesül:

$$E[\exp(\sigma B(t))] = \exp \left(\frac{1}{2}\sigma^2 t \right). \quad (53)$$

Ezt az eredményt felhasználva kapjuk, hogy

$$E[S(t)] = S(0) \exp\left(\left(\mu - \frac{1}{2}\sigma^2\right)t\right) E[\exp(\sigma B(t))] = S(0) \exp(\mu t). \quad (54)$$

■

Állítás 3.3.5

[3] Legyen $S(t)$ egy geometriai Brown-mozgás, amely kielégíti a következő SDE-t:

$$dS(t) = \mu S(t) dt + \sigma S(t) dB(t), \quad (55)$$

ahol μ és σ konstansok. Ekkor az $S(t)$ folyamat varianciája a következőképpen írható fel:

$$\text{Var}[S(t)] = S^2(0) \exp(2\mu t) (\exp(\sigma^2 t) - 1). \quad (56)$$

Bizonyítás. A második momentum kiszámításához felhasználjuk a 42. egyenlet szerinti $S(t)$ explicit megoldást:

$$S^2(t) = S^2(0) \exp\left(2\left(\mu - \frac{1}{2}\sigma^2\right)t + 2\sigma B(t)\right). \quad (57)$$

Ekkor:

$$E[S^2(t)] = S^2(0) \exp\left(2\left(\mu - \frac{1}{2}\sigma^2\right)t\right) E[\exp(2\sigma B(t))]. \quad (58)$$

Mivel $2\sigma B(t)$ normális eloszlású, 0 várható értékkel és $4\sigma^2 t$ szórásnégyzettel, ezért

$$E[\exp(2\sigma B(t))] = \exp(2\sigma^2 t). \quad (59)$$

Ezt felhasználva kapjuk, hogy

$$\begin{aligned} E[S^2(t)] &= S^2(0) \exp\left(2\left(\mu - \frac{1}{2}\sigma^2\right)t\right) E[\exp(2\sigma B(t))] = \\ &= S^2(0) \exp(2\mu t + \sigma^2 t). \end{aligned} \quad (60)$$

A variancia definíciója szerint:

$$\begin{aligned} \text{Var}[S(t)] &= E[S^2(t)] - (E[S(t)])^2 = \\ &= S^2(0) \exp(2\mu t + \sigma^2 t) - (S(0) \exp(\mu t))^2 = \\ &= S^2(0) \exp(2\mu t) (\exp(\sigma^2 t) - 1). \end{aligned} \quad (61)$$

■

4 A gépi tanulás elméleti háttere

A gépi tanulás fontos szerepet játszik a tudomány, a gazdaság és a technológia számos területén. Például az orvostudományban a gépi tanulás segíthet a betegségek korai felismerésében és betegségekkel járó kockázatok azonosításában. A pénzügyi szektorban a gépi tanulás alkalmazható a kockázatkezelésben, a csalásfelderítésben és a kereskedési stratégiák optimalizálásában.

A gépi tanulás lehetővé teszi a nagy adathalmazok elemzését és a mintázatok felismerését ezért bűnügyi adatok elemzésére is használható, például a bűnözési mintázatok felismerésére és bűnügyi előrejelzések készítésére.

4.1 A gépi tanulás alapjai

A gépi tanulás algoritmusait három fő csoportba sorolhatjuk:

- Felügyelt tanulás: ahol a modell egy címkézett adathalmazon tanul, azaz minden bemeneti adathoz (X) tartozik egy kimeneti címke (y). A modell célja, egy olyan függvény megtanulása, amely képes egy új, ismeretlen bemeneti adat (X) alapján helyesen megjósolni a hozzá tartozó kimeneti címkét (y).
- Felügyelet nélküli tanulás: ahol a modell egy címkézetlen adathalmazon tanul, azaz csak bemeneti adatok (X) állnak rendelkezésre, de nincs hozzájuk tartozó kimeneti címke (y). A modell célja, hogy feltárja az adat szerkezetét, megtalálja a rejtett mintázatokat.
- Megerősítési tanulás: ahol a modell egy környezetben tanul, és a tanulási folyamat során visszajelzést kap a környezettől, amely alapján maximalizálni igyekszik egy célfüggvényt.

A szakdolgozat keretein belül elsősorban a felügyelt tanulás alapjaival foglalkozunk, különös tekintettel a regressziós problémákra, ahol a cél egy folytonos kimeneti érték előrejelzése.

A felügyelt tanulás esetén formálisan a következőképpen tekinthetünk az adatra:

$$D = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}. \quad (62)$$

ahol $x_i \in \mathbb{R}$ a bemeneti változókat tartalmazó vektor és $y_i \in \mathbb{R}$ a hozzá tartozó célváltozó értéke. A statisztikai tanulási modell általános alakja a következőképpen írható fel:

$$Y = f(X) + \varepsilon, \quad (63)$$

ahol f az ismeretlen függvény, amit becsülni szeretnénk, míg ε egy véletlen zaj, amely a modell hibáját reprezentálja és függelen a bemeneti változóktól. Továbbá feltételezzük, hogy $E[\varepsilon] = 0$.

Két fő kérdésre keresünk választ a gépi tanulás során:

- Egy új bemeneti adat (x) esetén mennyi lesz a célváltozó (y) értéke?
Ez a predikciós kérdés. Ebben az esetben a függvény úgynevezett „fekete doboz” modellként működik, ahol nem a függvény pontos alakja a lényeg, hanem a predikciós teljesítménye. Az előrejelzés pontossága két hibafaktortól függ, egy csökkenthető hibától, amely a függvény becslésének pontosságából adódik, és egy nem csökkenthető hibától, amely egy felső korlátot szab az előrejelzés pontosságának.
- Hogyan befolyásolja a bemeneti változó (X) értéke a célváltozó (Y) értékét?
Ez a magyarázó kérdés. Vizsgálhatjuk, hogy a bemeneti változók közül melyik az néhány legfontosabb, amely a legnagyobb hatással van a célváltozó értékére. Ilyenkor a függvény pontos alakja is fontos, nem viselkedhet „fekete doboz” modellként.

A változóknak két fő típusát különböztetjük meg, lehetnek kvalitatív (minőségi) vagy kvantitatív (mennyiségi) változók. A kvalitatív változók kategóriákba, osztályokba sorolhatóak, például a nem, a szín vagy a márka. Ezzel szemben a kvantitatív változók számszerű értékeket vesznek fel, ilyen például a magasság, a súly vagy az ár. A célváltozó típusa alapján a gépi tanulási problémák lehetnek klasszifikációs vagy regressziós problémák. Klasszifikáció esetén a célváltozó kvalitatív, és a modell célja, hogy egy adott bemeneti adat alapján megállapítsa a hozzá tartozó kategóriát. Regresszió esetén a célváltozó kvantitatív, és a modell célja, hogy egy adott bemeneti adat alapján megjósolja a hozzá tartozó számértéket. A határvonal a klasszifikációs és regressziós módszerek között azonban nem mindig éles. A legkisebb négyzetek módszerét mennyiségi meghatározásra használjuk, a logisztikus regressziót pedig kvalitatív meghatározásra, de a KNN (K-Nearest Neighbors) algoritmust, a döntési fákat mind a két probléma esetén használhatjuk.


Mindkét probléma esetén fontos vizsgálni a modell teljesítményét, hibáját. A várható hiba egy x_0 pontban a következőképpen írható fel:

$$\begin{aligned}
E\left[\left(y_0 - \hat{f}(x_0)\right)^2\right] &= E\left[\left(f(x_0) + \varepsilon - \hat{f}(x_0)\right)^2\right] = \\
E\left[\left(f(x_0) - \hat{f}(x_0)\right)^2 + \varepsilon^2 + 2\left(f(x_0) - \hat{f}(x_0)\right)\varepsilon\right] &= \\
E\left[\left(f(x_0) - \hat{f}(x_0)\right)^2\right] + E[\varepsilon^2] + 2E\left[\left(f(x_0) - \hat{f}(x_0)\right)\varepsilon\right] &= \quad (64) \\
E\left[\left(f(x_0) - \hat{f}(x_0)\right)^2\right] + \text{Var}[\varepsilon] + 2E[\varepsilon]E\left[f(x_0) - \hat{f}(x_0)\right] &= \\
E\left[\left(f(x_0) - E[\hat{f}(x_0)] + E[\hat{f}(x_0)] - \hat{f}(x_0)\right)^2\right] + \text{Var}[\varepsilon] &= \\
E\left[\left(f(x_0) - E[\hat{f}(x_0)]\right)^2\right] + E\left[\left(E[\hat{f}(x_0)] - \hat{f}(x_0)\right)^2\right] + \text{Var}[\varepsilon] &= \\
\left(E[\hat{f}(x_0)] - f(x_0)\right)^2 + \text{Var}[\hat{f}(x_0)] + \text{Var}[\varepsilon] &
\end{aligned}$$

ahol $\hat{f}(x_0)$ a modell által adott előrejelzés, $f(x_0)$ a valódi értéke, és ε a nem csökkenthető hiba. Tehát a várható hiba három összetevőből épül fel: a becslés varianciájából

$(\text{Var}[\hat{f}(x_0)])$, a becslés torzításának négyzetéből $((E[\hat{f}(x_0)] - f(x_0))^2$ és a hibatag varianciájából $(\text{Var}[\varepsilon])$.

Ahhoz, hogy a várható hiba értékét minimalizáljuk, olyan módszert kell választanunk, amely egyszerre biztosít alacsony variációt és alacsony torzítást. A variancia azt mutatja meg, hogy a modell előrejelzése mennyire érzékeny a tanító adathalmaz változásaira. Általánosságban elmondható, hogy a komplexebb modellek nagyobb varianciával rendelkeznek. A torzítás pedig abból fakad, hogy a modell nem képes pontosan megragadni a valódi függvény alakját, ez akkor fordulhat elő ha egy bonyolult problémát egy egyszerűbb modellel közelítünk. Például ha a változók közötti kapcsolat erősen nemlineáris, de egy lineáris modellt használunk, akkor a modell torzított lesz. Általában a kevésbé komplex modellek nagyobb torzítással rendelkeznek. Tehát láthatjuk, hogy a modell komplexitásának növelése csökkenti a torzítást, de növeli a variációt. Ez az úgynevezett torzítás-variancia kompromisszum (bias-variance tradeoff).



1. Ábra: Torzítás-variancia kompromisszum illusztrációja

Az 1. Ábra alapján látható, hogy a modell komplexitásának növelésével a torzítás csökken, de a variancia nő. Az ábrán is látható, hogy kezdetben a modell komplexitásának növelésével a torzítás gyorsabban csökken, mint ahogy a variancia nő, így a teljes hiba csökken. Azonban egy bizonyos pont után a variancia növekedése gyorsabb lesz, mint a torzítás csökkenése, így a teljes hiba növekedni kezd. Az optimális pont ott van, ahol a teljes hiba minimális. Valós helyzetben, mivel a valódi függvény nem ismert, nem tudjuk explicit módon kiszámolni a torzítást és a variációt, ezért gyakran keresztvalidációs módszereket alkalmazunk a modell teljesítményének értékelésére.


Ahhoz, hogy kiértékeljük egy modell teljesítményét, szükségünk van egy mérőszámra, amely megmutatja, hogy a modell mennyire jól teljesít a tanító adathalmazon vagy egy

új, ismeretlen adathalmazon. A regressziós problémák esetén a leggyakrabban használt mérőszámok közé tartozik az átlagos négyzetes hiba (MSE):

$$\text{MSE} = \sum_{i=1}^n \frac{(y_i - \hat{f}(x_i))^2}{n} \quad (65)$$

ahol y_i a valódi érték, $\hat{f}(x_i)$ a modell által adott előrejelzés, és n a minta mérete. Minél kisebb az MSE értéke, annál jobb a modell teljesítménye. Ezt az értéket a tanító adatra tudjuk kiszámolni, de a modell választásánál az új, ismeretlen adatokon való teljesítmény a fontosabb. Mivel a tanító adaton való teljesítmény nem feltétlenül tükrözi az új adatokon való teljesítményt, nem választhatjuk a legkisebb MSE-vel rendelkező módszert. Sőt, ha a tanító adaton túl jól teljesít egy módszer, akkor fennáll a veszélye annak, hogy a modell túltanult (overfitting), vagyis a modell nemcsak a valódi mintázatot tanulta meg, hanem a tanító adathalmaz zaját is, így az új adatokon való teljesítménye gyenge lesz.

Tehát ebben az esetben is fennáll a torzítás-variancia kompromisszum esetéhez hasonló összefüggés: a modell komplexitásának növelésével a tanító adaton az MSE monoton csökken, azonban a teszt adaton az MSE egy bizonyos pont után növekedni kezd, mivel a modell túltanul. (2. Ábra)




2. Ábra: Túllillesztés illusztrációja

A gyakorlatban a tanító adaton az MSE értékét meg tudjuk határozni, de a teszt adaton az MSE értékét nem, mivel a teszt adaton a valódi értékek nem ismertek. A minimumpont meghatározására a gyakorlatban az egyik leelterjedtebb módszer a keresztvalidáció, amely során a tanító adatot több részre osztjuk, és a modell teljesítményét ezekre a részekre értékeljük. Ez lehetővé teszi, hogy becslést kapjunk a modell új adatokon való teljesítményére, és segítséget nyújt a megfelelő modell komplexitásának kiválasztásában.

4.2 Döntési fák

A fa-alapú módszerek egy jelentős és széles körben használt osztálya a gépi tanulási algoritmusoknak. Ezek a módszerek könnyen értelmezhető modelleket hoznak létre, amelyek jól teljesítenek mind klasszifikációs, mind regressziós problémák esetén. Ezek a módszerek a bementeti változók terét egyszerű, jellemzően téglalap alakú régiókra osztják fel, rétegzik azokat. Ha egy új megfigyelést szeretnénk osztályozni vagy a hozzá tartozó értéket előrejelezni, akkor a modell megvizsgálja, hogy a megfigyelés melyik régióba esik, és a régióba eső tanuló adatok között előforduló leggyakoribb osztályt vagy a régióba eső tanuló adatok átlagát használja a predikcióhoz. A modell struktúrája:


- Gyökércsomópont: A legfelső szint, ami a teljes adatot reprezentálja.
- Belső csomópontok: Egy-egy bemeneti változó (feature) alapján végzett döntést reprezentálnak, amelyek az adatot két vagy több részre osztják.
- Élek: A tesztek eredményét reprezentálják, amelyek a bemeneti változó értékétől függően vezetnek a következő csomóponthoz.
- Levélcsomópontok: Az osztályokat vagy a regressziós értékeket reprezentálják, amelyek a modell végső döntését adják meg.



3. Ábra: Döntési fa példa

A 3. Ábra egy döntési fa példáját mutatja be: lakások árát becsüli meg különböző jellemzők alapján. A döntési fa struktúrája a következő:

- A gyökércsomópontban az elhelyezkedés szerepel, ez a döntési folyamat kiindulópontja. A modell a tanítás során ezt a változót találta a legfontosabbnak, ez bontja fel legjobban az adatokat.
- Élek: A lehetséges állapotokat jelölik.
- Belső csomópontok: Ha az „elhelyezkedés” értéke alapján nem tudunk dönteni, további változókat kell vizsgálnunk. Például, ha a lakás a belvárosban helyezkedik el, akkor a következő változó, amit megvizsgálunk, a „Méret”.
- Levélcsomópontok: Ezek a végső döntéseket jelölik, például ha a lakás a belvárosban helyezkedik el és a mérete „Nagy”, akkor a modell szerint a lakás ára 95 millió forint.



4. Ábra: A bemeneti tér régiókra bontása a regressziós döntési fa szerint.

A 4. Ábra a regressziós döntési fa által létrehozott régiókat szemlélteti. Minden színezett tartomány egy levélcsomópontnak felel meg, és az ott szereplő szám az adott régióhoz rendelt becsült célérték.

4.2.1 A döntési fák tanítása

A fák építése mind a klasszifikációs, mind a regressziós problémák esetében rekurzív módon történik. A fák építése „mohó” módon történik, felülről lefelé haladva választjuk ki a legjobb vágást, amely az adott pillanatban a legjobban szétválasztja az adatokat. A legjobb vágás kiválasztásához különböző mérőszámokat használunk, ezek a következők lehetnek:

- *Gini-index*: Klasszifikációs problémák esetén használjuk. Azt méri, hogy mekkora eséllyel osztályoznánk félre egy véletlenszerűen kiválasztott elemet, ha a részhalmaz eloszlása alapján osztályoznánk. Minél kisebb a Gini-index, annál tisztább a részhalmaz.

$$G(m) = \sum_{k=1}^K p_{mk}(1 - p_{mk}) = 1 - \sum_{k=1}^K p_{mk}^2, \quad (66)$$

ahol p_{mk} a k -edik osztályba tartozó elemek aránya a m -edik részhalmazban.

- *Entrópia*: Szintén klasszifikációs problémák esetén használjuk. Azt méri, hogy mekkora információt nyerünk egy adott vágással. Minél nagyobb az entrópia csökkenése, annál jobb a vágás.

$$H(m) = - \sum_{k=1}^K p_{mk} \log(p_{mk}), \quad (67)$$

ahol p_{mk} a k -edik osztályba tartozó elemek aránya a m -edik részhalmazban.

- *Négyzetes hiba*: Regressziós problémák esetén használjuk. Azt mérjük, hogy a vágás utáni részhalmazban mekkora az a tényleges válaszértékek és a részhalmaz átlaga közötti eltérések négyzetösszege. Minél kisebb ez az érték, annál jobb a vágás.

$$\text{MSE}(m) = \frac{1}{n_m} \sum_{i=1}^m (y_i - \hat{y}_m)^2, \quad (68)$$

ahol n_m a m -edik részhalmazban lévő elemek száma, y_i a tényleges válaszérték, és $\hat{y}_m$ a részhalmaz átlaga.

A döntési fák esetén ügyelni kell arra, hogy a fa ne nőjön túl mélyre, mert ez túlannuláshoz vezethet. Erre megoldás lehet a fa vágása (pruning). Kétfő vágási módszert alkalmaznak a gyakorlatban:

- *Előmetzés (prepruning)*: A fa építése során már a vágás kiválasztásánál figyelembe vesszük a vágás utáni részhalmazok méretét, és csak akkor hajtjuk végre a vágást, ha a részhalmazok mérete egy bizonyos küszöbérték fölött van.
- *Utólagos metzés (postpruning)*: Először egy teljes fát építünk, majd utólagosan, alulról felfelé haladva metszük vissza a fát.


4.3 Ensemble módszerek

Az ensemble módszerek használata során több gyenge modellt kombinálunk egy erősebb modell létrehozásához. Két fő típusát különböztetjük meg:

- *Bagging*: A bagging során a tanító adatból bootstrap (visszatevéses mintavétellel) több új adathalmazt hozunk létre, majd mindegyiket tanítunk egy gyenge modellt (például egy metszés nélküli döntési fát). Majd egyesítjük a modellek előrejelzéseit, klasszifikáció esetén többségi szavazással, regresszió esetén pedig átlagolással. Mivel egy mély fának alacsony a torzítása, de magas a varianciája, ezért a bagging segítségével csökkenthetjük a varianciát anélkül, hogy a torzítást növelnénk.
- *Boosting*: Míg a bagging egymástól függetlenül, párhuzamosan épít fákat, addig a boosting során szekvenciálisan építjük a fákat. Minden új fa a korábbi fák információit használja fel és a korábbi fák által helytelenül osztályozott vagy előrejelzett megfigyelésekre helyezi a hangsúlyt, azaz ezeket a megfigyeléseket nagyobb súllyal veszi figyelembe a tanítás során.

4.3.1 Random Forest

Ensemble módszer, amely a bagging elvén alapul és nagyszámú, egymástól független döntési fát épít. A módszer regressziós és klasszifikációs problémák esetén is használható. A Random Forest során minden egyes fa építésekor a változók egy véletlenszerű részhalmazát választjuk ki, és csak ezek közül választjuk ki a legjobb vágást. (5. Ábra)



5. Ábra: Random Forest módszer vázlatos ábrája

Minden fát a lehető legnagyobbra növesztünk, azaz metszés nélkül építjük. A bagging esetében előfordulhat, hogyha van egy nagyon erős változó, akkor a tanított fák közül sok ezt az erős változót fogja választani a legelső vágáshoz, így a fák hasonlóak lesznek egymáshoz, nem lesznek függetlenek, így a variancia csökkentése sem lesz olyan hatékony. A Random Forest esetében viszont csak csak egy véletlen m elemű részhalmazzal választunk a p változóból, így a vágások $\frac{p-m}{p}$ arányában a legerősebb változó nem lesz kiválasztva, így a fák nagyobb mértékben lesznek különbözőek és függetlenek, így a variancia csökkentése is hatékonyabb lesz. A modell hiperparaméterei közé tartozik a minimális csomópontok száma és a változókból kiválasztott részhalmaz mérete. Az m paraméter értékét gyakran a gyakorlatban $\sqrt{p}$ -re (klasszifikációs problémák esetén) vagy $\frac{p}{3}$ -ra (regressziós problémák esetén) állítják be, de ez a probléma jellegétől függően változhat. A minimális csomópontok számát klasszifikációs problémák esetén gyakran 1-re, regressziós problémák esetén pedig 5-re állítják be, de ez is a probléma jellegétől függően változhat. A Random Forest módszer nagy előnye, hogy nem érzékeny a fák számára, így általában a nagy számú fa építése nem vezet túltanuláshoz, ahogy egyre több fát adunk a modellhez, a hibaartás csökken, és egy bizonyos pont után stabilizálódik.

Random Forest esetén, mivel minden fa egy bootstrap mintán tanul, a tanító adathalmaz körülbelül egyharmada minden fa esetében kimarad a tanításból, ezeket a kimaradt pontokat nevezzük out-of-bag (OOB) pontoknak. Ezt felhasználva a modell teljesítményét is értékelhetjük, anélkül, hogy külön teszt adathalmazt kellene fenntartanunk. A hibabecsléshez minden egyes megfigyelés esetén kiszámoljuk a fák előrejelzését, amelyek nem tanultak az adott megfigyelésen (azaz azok a fák, amelyeknél az adott megfigyelés OOB pont), majd ezeket az előrejelzéseket átlagoljuk (regresszió esetén) vagy többségi szavazással egyesítjük (klasszifikáció esetén), és összehasonlítjuk a valódi értékekkel. A hagyományos döntési fákkal szemben a Random Forest kevésbé átlátható, de többféle mutatóval is értékelhetjük a változók fontosságát, például a csomópontok tisztaságának növekedése alapján, vagy az OOB hibabecslés alapján, amely megmutatja, hogy egy adott változó kizárása hogyan befolyásolja a modell teljesítményét.

4.4 Idősorok elemzése

Idősornak tekinthetünk minden olyan adatot, amelyet időpontokhoz rendelünk és a megfigyelések között időbeli függés van, például a bűnügyi statisztikák is jellemzően idősorok. Az idősorok elemzése olyan módszereket foglal magában, amelyekkel az adatokból mintázatok, trendeket lehet felismerni, valamint előrejelzéseket készíthetünk. Az idősorok elemzésének két fő célja van: a múltbeli adatok megértése és a jövőbeli értékek előrejelzése. Az idősorok egyik legfontosabb jellemzője, hogy az egymást követő megfigyelések nem függetlenek. Ez a függőség lehet rövid távú, amikor a közelmúlt megfigyelései befolyásolják a jövőbeli értékeket, vagy hosszútávú, amikor trendek vagy szezonális mintázatok figyelhetők meg az adatokban. Akkor beszélhetünk trendről, ha az adatokban hosszú távú növekedés vagy csökkenés figyelhető meg, míg szezonális mintázat esetében az adatsort valamilyen ismétlődő ciklus jellemzi, például éves, havi

vagy heti szinten. Ezek alapján az idősorok több, egymástól független komponensből állhatnak, tehát egy Y_t idősor felírható a következőképpen:

$$Y_t = f(S_t, T_t, \varepsilon_t) \quad (69)$$

ahol S_t a szezonális komponens, T_t a trendkomponens, és ε_t a maradéktag.

4.4.1 Alapfogalmak

Definíció 4.4.1.1

Egy idősor kovarianciája a következőképpen definiálható:

$$\text{Cov}(X_t, X_{t+k}) = E[(X_t - E[X_t])(X_{t+k} - E[X_{t+k}])], \quad (70)$$

ahol X_t az idősor t -edik megfigyelése, $E[X_t]$ az idősor t -edik megfigyelésének várható értéke, és k a késleltetés (lag) értéke.

Definíció 4.4.1.2

Egy idősor autokovarianciája a következőképpen definiálható: $\gamma(h) = \text{Cov}(X_t, X_{t+h})$, ahol X_t az idősor t -edik megfigyelése, és h a késleltetés (lag) értéke.

Definíció 4.4.1.3

Egy idősor autokorrelációja a következőképpen definiálható: $\rho(h) = \frac{\gamma(h)}{\gamma(0)}$,

Definíció 4.4.1.4

Egy idősor gyengén stacionáris, ha teljesül az alábbi három feltétel:

1. Az idősor várható értéke időben állandó, azaz $E[X_t] = \mu$ minden t -re.
2. $E[X_t^2] < \infty$ minden t -re.
3. Két megfigyelés közötti kovariancia csak a köztük lévő időkülönbségtől (h) függ és nem a konkrét t időponttól, azaz $\text{Cov}(X_t, X_{t+h}) = \gamma(h)$.

Definíció 4.4.1.5

Egy idősor erősen stacionáris, ha minden h és minden $t_1, t_2, \dots, t_n$ esetén teljesül, hogy $(X_{t_1}, X_{t_2}, \dots, X_{t_n})$ és $(X_{t_1+h}, X_{t_2+h}, \dots, X_{t_n+h})$ azonos eloszlásúak.

A (gyenge) stacionaritás fontos fogalom az idősorelemzésben, mivel a legtöbb klasszikus idősorelemzési módszer feltételezi, hogy az idősor (gyengén)stacionáris. A stacionaritás azt jelenti, hogy az idősor statisztikai tulajdonságai időben állandóak, így a múltbeli adatok alapján megbízhatóan előrejelezhetjük a jövőbeli értékeket.

4.4.2 Klasszikus idősorelemzési módszerek

A klasszikus idősorelemzési módszereket két nagy csoportra oszthatjuk: determinisztikus és sztochasztikus módszerekre.

4.4.2.1 Determinisztikus és simítási módszerek

Ezek a módszerek az adatokban lévő véltlen ingadozás kiszűrésére, a mögöttes trendek és szezonális mintázatok kiemelésére szolgálnak. Ezek a módszerek olyan rekurzív becslésnek tekinthetők, amely során a múltbeli megfigyelések egy súlyozott kombinációját használjuk a jövőbeli érték becslésére. A súlyok meghatározása alapján különböző simítási módszereket különböztetünk meg:

- **Egyszerű exponenciális simítás:** Olyan idősorok esetén használjuk, amelyekben nincs trend vagy szezonális mintázat. A módszer lényege, hogy a jövőbeli értéket a múltbeli értékek súlyozott átlagaként becsljük, ahol a súlyok exponenciálisan csökkennek a múltbeli értékekre vonatkozóan. Az alapegyenlete a következőképpen írható fel:

$$\hat{Y}_{t+1} = \alpha Y_t + (1 - \alpha) \hat{Y}_t, \quad (71)$$

ahol α a simítási paraméter, amely értéke 0 és 1 között van, Y_t az idősor t -edik megfigyelése, és $\hat{Y}_t$ a t -edik időpontban becsült érték. Ebből megmutatható:

$$\hat{Y}_{t+1} = \alpha \sum_{h=0}^{\infty} (1 - \alpha)^h Y_{t-h} \quad (72)$$

- **Holt-Winters módszer:** Olyan idősorok esetén használjuk, amelyekben trend és/vagy szezonális mintázat is megfigyelhető. A módszer három egyenletből áll, amelyek a szint, a trend és a szezonális komponens becslésére szolgálnak. A három egyenlet a következőképpen írható fel:

$$\ell_t = \alpha(Y_t - s_{t-m}) + (1 - \alpha)(\ell_{t-1} + b_{t-1}), \quad (73)$$

$$b_t = \beta(\ell_t - \ell_{t-1}) + (1 - \beta)b_{t-1}, \quad (74)$$

$$s_t = \gamma(Y_t - \ell_t) + (1 - \gamma)s_{t-m}, \quad (75)$$

ahol ℓ_t a szint becslése, b_t a trend becslése, s_t a szezonális komponens becslése, α , β és γ a simítási paraméterek, amelyek értéke 0 és 1 között van, Y_t az idősor t -edik megfigyelése, és m a szezon hossza. Ekkor az előrejelzés az $t + h$ időpontban a következőképpen számítható:

$$\hat{Y}_{t+h} = \ell_t + hb_t + s_{t+h-m}, \quad (76)$$

ahol h a előrejelzés időtávja.

4.4.2.2 Sztochasztikus módszerek

A klasszikus sztochasztikus megközelítés alapját a Box-Jenkins módszertan képezi, amely az autoregresszív és mozgóátlag modellekre épül. Ezek a modellek nemcsak a determinista komponenseket, hanem a véletlen ingadozásokat is modellezzik. Ezek a módszerek feltételezik, hogy az idősor stacionárius, így gyakran szükséges az idősor differenciálása a stacionaritás eléréséhez.

- **Autoregresszív (AR) modellek:** Az AR modellekbe a jövőbeli értékek a múltbeli értékek lineáris kombinációjaként áll elő:

$$Y_t = c + \sum_{i=1}^p \varphi_i Y_{t-i} + \varepsilon_t, \quad (77)$$

ahol Y_t az idősor t -edik megfigyelése, c egy konstans, φ_i az autoregresszív paraméterek, p az autoregresszív rend, és ε_t a hiba.

- **Mozgóátlag (MA) modellek:** Az MA modellek, szemben a determinisztikus mozgóátlag modellekkel, azt feltételezik, hogy a jövőbeli értékek nem a múltbeli tényleges értékektől, hanem a múltbeli előrejelzések hibáitól függenek:

$$Y_t = c + \sum_{i=1}^q \theta_i \varepsilon_{t-i} + \varepsilon_t, \quad (78)$$

ahol Y_t az idősor t -edik megfigyelése, c egy konstans, θ_i a mozgóátlag paraméterek, q a mozgóátlag rend, és ε_t a hiba.

- **ARMA és ARIMA modellek:** Ezek a modellek az AR és MA modellek kombinációi, az ARMA(p,q) modellt stacionárius idősorokra alkalmazzuk, míg az ARIMA(p,d,q) modell alkalmas nem stacionárius idősorokra is, ebben az esetben differenciálás segítségével érjük el a stacionaritást. A ARMA(p,q) modell a következőképpen írható fel:

$$Y_t = c + \sum_{i=1}^p \varphi_i Y_{t-i} + \sum_{j=1}^q \theta_j \varepsilon_{t-j} + \varepsilon_t, \quad (79)$$

ahol Y_t az idősor t -edik megfigyelése, c egy konstans, φ_i az autoregresszív paraméterek, θ_j a mozgóátlag paraméterek, p az autoregresszív rend, q a mozgóátlag rend, és ε_t a hiba. Az ARIMA modell esetén alkalmazott differenciálás:

$$\Delta Y_t = Y_t - Y_{t-1}, \quad (80)$$

Majd ezekre a differenciált értékekre alkalmazzuk az ARMA modellt, tehát d -edik rendű differenciálás esetén:

$$\Delta^d Y_t = c + \sum_{i=1}^p \varphi_i \Delta^d Y_{t-i} + \sum_{j=1}^q \theta_j \varepsilon_{t-j} + \varepsilon_t, \quad (81)$$

ahol $\Delta^d Y_t$ a d -edik rendű differenciált idősor t -edik megfigyelése.

A szezonális modellezésére a SARIMA modellt használjuk, amely az ARIMA modell kiterjesztése, és a szezonális komponenseket is figyelembe veszi. Amennyiben más, külső tényezőket is szeretnénk figyelembe venni az előrejezés során, akkor az ARIMAX modellt használhatjuk, azonban ez csak akkor alkalmazható, ha lineáris kapcsolat van a külső tényezők és az idősor között, ami a gyakorlatban sokszor nem teljesül.

4.4.3 Gépi tanulási és mélytanulási módszerek idősorok elemzésére

Ahogy azt korábban láttuk a klasszikus idősor elemzési módszerek sok előfeltételezéssel élnek az adatokra vonatkozóan, például a stacionaritás feltételezése, valamint a lineáris kapcsolat feltételezése a külső tényezők és az idősor között. Ezek a feltételezések gyakran nem teljesülnek a valós adatok esetében, így ezek a módszerek nem mindig nyújtanak jó előrejelzéseket. Ezzel szemben a gépi tanulási (Machine Learning, ML) és mély tanulási (Deep Learning, DL) módszerek rugalmasabbak, képesek komplex, nemlineáris összefüggések modellezésére is. A gépi tanulási módszerek alkalmazásához az idősorokat általában felügyelt tanítási problémává alakítjuk, ahol a célváltozó a jövőbeli érték, a bemeneti változók pedig a múltbeli értékek és a külső tényezők:

$$Y_t = f(X_t) + \varepsilon_t, \quad (82)$$

ahol Y_t a jövőbeli érték, X_t a bemeneti változók, f a modell, és ε_t a hiba. A gépi tanulási módszerek (például a döntési fák, Random Forest, Gradient Boosting, Support Vector Machines) általában nem tudják értelmezni az idősorok időbeli függését, így új változókat kell bevezetni, amelyek kifejezik a múltbeli értékek hatását a jövőbeli értékekre, ilyen változók lehetnek például:

- *Késleltetett (Lag) változók*: Ezek a múltbeli értékek, például $Y_{t-1}, Y_{t-2}, \dots, Y_{t-p}$, ahol p a késleltetés rendje.
- *Mozgóátlag változók*: Ezek a múltbeli értékek átlagai, például $MA_p = \frac{Y_{t-1} + Y_{t-2} + \dots + Y_{t-p}}{p}$, ahol p a mozgóátlag rendje.

A gépi tanulási módszerek nagy előnye a klasszikus módszerekkel szemben, hogy képesek a nemlineáris összefüggések modellezésére, illetve képesek a változók közötti kölcsönhatások figyelembevételére is. A gépi tanulási módszerekkel szemben a mélytanulási módszerek képesek megragadni az adatok időbeliségét is, például a Recurrent Neural Networks (RNN) és a Long Short-Term Memory (LSTM) hálózatok.

- *Recurrent Neural Networks (RNN)*: Olyan neurális hálózatok, amelyek képesek az adatok időbeli függését modellezni egy belső, rekurzív állapot (h_t) segítségével:

$$h_t = \sigma(W_h h_{t-1} + W_x X_t + b), \quad (83)$$

ahol h_t a rekurzív állapot a t -edik időpontban, W_h és W_x a súlyok, b a torzítás (bias), és σ egy aktivációs függvény.

- *Long Short-Term Memory (LSTM) hálózatok*: Olyan RNN-ek, amelyek képesek hosszú távú függőségek modellezésére is, egy speciális cella struktúrával, amely

három kaput tartalmaz: a bemeneti kaput , a kimeneti kaput és a felejtési kaput. Ezek a kapuk szabályozzák az információ áramlását a cellában, így lehetővé téve a hosszú távú függőségek megragadását is.

$$i_t = \sigma(W_i[h_{t-1}, X_t] + b_i), \quad (84)$$

$$o_t = \sigma(W_o[h_{t-1}, X_t] + b_o), \quad (85)$$

$$f_t = \sigma(W_f[h_{t-1}, X_t] + b_f), \quad (86)$$

Bár a mélytanulási módszerek rendelkeznek a legnagyobb kapacitással, gyakran nagy mennyiségű adatot és számítási erőforrást igényelnek a tanításhoz és black-box jellegük miatt az eredmények értelmezése is nehéz lehet. Ezzel szemben a gépi tanulási módszerek gyakran jó kompromisszumot jelentenek, nem igénylik a klasszikus módszerek szigorú előfeltételezéseit és alkalmazásukhoz nem szükséges annyi adat és számítási erőforrás, mint a mélytanulási módszerek esetén, valamint az eredmények értelmezését is megkönnyítik a mélytanulási módszerekkel szemben, például a döntési fák esetén a változók fontosságának értékelésével.

5 Irodalomjegyzék

- [1] S. E. Shreve, *Stochastic Calculus for Finance II: Continuous-Time Models*. Springer, 2004.
- [2] M. Pitera, „Stochastic Processes – Lecture Notes”. 2020.
- [3] F. Herzog, „Stochastic Differential Equations”. 2013.
- [4] B. Øksendal, *Stochastic Differential Equations: An Introduction with Applications*. Springer, 2003.
- [5] T. Hastie, R. Tibshirani, és J. Friedman, *The Elements of Statistical Learning*. Springer, 2009.
- [6] B. C. Csáji, „Data Mining and Machine Learning”. 2025.
- [7] G. James, D. Witten, T. Hastie, és R. Tibshirani, *An Introduction to Statistical Learning*, 2. kiad. Springer, 2021.
- [8] G. E. P. Box és G. M. Jenkins, *Time Series Analysis: Forecasting and Control*. Holden-Day, 1970.
- [9] R. J. Hyndman és G. Athanasopoulos, *Forecasting: Principles and Practice*, 2. kiad. OTexts, 2018.