

EÖTVÖS LORÁND TUDOMÁNYEGYETEM
Természettudományi Kar

Gyórfi Enikő

BŰNÖZÉSI GYAKORISÁG MODELLEZÉSE

Szakdolgozat
Matematika alapszak

Témavezető:
Maga Balázs



ELTE | TTK
TERMÉSZETTUDOMÁNYI KAR

Budapest, 2026

Tartalomjegyzék

1	Bevezetés	1
2	A Sztochasztikus Folyamatok Elméleti Alapjai	1
2.1	Definíciók és alapfogalmak	1
2.2	Sztochasztikus folyamatok	2
2.3	Brown-mozgás	4
3	Sztochasztikus differenciálegyenletek	6
3.1	Bevezetés	6
3.2	Itô-integrál	7
3.3	Geometriai Brown-mozgás	12
4	A gépi tanulás elméleti háttere	15
4.1	A gépi tanulás alapjai	15
4.2	Döntési fák	19
4.2.1	A döntési fák tanítása	21
4.3	Ensemble módszerek	22
4.3.1	Random Forest	22
4.4	Idősorok elemzése	23
4.4.1	Alapfogalmak	24
4.4.2	Klasszikus idősorelemzési módszerek	25
4.4.2.1	Determinisztikus és simításos módszerek	25
4.4.2.2	Sztochasztikus módszerek	26
4.4.3	Gépi tanulási és mélytanulási módszerek idősorok elemzésére	27
5	Gyakorlati alkalmazások	29
5.1	Adatok bemutatása	29
5.2	Bűnözés időbeli modellezése geometriai Brown-mozgással	33
5.2.1	Adatok előkészítése	33
5.2.2	Paraméterek meghatározása	34
5.2.3	Eredmények és értékelés	35
5.3	Bűnözés előrejelzése Random Forest modellel	38
5.3.1	Adatok előkészítése	38
5.3.2	Modellépítés és eredmények	41
5.3.2.1	Modell 1: Késleltetett változók	41
5.3.3	Modell 2: Késleltetett változók, mozgóátlagok és mozgószórások	44
5.4	Bűnözést befolyásoló demográfiai tényezők elemzése és előrejelzés készítése ..	45
6	Irodalomjegyzék	46

1 Bevezetés

2 A Sztochasztikus Folyamatok Elméleti Alapjai

2.1 Definíciók és alapfogalmak

Definíció 2.1.1

Egy valószínűségi tér $(\Omega, \mathcal{F}, P)$ hármasa tartalmazza:

- Ω (**eseménytér**): a lehetséges kimenetek halmaza.
- $\mathcal{F}$ (**σ -algebra**): Ω részhalmazainak olyan rendszere, amely tartalmazza az $\emptyset$ üres halmazt; komplementerre zárt; és megszámlálható unióra zárt. Az $(\Omega, \mathcal{F})$ párost mérhető térnek nevezzük.
- P (**valószínűségi mérték**): egy $P : \mathcal{F} \rightarrow \mathbb{R}$ függvény, amely kielégíti a $P(\emptyset) = 0$ és $P(\Omega) = 1$ feltételeket, és megszámlálható additivitással rendelkezik diszjunkt halmazok esetén.

Definíció 2.1.2

Legyen X egy Ω -n értelmezett függvényekből álló halmaz. Az X által generált σ -algebra a legkisebb σ -algebra, amelyre vonatkozóan ezen függvények mind mérhetőek. Jelölése: $\sigma(X)$.

Definíció 2.1.3

[1] Tegyük fel, hogy adott két valószínűségi mérték $\mathcal{P}$ és $\mathcal{Q}$ ugyanazon mérhető téren $(\Omega, \mathcal{F})$. Azt mondjuk, hogy a $\mathcal{Q}$ mérték abszolút folytonos a $\mathcal{P}$ -re nézve, ha létezik egy integrálható véletlen változó $f : \Omega \rightarrow \mathbb{R}$, melyre minden $A \in \mathcal{F}$ esetén

$$\mathcal{Q}(A) = \int_A f(\omega) d\mathcal{P}(\omega) \quad (1)$$

teljesül.

Ekkor f a $\mathcal{Q}$ mérték $\mathcal{P}$ -re vonatkozó sűrűségfüggvénye.

Megjegyzés. Ebben az esetben, ha $E^{\mathcal{P}}$ és $E^{\mathcal{Q}}$ a két mérték szerinti várható értékek, akkor minden $\mathcal{Q}$ szerint integrálható véletlen változóra X :

$$E^{\mathcal{Q}}[X] = \int_{\Omega} X \, d\mathcal{Q} = \int_{\Omega} X f \, d\mathcal{P} = E^{\mathcal{P}}[Xf]. \quad (2)$$

Definíció 2.1.4

[1] Legyen Ω egy nemüres halmaz. Legyen T egy rögzített pozitív szám, és tegyük fel, hogy minden $t \in [0, T]$ esetén adott egy $\mathcal{F}(t)$ σ -algebra. Tegyük fel továbbá, hogy ha $s \leq t$, akkor minden halmaz, amely eleme $\mathcal{F}(s)$ -nek, eleme $\mathcal{F}(t)$ -nek is. Ekkor a $0 \leq t \leq T$ paraméterű $\mathcal{F}(t)$ σ -algebrák gyűjteményét filtrációnak nevezzük.

Definíció 2.1.5

[1] Legyen X egy nem üres Ω mintatéren értelmezett valószínűségi változó. Legyen $\mathcal{G}$ az Ω részhalmazainak egy σ -algebrája. Ha a $\sigma(X)$ minden halmaza eleme $\mathcal{G}$ -nek is, akkor azt mondjuk, hogy X $\mathcal{G}$ -mérhető.

Definíció 2.1.6

[1] Legyen $f(t)$ egy $[0, T]$ intervallumon értelmezett függvény. Az f kvadratikus variációját a $[0, T]$ intervallumon a következő határértékkel definiáljuk:

$$[f, f](T) = \lim_{\|\Pi\| \rightarrow \infty} \sum_{i=0}^{n-1} (f(t_{i+1}) - f(t_i))^2, \quad (3)$$

ahol $\Pi = \{0 = t_0 < t_1 < \dots < t_n = T\}$ egy partíciója a $[0, T]$ intervallumnak, és $\|\Pi\| = \max_{0 \leq i \leq n-1} (t_{i+1} - t_i)$.

2.2 Sztochasztikus folyamatok

Definíció 2.2.1

[1] Legyen $(\Omega, \mathcal{F}, P)$ egy valószínűségi tér és T egy rögzített pozitív szám. Ekkor az $X = (X_t)_{t \in [0, T]}$ családot sztochasztikus folyamatnak nevezzük, ha minden $t \in [0, T]$ esetén X_t egy valószínűségi változó.

Definíció 2.2.2

[1] Legyen $(\Omega, \mathcal{F}, P)$ egy valószínűségi tér és $(\mathcal{F}(t))_{0 \leq t \leq T}$ filtráció. Legyen $X(t)$ egy valószínűségi változókból álló család, amelyet $t \in [0, T]$ paraméter indexel. Azt mondjuk, hogy $X(t)$ egy adaptált sztochasztikus folyamat az $\mathcal{F}(t)$ -re nézve, ha minden t -re az $X(t)$ valószínűségi változó $\mathcal{F}(t)$ -mérhető.

Definíció 2.2.3

[1] Legyen $(\Omega, \mathcal{F}, P)$ egy valószínűségi mező, legyen T egy rögzített pozitív szám, és legyen $(\mathcal{F}(t))_{0 \leq t \leq T}$ a $\mathcal{F}$ σ -algebráinak egy filtrációja. Tekintsünk egy adaptált sztochasztikus folyamatot $M(t)$ -t, $0 \leq t \leq T$.

(i) Ha $E[M(t) | \mathcal{F}(s)] = M(s)$ minden $0 \leq s \leq t \leq T$ esetén, akkor a folyamatot **martingálnak** nevezzük.

(ii) Ha $E[M(t) | \mathcal{F}(s)] \geq M(s)$ minden $0 \leq s \leq t \leq T$ esetén, akkor a folyamat **szubmartingál**.

(iii) Ha $E[M(t) | \mathcal{F}(s)] \leq M(s)$ minden $0 \leq s \leq t \leq T$ esetén, akkor a folyamat **supermartingál**.

Definíció 2.2.4

[1] Legyen $(\Omega, \mathcal{F}, P)$ egy valószínűségi mező, legyen T egy rögzített pozitív szám és legyen $(\mathcal{F}(t))_{0 \leq t \leq T}$ a $\mathcal{F}$ σ -algebráinak egy filtrációja. Az $X(t)_{0 \leq t \leq T}$ adaptált sztochasztikus folyamatot Markov-folyamatnak nevezzük, ha minden $0 \leq s < t \leq T$ és minden nemnegatív, Borel-mérhető f függvény esetén létezik egy g Borel-mérhető függvény, amelyre teljesül:

$$E[f(X(t)) | \mathcal{F}(s)] = g(X(s)) \quad (4)$$

Megjegyzés. Tehát a Markov-folyamat jövőbeli állapota csak a jelenlegi állapottól függ, és független a múltbeli állapotoktól. Ebből következik, hogy az együttes valószínűségi sűrűség feltételes formája felírható átmeneti sűrűségek szorzataként:

$$p(x_n, t_n \dots x_2, t_2 | x_1, t_1) = p(x_n, t_n | x_{n-1}, t_{n-1}) \dots p(x_2, t_2 | x_1, t_1). \quad (5)$$

Definíció 2.2.5

Egy folytonos Markov-folyamat időben homogén, ha az átmeneti sűrűsége csak az időbeli különbségektől függ:

$$p(x, t | y, s) = p(x, t - s | y, 0). \quad (6)$$

2.3 Brown-mozgás

Definíció 2.3.1

[2] Egy $B = (B_t)_{t \geq 0}$ sztochasztikus folyamatot Brown-mozgásnak (vagy Wiener-folyamatnak) nevezünk, ha az alábbi négy tulajdonságnak tesz eleget:

- A folyamat a $t = 0$ időpontban a nullából indul, 1 valószínűséggel, azaz $B_0 = 0$.
- A folyamat pályái, azaz a $t \mapsto B_t(\omega)$ leképezések minden egyes ω elemi eseményre, majdnem biztosan folytonosak.
- Bármely $0 \leq s_1 < t_1 \leq s_2 < t_2$ időpontosorozatra a $B_{t_1} - B_{s_1}$ és $B_{t_2} - B_{s_2}$ valószínűségi változók függetlenek egymástól.
- Bármely $s < t$ időpontpárra a $B_t - B_s$ növekmény normális eloszlású, 0 várható értékkel és $t - s$ szórásnégyzettel. Formálisan: $B_t - B_s \sim N(0, t - s)$.

Megjegyzés. A független növekmények tulajdonságából adódóan a Brown-mozgás egy Gauss–Markov-folyamat. Továbbá, mivel az átmeneti sűrűsége csak az időbeli különbségtől függ, egyben időben homogén Markov-folyamat is.

Definíció 2.3.2

[1] Legyen $(\Omega, \mathcal{A}, P)$ egy valószínűségi mező, amelyen a $B(t)$, $t \geq 0$ Brown-mozgás definiálva van. A $B(t)$ -hez tartozó filtráció egy $\mathcal{F}(t)$ szigma-algebrákból álló család, amelyre a következő feltételek teljesülnek:

- Az információ halmozódik: $\mathcal{F}(s) \subset \mathcal{F}(u)$ minden $0 \leq s < u$ esetén, vagyis az idő előrehaladtával az elérhető információ mennyisége nem csökken.
- Adaptivitás: minden $t \geq 0$ esetén a $B(t)$ $\mathcal{F}(t)$ -mérhető.
- A jövőbeli növekmények függetlensége: minden $0 \leq s < u$ esetén a $B(u) - B(s)$ növekmény független $\mathcal{F}(s)$ -től.

Tétel 2.3.3

[1] Legyen $(\Omega, \mathcal{A}, P)$ egy valószínűségi mező, amelyen a $B(t)$, $t \geq 0$ Brown-mozgás definiálva van. Ekkor a következő állítások teljesülnek:

- $B(t)$ martingál a fenti definícióban definiált filtrációval.

Bizonyítás. Elég azt bizonyítani, hogy a $B(t)$ folyamat martingál. Legyen $0 \leq s < t$ adott, és tekintsük a következő várható értéket:

$$E[B(t) \mid \mathcal{F}(s)] = E[B(t) - B(s) + B(s) \mid \mathcal{F}(s)]. \quad (7)$$

Mivel a Brown-mozgás növekményei függetlenek a múltbeli információtól, ezért

$$E[B(t) - B(s) \mid \mathcal{F}(s)] = E[B(t) - B(s)] = 0. \quad (8)$$

Ezenkívül, mivel $B(s)$ már ismert a $\mathcal{F}(s)$ -ben, ezért

$$E[B(s) \mid \mathcal{F}(s)] = B(s). \quad (9)$$

Ezeket az eredményeket összevonva kapjuk, hogy

$$E[B(t) \mid \mathcal{F}(s)] = 0 + B(s) = B(s). \quad (10)$$

Ez pontosan a martingál feltétel, így a $B(t)$ folyamat martingál. ■

3 Sztochasztikus differenciálegyenletek

3.1 Bevezetés

Egy közönséges differenciálegyenlet az alábbi formában írható fel:

$$\frac{dx(t)}{dt} = f(t, x(t)). \quad (11)$$

ahol $x(t)$ a vizsgált mennyiség időbeli változása, és $f(t, x(t))$ egy determinisztikus függvény, amely meghatározza a rendszer dinamikáját.

Integrál formában és $x(0) = x_0$ kezdeti értékkel ez az egyenlet a következőképpen néz ki:

$$x(t) = x_0 + \int_0^t f(s, x(s)) ds. \quad (12)$$

Egy SDE akkor jön létre, ha a differenciálegyenlet egy együtthatója determinisztikus paraméter helyett sztochasztikus paraméterré válik. Például tekintsük a következő KDE-t:

$$\frac{dx(t)}{dt} = a(t)x(t). \quad (13)$$

Amennyiben feltesszük, hogy $a(t)$ egy sztochasztikus folyamat, akkor az egyenlet sztochasztikus differenciálegyenletté alakul. Ekkor az $a(t)$ a következő formában írható fel:

$$a(t) = f(t) + h(t)\xi(t), \quad (14)$$

ahol $\xi(t)$ egy fehér zaj folyamat.

Ekkor az SDE a következőképpen néz ki:

$$\frac{dx(t)}{dt} = (f(t) + h(t)\xi(t))x(t) \quad (15)$$

Legyen $dB(t) = \xi(t) dt$, ahol $dB(t)$ a Brown-mozgás differenciálját jelöli, ekkor az SDE differenciál formában a következőképpen írható fel:

$$dx(t) = f(t)x(t) dt + h(t)x(t) dB(t). \quad (16)$$

Általánosabban egy Itô-típusú sztochasztikus differenciálegyenlet a következő formában írható fel:

$$dx(t, \omega) = f(t, x(t, \omega)) dt + g(t, x(t, \omega)) dB(t). \quad (17)$$

Egy általános, Itô-típusú SDE a következő szimbolikus formában írható fel:

$$dX(t) = \mu(t, X(t)) dt + \sigma(t, X(t)) dB(t). \quad (18)$$

Ez az egyenlet valójában egy integrálegyenlet rövidítése, és két fő részből áll:

- **Drift tag:** a folyamat változásának determinisztikus, előre jelezhető komponense egy infinitezimális dt időlépés alatt.
- **Diffúziós tag** $(\sigma(X_t, t) dB_t)$: ez a sztochasztikus, előre nem látható komponenst képviseli. A hatásának nagyságát a $\sigma(X_t, t)$ volatilitás- vagy diffúziós függvény skálázza, amely függhet a rendszer aktuális állapotától és az időtől is. Ez a tag visz véletlenszerűséget a rendszer leírásába.

3.2 Itô-integrál

Amikor a modellezett rendszerben véletlen hatások jelennek meg, a klasszikus integrál-fogalom már nem elegendő. Számos alkalmazási területen, például pénzügyi matematikában, fizikai rendszerek leírásában vagy biológiai folyamatok vizsgálatában, a modellek természetes módon vezetnek sztochasztikus folyamatokhoz. A Brown-mozgás pályái 1 valószínűséggel folytonosak, de sehol sem differenciálhatók, így nem rendelkeznek jól definiált deriváltakkal. Emiatt a hagyományos Riemann- vagy Lebesgue-integrál közvetlenül nem alkalmazható olyan kifejezésekre, mint például

$$\int_0^t X(s) dB(s). \quad (19)$$

Az ilyen típusú integrálok értelmezéséhez egy új integrálfogalom bevezetése szükséges. Az Itô-integrál lehetővé teszi, hogy Brown-mozgásra vonatkozóan értelmezzük a sztochasztikus integrálokat.

Az előbbi kifejezésben az integrál egyik összetevője egy $B(t)$, $t \geq 0$ Brown-mozgás, valamint az ehhez tartozó $\mathcal{F}(t)$, $t \geq 0$ filtráció. Az integrandus $X(t)$ egy adaptált sztochasztikus folyamat, amely azt jelenti, hogy minden $t \geq 0$ esetén $X(t)$ $\mathcal{F}(t)$ -mérhető. Az adaptáltság biztosítja, hogy $X(t)$ értéke csak a t időpontig ismert információtól függ.

Definíció 3.2.1

[1] Legyen a $0 = t_0 < t_1 < \dots < t_n = T$ egy partíciója a $[0, T]$ intervallumnak, és legyen $\Delta(t)$ konstans minden $t \in [t_i, t_{i+1})$ intervallumon. Ekkor $\Delta(t)$ -t elemi folyamatnak nevezzük.

Ez analóg a Lebesgue-integrál lépcsős függvényeivel, ahol a függvény értéke egy adott intervallumon állandó.

Definíció 3.2.2

[1] Egy elemi folyamat Itô-integrálja a következőképpen definiálható:

$$I(t) = \int_0^T \Delta(s) dB(s) = \sum_{j=0}^n \Delta(t_j)(B(t_j) - B(t_{j-1})) + \Delta(t_n)(B(T) - B(t_n)). \quad (20)$$

Tétel 3.2.3

[1] Legyen $\Delta(t)$ egy elemi folyamat, ekkor az Itô-izometria a következőképpen írható fel:

$$E \left[\left(\int_0^t \Delta(s) dB(s) \right)^2 \right] = E \left[\int_0^t \Delta^2(s) ds \right]. \quad (21)$$

Az elemi folyamatok integráljának felhasználásával az Itô-integrál kiterjeszthető általános adaptált sztochasztikus folyamatokra, amelyek kielégítik a megfelelő feltételeket:

- $X(t)$ adaptált a $\mathcal{F}(t)$ filtrációhoz.
- $X(t)$ kvadratikusan integrálható, azaz $\int_0^t E[X^2(s)] ds < \infty$ minden $t \geq 0$ esetén.

Az integrál definiálásához az $X(t)$ folyamatot elemi folyamatokkal közelítjük. Vesszük a $[0, T]$ intervallum egy partícióját: $0 = t_0 < t_1 < \dots < t_n = T$, és a $[t_j, t_{j+1}]$ intervallumon a közelítő $\Delta(t)$ elemi folyamat értékét az $X(t_j)$ értékére állítjuk. Így a felosztás finomításával az elemi folyamat egyre jobb közelítést ad az $X(t)$ folyamatnak. Választható tehát elemi folyamatok sorozata $\Delta_n(t)$ úgy, hogy a következő konvergencia teljesüljön, ha $n \rightarrow \infty$:

$$E \int_0^t |X(s) - \Delta_n(s)|^2 ds \rightarrow 0. \quad (22)$$

Ekkor az Itô-integrál a következőképpen definiálható:

$$\int_0^t X(s) dB(s) = \lim_{n \rightarrow \infty} \int_0^t \Delta_n(s) dB(s), \quad 0 \leq t \leq T. \quad (23)$$

Az integrál tulajdonságait a következő tétel foglalja össze:

Tétel 3.2.4

[1] Legyen T egy pozitív konstans, és legyen $X(t)$, $0 \leq t \leq T$ egy adaptált sztochasztikus folyamat, amely kielégíti a fentebb írt feltételeket. Ekkor az

$$I(t) = \int_0^t X(s) dB(s) \quad (24)$$

folyamat a következő tulajdonságokkal rendelkezik:

- **Folytonosság:** $I(t)$ pályái folytonosak.
- **Adaptáltság:** minden t -re az $I(t)$ folyamat $\mathcal{F}(t)$ -mérhető.
- **Linearitás:** ha $I(t) = \int_0^t X(s) dB(s)$ és $J(t) = \int_0^t Y(s) dB(s)$, akkor $I(t) + J(t) = \int_0^t (X(s) + Y(s)) dB(s)$. Továbbá minden c konstansra $I(t) = \int_0^t c X(s) dB(s)$.
- **Martingál tulajdonság:** az $I(t)$ folyamat martingál.
- **Itô-izometria:** $E[I^2(t)] = E\left[\int_0^t X^2(u) du\right]$.
- **Kvadratikus variáció:** $[I, I](t) = \int_0^t X^2(u) du$.

Eddig azt vizsgáltuk, hogyan lehet értelmezni egy Brown-mozgásra vonatkozó integrált, és milyen tulajdonságokkal rendelkezik ez az integrál. Most vizsgáljuk meg, hogyan lehet értelmezni egy Brown-mozgás által meghatározott folyamat megváltozását. Tekintsük a következő kifejezést:

$$\frac{d}{dt} f(B(t)). \quad (25)$$

Ez a kifejezés nem értelmezhető a klasszikus analízisben használt láncszabály szerint, mivel a Brown-mozgás pályái sehol sem differenciálhatók. Ennek értelmezéséhez az Itô–Doeblin-formula alkalmazására van szükség, amely egy sztochasztikus változókra vonatkozó általánosított láncszabály.

Tétel 3.2.5

[1] Legyen $f(t, x)$ függvény, melynek parciális deriváltjai f_t , f_x és f_{xx} léteznek és folytonosak. Legyen továbbá $B(t)$ egy Brown-mozgás. Ekkor minden $T \geq 0$ esetén teljesül a következő egyenlőség:

$$\begin{aligned} f(T, B(T)) &= f(0, B(0)) + \int_0^T f_t(t, B(t)) dt \\ &+ \int_0^T f_x(t, B(t)) dB(t) + \frac{1}{2} \int_0^T f_{xx}(t, B(t)) dt. \end{aligned} \quad (26)$$

Ahhoz, hogy megértsük az Itô–Doebelin-formula jelentőségét, tekintsük a következő példát. Legyen $f(x) = \frac{1}{2}x^2$, ekkor f nem függ az időtől, így $f_t = 0$, és a parciális deriváltakak $f_x = x$ és $f_{xx} = 1$. Legyen x_{j-1} és x_j két szomszédos pont egy partícióban, és tekintsük a Taylor-sor első két tagját:

$$f(x_j) - f(x_{j-1}) = f_x(x_{j-1})(x_j - x_{j-1}) + \frac{1}{2}f_{xx}(x_{j-1})(x_j - x_{j-1})^2. \quad (27)$$

Továbbá legyen $T > 0$ egy rögzített pozitív szám, és legyen a $[0, T]$ intervallum egy partíciója $\mathcal{P} = \{t_0, t_1, \dots, t_n\}$. Az $f(B(t))$ folyamat változását 0 és T között a következőképpen írhatjuk fel:

$$\begin{aligned} f(B(T)) - f(B(0)) &= \sum_{j=1}^n f_x(B(t_{j-1}))(B(t_j) - B(t_{j-1})) + \\ &\quad \frac{1}{2} \sum_{j=1}^n f_{xx}(B(t_{j-1}))(B(t_j) - B(t_{j-1}))^2. \end{aligned} \quad (28)$$

Ha ebbe behelyettesítjük a parciális deriváltakak értékét, akkor a következő egyenlőséget kapjuk:

$$\begin{aligned} f(B(T)) - f(B(0)) &= \sum_{j=1}^n B(t_{j-1})(B(t_j) - B(t_{j-1})) + \\ &\quad \frac{1}{2} \sum_{j=1}^n (B(t_j) - B(t_{j-1}))^2. \end{aligned} \quad (29)$$

A partíció finomításával, azaz ha $\|\mathcal{P}\| \rightarrow 0$, akkor a következő konvergencia teljesül:

$$\sum_{j=1}^n B(t_{j-1})(B(t_j) - B(t_{j-1})) \rightarrow \int_0^T B(t) dB(t) \quad (30)$$

és

$$\sum_{j=1}^n (B(t_j) - B(t_{j-1}))^2 \rightarrow [B, B](T) = T. \quad (31)$$

Ezeket az eredményeket összevonva kapjuk, hogy

$$f(B(T)) - f(B(0)) = \int_0^T B(t) dB(t) + \frac{1}{2}T. \quad (32)$$

Ez pontosan az Itô–Doebelin-formula egy speciális esete, amelyben a függvény csak a Brown-mozgás értékétől függ, és nem függ az időtől.

Eddig az Itô–Doebelin-formulát egy speciális esetre vizsgáltuk, nevezetesen a Brown-mozgásra. Azonban ez a formula általánosítható tetszőleges Itô-folyamatokra is.

Definíció 3.2.6

[1] Legyen $B(t)$ egy Brown mozgás és $\mathcal{F}$ a $B(t)$ -hez tartozó filtráció. Az $X(t)$ folyamatot Itô-folyamatnak nevezzük, ha felírható a következő alakban:

$$X(t) = X(0) + \int_0^t \mu(s) ds + \int_0^t \sigma(s) dB(s), \quad (33)$$

ahol $\mu(s)$ és $\sigma(s)$ adaptált sztochasztikus folyamatok, amelyek kielégítik a megfelelő integrálhatósági feltételeket, és $X(0)$ egy adott kezdeti érték.

Tekintsünk egy általános Itô-folyamatot $X(t)$ -t, amely kielégíti a következő SDE-t:

$$dX(t) = \mu(t) dt + \sigma(t) dB(t). \quad (34)$$

Ekkor az Itô–Doebelin-formula kiterjeszthető az $X(t)$ folyamatra is, és a következőképpen írható fel:

Tétel 3.2.7

[1] Legyen $X(t)$ egy Itô-folyamat, amely kielégíti a következő SDE-t:

$$dX(t) = \mu(t, X(t)) dt + \sigma(t, X(t)) dB(t), \quad (35)$$

és legyen $f(t, x) \in C^2([0, \infty) \times \mathbb{R})$. Ekkor az $Y(t) = f(t, X(t))$ folyamatra teljesül a következő egyenlőség:

$$dY(t) = \frac{\partial f(t, X(t))}{\partial t} dt + \frac{\partial f(t, X(t))}{\partial x} dX(t) + \frac{1}{2} \frac{\partial^2 f(t, X(t))}{\partial x^2} (dX(t))^2. \quad (36)$$

A fenti tételben a $(dX(t))^2$ kifejezés a következőképpen értelmezendő:

$$(dX(t))^2 = (\mu(t, X(t)) dt + \sigma(t, X(t)) dB(t))^2. \quad (37)$$

A következő egyenlőségek teljesülnek:

- $(dt)^2 = 0$,
- $dt dB(t) = 0$,
- $(dB(t))^2 = dt$.

Ezeket az eredményeket összevonva kapjuk, hogy

$$(dX(t))^2 = \sigma^2(t, X(t)) dt. \quad (38)$$

Ezt az eredményt visszahelyettesítve a tétel állításába kapjuk, hogy

$$dY(t) = \frac{\partial f(t, X(t))}{\partial t} dt + \frac{\partial f(t, X(t))}{\partial x} dX(t) + \frac{1}{2} \frac{\partial^2 f(t, X(t))}{\partial x^2} \sigma^2(t, X(t)) dt. \quad (39)$$

3.3 Geometriai Brown-mozgás

A pénzügyi modellezésben és más területeken, ahol a vizsgált mennyiségek (például árak vagy populációk mérete) nem vehetnek fel negatív értéket, és a növekedésük arányos a jelenlegi méretükkel, a leggyakrabban használt modell a geometriai Brown-mozgás (GBM).

Definíció 3.3.1

[1] Legyen $B(t)$ Brown-mozgás. Az $S(t)$ folyamatot geometriai Brown-mozgásnak nevezzük, ha kielégíti a következő sztochasztikus differenciálegyenletet:

$$dS(t) = \mu S(t) dt + \sigma S(t) dB(t), \quad (40)$$

ahol μ és σ konstansok.

A következő tétel megmutatja, hogy a geometriai Brown-mozgás explicit megoldással rendelkezik, amely egy exponenciális függvény formájában írható fel.

Tétel 3.3.2

[3] Legyen $S(t)$ egy geometriai Brown-mozgás, amely kielégíti a következő SDE-t:

$$dS(t) = \mu S(t) dt + \sigma S(t) dB(t), \quad (41)$$

ahol μ és σ konstansok. Ekkor az $S(t)$ folyamat explicit megoldása a következőképpen írható fel:

$$S(t) = S(0) \exp\left(\left(\mu - \frac{1}{2}\sigma^2\right)t + \sigma B(t)\right). \quad (42)$$

Bizonyítás. Legyen $Y(t) = \Phi(t, S(t)) = \ln(S(t))$. A parciális deriváltak a következők:

$$\frac{\partial \Phi(t, S)}{\partial S} = \frac{1}{S}, \quad \frac{\partial^2 \Phi(t, S)}{\partial S^2} = -\frac{1}{S^2}, \quad \frac{\partial \Phi(t, S)}{\partial t} = 0. \quad (43)$$

Ekkor az Itô–Doebelin-formula alkalmazásával kapjuk, hogy:

$$dY(t) = \left(\frac{\partial \Phi(t, S)}{\partial t} + \mu S(t) \frac{\partial \Phi(t, S)}{\partial S} + \frac{1}{2} \sigma^2 S^2(t) \frac{\partial^2 \Phi(t, S)}{\partial S^2} \right) dt + \sigma S(t) \frac{\partial \Phi(t, S)}{\partial S} dB(t). \quad (44)$$

Ebbe a parciális deriváltak értékét behelyettesítve kapjuk, hogy

$$dY(t) = \left(\mu - \frac{1}{2}\sigma^2 \right) dt + \sigma dB(t). \quad (45)$$

Integrálva ezt az egyenletet 0 és t között kapjuk, hogy:

$$Y(t) = Y_0 + \int_0^t \left(\mu - \frac{1}{2}\sigma^2 \right) ds + \int_0^t \sigma dB, \quad (46)$$

$$Y(t) = Y_0 + \left(\mu - \frac{1}{2}\sigma^2 \right) t + \sigma B(t). \quad (47)$$

Visszahelyettesítve $Y(t) = \ln(S(t))$, kapjuk az $S(t)$ folyamat explicit megoldását:

$$\ln(S(t)) = \ln(S(0)) + \left(\mu - \frac{1}{2}\sigma^2 \right) t + \sigma B(t), \quad (48)$$

$$S(t) = S(0) \exp \left(\left(\mu - \frac{1}{2}\sigma^2 \right) t + \sigma B(t) \right). \quad (49)$$

■

Mivel $\ln S(t)$ normális eloszlású, ezért a geometriai Brown.mozgás eloszlásáról a következő állítás tehető:

Állítás 3.3.3

[3] A geometriai Brown-mozgás $S(t)$ minden $t > 0$ esetén lognormális eloszlású.

Állítás 3.3.4

[3] Legyen $S(t)$ egy geometriai Brown-mozgás, amely kielégíti a következő SDE-t:

$$dS(t) = \mu S(t) dt + \sigma S(t) dB(t), \quad (50)$$

ahol μ és σ konstansok. Ekkor az $S(t)$ folyamat várható értéke a következőképpen írható fel:

$$E[S(t)] = S(0) \exp(\mu t). \quad (51)$$

Bizonyítás. Az $S(t)$ folyamat explicit megoldása a következőképpen írható fel:

$$S(t) = S(0) \exp \left(\left(\mu - \frac{1}{2}\sigma^2 \right) t + \sigma B(t) \right). \quad (52)$$

Mivel $B(t)$ normális eloszlású, ezért $\sigma B(t)$ is normális eloszlású, 0 várható értékkel és $\sigma^2 t$ szórásnégyzettel. Ezért a következő egyenlőség teljesül:

$$E[\exp(\sigma B(t))] = \exp \left(\frac{1}{2}\sigma^2 t \right). \quad (53)$$

Ezt az eredményt felhasználva kapjuk, hogy

$$E[S(t)] = S(0) \exp\left(\left(\mu - \frac{1}{2}\sigma^2\right)t\right) E[\exp(\sigma B(t))] = S(0) \exp(\mu t). \quad (54)$$

■

Állítás 3.3.5

[3] Legyen $S(t)$ egy geometriai Brown-mozgás, amely kielégíti a következő SDE-t:

$$dS(t) = \mu S(t) dt + \sigma S(t) dB(t), \quad (55)$$

ahol μ és σ konstansok. Ekkor az $S(t)$ folyamat varianciája a következőképpen írható fel:

$$\text{Var}[S(t)] = S^2(0) \exp(2\mu t) (\exp(\sigma^2 t) - 1). \quad (56)$$

Bizonyítás. A második momentum kiszámításához felhasználjuk a 42. egyenlet szerinti $S(t)$ explicit megoldást:

$$S^2(t) = S^2(0) \exp\left(2\left(\mu - \frac{1}{2}\sigma^2\right)t + 2\sigma B(t)\right). \quad (57)$$

Ekkor:

$$E[S^2(t)] = S^2(0) \exp\left(2\left(\mu - \frac{1}{2}\sigma^2\right)t\right) E[\exp(2\sigma B(t))]. \quad (58)$$

Mivel $2\sigma B(t)$ normális eloszlású, 0 várható értékkel és $4\sigma^2 t$ szórásnégyzettel, ezért

$$E[\exp(2\sigma B(t))] = \exp(2\sigma^2 t). \quad (59)$$

Ezt felhasználva kapjuk, hogy

$$\begin{aligned} E[S^2(t)] &= S^2(0) \exp\left(2\left(\mu - \frac{1}{2}\sigma^2\right)t\right) E[\exp(2\sigma B(t))] = \\ &= S^2(0) \exp(2\mu t + \sigma^2 t). \end{aligned} \quad (60)$$

A variancia definíciója szerint:

$$\begin{aligned} \text{Var}[S(t)] &= E[S^2(t)] - (E[S(t)])^2 = \\ &= S^2(0) \exp(2\mu t + \sigma^2 t) - (S(0) \exp(\mu t))^2 = \\ &= S^2(0) \exp(2\mu t) (\exp(\sigma^2 t) - 1). \end{aligned} \quad (61)$$

■

4 A gépi tanulás elméleti háttere

A gépi tanulás fontos szerepet játszik a tudomány, a gazdaság és a technológia számos területén. Például az orvostudományban a gépi tanulás segíthet a betegségek korai felismerésében és betegségekkel járó kockázatok azonosításában. A pénzügyi szektorban a gépi tanulás alkalmazható a kockázatkezelésben, a csalásfelderítésben és a kereskedési stratégiák optimalizálásában.

A gépi tanulás lehetővé teszi a nagy adathalmazok elemzését és a mintázatok felismerését ezért bűnügyi adatok elemzésére is használható, például a bűnözési mintázatok felismerésére és bűnügyi előrejelzések készítésére.

4.1 A gépi tanulás alapjai

A gépi tanulás algoritmusait három fő csoportba sorolhatjuk:

- Felügyelt tanulás: ahol a modell egy címkézett adathalmazon tanul, azaz minden bemeneti adathoz (X) tartozik egy kimeneti címke (y). A modell célja, egy olyan függvény megtanulása, amely képes egy új, ismeretlen bemeneti adat (X) alapján helyesen megjósolni a hozzá tartozó kimeneti címkét (y).
- Felügyelet nélküli tanulás: ahol a modell egy címkézetlen adathalmazon tanul, azaz csak bemeneti adatok (X) állnak rendelkezésre, de nincs hozzájuk tartozó kimeneti címke (y). A modell célja, hogy feltárja az adat szerkezetét, megtalálja a rejtett mintázatokat.
- Megerősítési tanulás: ahol a modell egy környezetben tanul, és a tanulási folyamat során visszajelzést kap a környezettől, amely alapján maximalizálni igyekszik egy célfüggvényt.

A szakdolgozat keretein belül elsősorban a felügyelt tanulás alapjaival foglalkozunk, különös tekintettel a regressziós problémákra, ahol a cél egy folytonos kimeneti érték előrejelzése.

A felügyelt tanulás esetén formálisan a következőképpen tekinthetünk az adatra:

$$D = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}. \quad (62)$$

ahol $x_i \in \mathbb{R}$ a bemeneti változókat tartalmazó vektor és $y_i \in \mathbb{R}$ a hozzá tartozó célváltozó értéke. A statisztikai tanulási modell általános alakja a következőképpen írható fel:

$$Y = f(X) + \varepsilon, \quad (63)$$

ahol f az ismeretlen függvény, amit becsülni szeretnénk, míg ε egy véletlen zaj, amely a modell hibáját reprezentálja és függelen a bemeneti változóktól. Továbbá feltételezzük, hogy $E[\varepsilon] = 0$.

Két fő kérdésre keresünk választ a gépi tanulás során:

- Egy új bemeneti adat (x) esetén mennyi lesz a célváltozó (y) értéke?
Ez a predikciós kérdés. Ebben az esetben a függvény úgynevezett „fekete doboz” modellként működik, ahol nem a függvény pontos alakja a lényeg, hanem a predikciós teljesítménye. Az előrejelzés pontossága két hibátényezőtől függ, egy csökkenthető hibától, amely a függvény becslésének pontosságából adódik, és egy nem csökkenthető hibától, amely egy felső korlátot szab az előrejelzés pontosságának.
- Hogyan befolyásolja a bemeneti változó (X) értéke a célváltozó (Y) értékét?
Ez a magyarázó kérdés. Vizsgálhatjuk, hogy a bemeneti változók közül melyik az néhány legfontosabb, amely a legnagyobb hatással van a célváltozó értékére. Ilyenkor a függvény pontos alakja is fontos, nem viselkedhet „fekete doboz” modellként.

A változóknak két fő típusát különböztetjük meg, lehetnek kvalitatív (minőségi) vagy kvantitatív (mennyiségi) változók. A kvalitatív változók kategóriákba, osztályokba sorolhatóak, például a nem, a szín vagy a márka. Ezzel szemben a kvantitatív változók számszerű értékeket vesznek fel, ilyen például a magasság, a súly vagy az ár. A célváltozó típusa alapján a gépi tanulási problémák lehetnek klasszifikációs vagy regressziós problémák. Klasszifikáció esetén a célváltozó kvalitatív, és a modell célja, hogy egy adott bemeneti adat alapján megállapítsa a hozzá tartozó kategóriát. Regresszió esetén a célváltozó kvantitatív, és a modell célja, hogy egy adott bemeneti adat alapján megjósolja a hozzá tartozó számértéket. A határvonal a klasszifikációs és regressziós módszerek között azonban nem mindig éles. A legkisebb négyzetek módszerét mennyiségi meghatározásra használjuk, a logisztikus regressziót pedig kvalitatív meghatározásra, de a KNN (K-Nearest Neighbors) algoritmust, a döntési fákat mind a két probléma esetén használhatjuk.


Mindkét probléma esetén fontos vizsgálni a modell teljesítményét, hibáját. A várható hiba egy x_0 pontban a következőképpen írható fel:

$$\begin{aligned}
 E\left[\left(y_0 - \hat{f}(x_0)\right)^2\right] &= E\left[\left(f(x_0) + \varepsilon - \hat{f}(x_0)\right)^2\right] = \\
 E\left[\left(f(x_0) - \hat{f}(x_0)\right)^2 + \varepsilon^2 + 2\left(f(x_0) - \hat{f}(x_0)\right)\varepsilon\right] &= \\
 E\left[\left(f(x_0) - \hat{f}(x_0)\right)^2\right] + E[\varepsilon^2] + 2E\left[\left(f(x_0) - \hat{f}(x_0)\right)\varepsilon\right] &= \quad (64) \\
 E\left[\left(f(x_0) - \hat{f}(x_0)\right)^2\right] + \text{Var}[\varepsilon] + 2E[\varepsilon]E\left[f(x_0) - \hat{f}(x_0)\right] &= \\
 E\left[\left(f(x_0) - E[\hat{f}(x_0)] + E[\hat{f}(x_0)] - \hat{f}(x_0)\right)^2\right] + \text{Var}[\varepsilon] &= \\
 E\left[\left(f(x_0) - E[\hat{f}(x_0)]\right)^2\right] + E\left[\left(E[\hat{f}(x_0)] - \hat{f}(x_0)\right)^2\right] + \text{Var}[\varepsilon] &= \\
 \left(E[\hat{f}(x_0)] - f(x_0)\right)^2 + \text{Var}[\hat{f}(x_0)] + \text{Var}[\varepsilon] &
 \end{aligned}$$

ahol $\hat{f}(x_0)$ a modell által adott előrejelzés, $f(x_0)$ a valódi értéke, és ε a nem csökkenthető hiba. Tehát a várható hiba három összetevőből épül fel: a becslés varianciájából

$(\text{Var}[\hat{f}(x_0)])$, a becslés torzításának négyzetéből $((E[\hat{f}(x_0)] - f(x_0))^2$ és a hibatag varianciájából $(\text{Var}[\varepsilon])$.

Ahhoz, hogy a várható hiba értékét minimalizáljuk, olyan módszert kell választanunk, amely egyszerre biztosít alacsony variációt és alacsony torzítást. A variancia azt mutatja meg, hogy a modell előrejelzése mennyire érzékeny a tanító adathalmaz változásaira. Általánosságban elmondható, hogy a komplexebb modellek nagyobb varianciával rendelkeznek. A torzítás pedig abból fakad, hogy a modell nem képes pontosan megragadni a valódi függvény alakját, ez akkor fordulhat elő ha egy bonyolult problémát egy egyszerűbb modellel közelítünk. Például ha a változók közötti kapcsolat erősen nemlineáris, de egy lineáris modellt használunk, akkor a modell torzított lesz. Általában a kevésbé komplex modellek nagyobb torzítással rendelkeznek. Tehát láthatjuk, hogy a modell komplexitásának növelése csökkenti a torzítást, de növeli a variációt. Ez az úgynevezett torzítás-variancia kompromisszum (bias-variance tradeoff).



1. Ábra: Torzítás-variancia kompromisszum illusztrációja

Az 1. Ábra alapján látható, hogy a modell komplexitásának növelésével a torzítás csökken, de a variancia nő. Az ábrán is látható, hogy kezdetben a modell komplexitásának növelésével a torzítás gyorsabban csökken, mint ahogy a variancia nő, így a teljes hiba csökken. Azonban egy bizonyos pont után a variancia növekedése gyorsabb lesz, mint a torzítás csökkenése, így a teljes hiba növekedni kezd. Az optimális pont ott van, ahol a teljes hiba minimális. Valós helyzetben, mivel a valódi függvény nem ismert, nem tudjuk explicit módon kiszámolni a torzítást és a variációt, ezért gyakran keresztvalidációs módszereket alkalmazunk a modell teljesítményének értékelésére.


Ahhoz, hogy kiértékeljük egy modell teljesítményét, szükségünk van egy mérőszámra, amely megmutatja, hogy a modell mennyire jól teljesít a tanító adathalmazon vagy egy

új, ismeretlen adathalmazon. A regressziós problémák esetén a leggyakrabban használt mérőszámok közé tartozik az átlagos négyzetes hiba (MSE):

$$\text{MSE} = \sum_{i=1}^n \frac{(y_i - \hat{f}(x_i))^2}{n} \quad (65)$$

ahol y_i a valódi érték, $\hat{f}(x_i)$ a modell által adott előrejelzés, és n a minta mérete. Minél kisebb az MSE értéke, annál jobb a modell teljesítménye. Ezt az értéket a tanító adatra tudjuk kiszámolni, de a modell választásánál az új, ismeretlen adatokon való teljesítmény a fontosabb. Mivel a tanító adaton való teljesítmény nem feltétlenül tükrözi az új adatokon való teljesítményt, nem választhatjuk a legkisebb MSE-vel rendelkező módszert. Sőt, ha a tanító adaton túl jól teljesít egy módszer, akkor fennáll a veszélye annak, hogy a modell túltanult (overfitting), vagyis a modell nemcsak a valódi mintázatot tanulta meg, hanem a tanító adathalmaz zaját is, így az új adatokon való teljesítménye gyenge lesz.

Tehát ebben az esetben is fennáll a torzítás-variancia kompromisszum esetéhez hasonló összefüggés: a modell komplexitásának növelésével a tanító adaton az MSE monoton csökken, azonban a teszt adaton az MSE egy bizonyos pont után növekedni kezd, mivel a modell túltanul. (2. Ábra)




2. Ábra: Túllillesztés illusztrációja

A gyakorlatban a tanító adaton az MSE értékét meg tudjuk határozni, de a teszt adaton az MSE értékét nem, mivel a teszt adaton a valódi értékek nem ismertek. A minimumpont meghatározására a gyakorlatban az egyik legelterjedtebb módszer a keresztvalidáció, amely során a tanító adatot több részre osztjuk, és a modell teljesítményét ezekre a részekre értékeljük. Ez lehetővé teszi, hogy becslést kapjunk a modell új adatokon való teljesítményére, és segítséget nyújt a megfelelő modell komplexitásának kiválasztásában.

4.2 Döntési fák

A fa-alapú módszerek egy jelentős és széles körben használt osztálya a gépi tanulási algoritmusoknak. Ezek a módszerek könnyen értelmezhető modelleket hoznak létre, amelyek jól teljesítenek mind klasszifikációs, mind regressziós problémák esetén. Ezek a módszerek a bementeti változók terét egyszerű, jellemzően téglalap alakú régiókra osztják fel, rétegzik azokat. Ha egy új megfigyelést szeretnénk osztályozni vagy a hozzá tartozó értéket előrejelezni, akkor a modell megvizsgálja, hogy a megfigyelés melyik régióba esik, és a régióba eső tanuló adatok között előforduló leggyakoribb osztályt vagy a régióba eső tanuló adatok átlagát használja a predikcióhoz. A modell struktúrája:


- Gyökércsomópont: A legfelső szint, ami a teljes adatot reprezentálja.
- Belső csomópontok: Egy-egy bemeneti változó (feature) alapján végzett döntést reprezentálnak, amelyek az adatot két vagy több részre osztják.
- Élek: A tesztek eredményét reprezentálják, amelyek a bemeneti változó értékétől függően vezetnek a következő csomóponthoz.
- Levélcsomópontok: Az osztályokat vagy a regressziós értékeket reprezentálják, amelyek a modell végső döntését adják meg.



3. Ábra: Döntési fa példa

A 3. Ábra egy döntési fa példáját mutatja be: lakások árát becsüli meg különböző jellemzők alapján. A döntési fa struktúrája a következő:

- A gyökércsomópontban az elhelyezkedés szerepel, ez a döntési folyamat kiindulópontja. A modell a tanítás során ezt a változót találta a legfontosabbnak, ez bontja fel legjobban az adatokat.
- Élek: A lehetséges állapotokat jelölik.
- Belső csomópontok: Ha az „elhelyezkedés” értéke alapján nem tudunk dönteni, további változókat kell vizsgálnunk. Például, ha a lakás a belvárosban helyezkedik el, akkor a következő változó, amit megvizsgálunk, a „Méret”.
- Levélcsomópontok: Ezek a végső döntéseket jelölik, például ha a lakás a belvárosban helyezkedik el és a mérete „Nagy”, akkor a modell szerint a lakás ára 95 millió forint.



4. Ábra: A bemeneti tér régiókra bontása a regressziós döntési fa szerint.

A 4. Ábra a regressziós döntési fa által létrehozott régiókat szemlélteti. Minden színezett tartomány egy levélcsomópontnak felel meg, és az ott szereplő szám az adott régióhoz rendelt becült célérték.

4.2.1 A döntési fák tanítása

A fák építése mind a klasszifikációs, mind a regressziós problémák esetében rekurzív módon történik. A fák építése „mohó” módon történik, felülről lefelé haladva választjuk ki a legjobb vágást, amely az adott pillanatban a legjobban szétválasztja az adatokat. A legjobb vágás kiválasztásához különböző mérőszámokat használunk, ezek a következők lehetnek:

- *Gini-index*: Klasszifikációs problémák esetén használjuk. Azt méri, hogy mekkora eséllyel osztályoznánk félre egy véletlenszerűen kiválasztott elemet, ha a részhalmaz eloszlása alapján osztályoznánk. Minél kisebb a Gini-index, annál tisztább a részhalmaz.

$$G(m) = \sum_{k=1}^K p_{mk}(1 - p_{mk}) = 1 - \sum_{k=1}^K p_{mk}^2, \quad (66)$$

ahol p_{mk} a k -edik osztályba tartozó elemek aránya a m -edik részhalmazban.

- *Entrópia*: Szintén klasszifikációs problémák esetén használjuk. Azt méri, hogy mekkora információt nyerünk egy adott vágással. Minél nagyobb az entrópia csökkenése, annál jobb a vágás.

$$H(m) = - \sum_{k=1}^K p_{mk} \log(p_{mk}), \quad (67)$$

ahol p_{mk} a k -edik osztályba tartozó elemek aránya a m -edik részhalmazban.

- *Négyzetes hiba*: Regressziós problémák esetén használjuk. Azt mérjük, hogy a vágás utáni részhalmazban mekkora az a tényleges válaszértékek és a részhalmaz átlaga közötti eltérések négyzetösszege. Minél kisebb ez az érték, annál jobb a vágás.

$$\text{MSE}(m) = \frac{1}{n_m} \sum_{i=1}^m (y_i - \hat{y}_m)^2, \quad (68)$$

ahol n_m a m -edik részhalmazban lévő elemek száma, y_i a tényleges válaszérték, és $\hat{y}_m$ a részhalmaz átlaga.

A döntési fák esetén ügyelni kell arra, hogy a fa ne nőjön túl mélyre, mert ez túlannuláshoz vezethet. Erre megoldás lehet a fa vágása (pruning). Kétfő vágási módszert alkalmaznak a gyakorlatban:

- *Előmetzés (prepruning)*: A fa építése során már a vágás kiválasztásánál figyelembe vesszük a vágás utáni részhalmazok méretét, és csak akkor hajtjuk végre a vágást, ha a részhalmazok mérete egy bizonyos küszöbérték fölött van.
- *Utólagos metzés (postpruning)*: Először egy teljes fát építünk, majd utólagosan, alulról felfelé haladva metszük vissza a fát.


4.3 Ensemble módszerek

Az ensemble módszerek használata során több gyenge modellt kombinálunk egy erősebb modell létrehozásához. Két fő típusát különböztetjük meg:

- *Bagging*: A bagging során a tanító adatból bootstrap (visszatevéses mintavétellel) több új adathalmazt hozunk létre, majd mindegyiket tanítunk egy gyenge modellt (például egy metszés nélküli döntési fát). Majd egyesítjük a modellek előrejelzéseit, klasszifikáció esetén többségi szavazással, regresszió esetén pedig átlagolással. Mivel egy mély fának alacsony a torzítása, de magas a varianciája, ezért a bagging segítségével csökkenthetjük a varianciát anélkül, hogy a torzítást növelnénk.
- *Boosting*: Míg a bagging egymástól függetlenül, párhuzamosan épít fákat, addig a boosting során szekvenciálisan építjük a fákat. Minden új fa a korábbi fák információit használja fel és a korábbi fák által helytelenül osztályozott vagy előrejelzett megfigyelésekre helyezi a hangsúlyt, azaz ezeket a megfigyeléseket nagyobb súllyal veszi figyelembe a tanítás során.

4.3.1 Random Forest

Ensemble módszer, amely a bagging elvén alapul és nagyszámú, egymástól független döntési fát épít. A módszer regressziós és klasszifikációs problémák esetén is használható. A Random Forest során minden egyes fa építésekor a változók egy véletlenszerű részhalmazát választjuk ki, és csak ezek közül választjuk ki a legjobb vágást. (5. Ábra)



5. Ábra: Random Forest módszer vázlatos ábrája

Minden fát a lehető legnagyobbra növesztünk, azaz metszés nélkül építjük. A bagging esetében előfordulhat, hogyha van egy nagyon erős változó, akkor a tanított fák közül sok ezt az erős változót fogja választani a legelső vágáshoz, így a fák hasonlóak lesznek egymáshoz, nem lesznek függetlenek, így a variancia csökkentése sem lesz olyan hatékony. A Random Forest esetében viszont csak csak egy véletlen m elemű részhalmazzal választunk a p változóból, így a vágások $\frac{p-m}{p}$ arányában a legerősebb változó nem lesz kiválasztva, így a fák nagyobb mértékben lesznek különbözőek és függetlenek, így a variancia csökkentése is hatékonyabb lesz. A modell hiperparamétereinek közé tartozik a minimális csomópontok száma és a változókból kiválasztott részhalmaz mérete. Az m paraméter értékét gyakran a gyakorlatban $\sqrt{p}$ -re (klasszifikációs problémák esetén) vagy $\frac{p}{3}$ -ra (regressziós problémák esetén) állítják be, de ez a probléma jellegétől függően változhat. A minimális csomópontok számát klasszifikációs problémák esetén gyakran 1-re, regressziós problémák esetén pedig 5-re állítják be, de ez is a probléma jellegétől függően változhat. A Random Forest módszer nagy előnye, hogy nem érzékeny a fák számára, így általában a nagy számú fa építése nem vezet túltanuláshoz, ahogy egyre több fát adunk a modellhez, a hibaartás csökken, és egy bizonyos pont után stabilizálódik.

Random Forest esetén, mivel minden fa egy bootstrap mintán tanul, a tanító adathalmaz körülbelül egyharmada minden fa esetében kimarad a tanításból, ezeket a kimaradt pontokat nevezzük out-of-bag (OOB) pontoknak. Ezt felhasználva a modell teljesítményét is értékelhetjük, anélkül, hogy külön teszt adathalmazt kellene fenntartanunk. A hibabecsléshez minden egyes megfigyelés esetén kiszámoljuk a fák előrejelzését, amelyek nem tanultak az adott megfigyelésen (azaz azok a fák, amelyeknél az adott megfigyelés OOB pont), majd ezeket az előrejelzéseket átlagoljuk (regresszió esetén) vagy többségi szavazással egyesítjük (klasszifikáció esetén), és összehasonlítjuk a valódi értékekkel. A hagyományos döntési fákkal szemben a Random Forest kevésbé átlátható, de többféle mutatóval is értékelhetjük a változók fontosságát, például a csomópontok tisztaságának növekedése alapján, vagy az OOB hibabecslés alapján, amely megmutatja, hogy egy adott változó kizárása hogyan befolyásolja a modell teljesítményét.

4.4 Idősorok elemzése

Idősornak tekinthetünk minden olyan adatot, amelyet időpontokhoz rendelünk és a megfigyelések között időbeli függés van, például a bűnügyi statisztikák is jellemzően idősorok. Az idősorok elemzése olyan módszereket foglal magában, amelyekkel az adatokból mintázatok, trendeket lehet felismerni, valamint előrejelzéseket készíthetünk. Az idősorok elemzésének két fő célja van: a múltbeli adatok megértése és a jövőbeli értékek előrejelzése. Az idősorok egyik legfontosabb jellemzője, hogy az egymást követő megfigyelések nem függetlenek. Ez a függőség lehet rövid távú, amikor a közelmúlt megfigyelései befolyásolják a jövőbeli értékeket, vagy hosszútávú, amikor trendek vagy szezonális mintázatok figyelhetők meg az adatokban. Akkor beszélhetünk trendről, ha az adatokban hosszú távú növekedés vagy csökkenés figyelhető meg, míg szezonális mintázat esetében az adatsort valamilyen ismétlődő ciklus jellemzi, például éves, havi

vagy heti szinten. Ezek alapján az idősorok több, egymástól független komponensből állhatnak, tehát egy Y_t idősor felírható a következőképpen:

$$Y_t = f(S_t, T_t, \varepsilon_t) \quad (69)$$

ahol S_t a szezonális komponens, T_t a trendkomponens, és ε_t a maradéktag.

4.4.1 Alapfogalmak

Definíció 4.4.1.1

Egy idősor kovarianciája a következőképpen definiálható:

$$\text{Cov}(X_t, X_{t+k}) = E[(X_t - E[X_t])(X_{t+k} - E[X_{t+k}])], \quad (70)$$

ahol X_t az idősor t -edik megfigyelése, $E[X_t]$ az idősor t -edik megfigyelésének várható értéke, és k a késleltetés (lag) értéke.

Definíció 4.4.1.2

Egy idősor autokovarianciája a következőképpen definiálható: $\gamma(h) = \text{Cov}(X_t, X_{t+h})$, ahol X_t az idősor t -edik megfigyelése, és h a késleltetés (lag) értéke.

Definíció 4.4.1.3

Egy idősor autokorrelációja a következőképpen definiálható: $\rho(h) = \frac{\gamma(h)}{\gamma(0)}$,

Definíció 4.4.1.4

Egy idősor gyengén stacionáris, ha teljesül az alábbi három feltétel:

1. Az idősor várható értéke időben állandó, azaz $E[X_t] = \mu$ minden t -re.
2. $E[X_t^2] < \infty$ minden t -re.
3. Két megfigyelés közötti kovariancia csak a köztük lévő időkülönbségtől (h) függ és nem a konkrét t időponttól, azaz $\text{Cov}(X_t, X_{t+h}) = \gamma(h)$.

Definíció 4.4.1.5

Egy idősor erősen stacionáris, ha minden h és minden $t_1, t_2, \dots, t_n$ esetén teljesül, hogy $(X_{t_1}, X_{t_2}, \dots, X_{t_n})$ és $(X_{t_1+h}, X_{t_2+h}, \dots, X_{t_n+h})$ azonos eloszlásúak.

A (gyenge) stacionaritás fontos fogalom az idősorelemzésben, mivel a legtöbb klasszikus idősorelemzési módszer feltételezi, hogy az idősor (gyengén)stacionáris. A stacionaritás azt jelenti, hogy az idősor statisztikai tulajdonságai időben állandóak, így a múltbeli adatok alapján megbízhatóan előrejelezhetjük a jövőbeli értékeket.

4.4.2 Klasszikus idősorelemzési módszerek

A klasszikus idősorelemzési módszereket két nagy csoportra oszthatjuk: determinisztikus és sztochasztikus módszerekre.

4.4.2.1 Determinisztikus és simítási módszerek

Ezek a módszerek az adatokban lévő véltlen ingadozás kiszűrésére, a mögöttes trendek és szezonális mintázatok kiemelésére szolgálnak. Ezek a módszerek olyan rekurzív becslésnek tekinthetők, amely során a múltbeli megfigyelések egy súlyozott kombinációját használjuk a jövőbeli érték becslésére. A súlyok meghatározása alapján különböző simítási módszereket különböztetünk meg:

- **Egyszerű exponenciális simítás:** Olyan idősorok esetén használjuk, amelyekben nincs trend vagy szezonális mintázat. A módszer lényege, hogy a jövőbeli értéket a múltbeli értékek súlyozott átlagaként becsljük, ahol a súlyok exponenciálisan csökkennek a múltbeli értékekre vonatkozóan. Az alapegyenlete a következőképpen írható fel:

$$\hat{Y}_{t+1} = \alpha Y_t + (1 - \alpha) \hat{Y}_t, \quad (71)$$

ahol α a simítási paraméter, amely értéke 0 és 1 között van, Y_t az idősor t -edik megfigyelése, és $\hat{Y}_t$ a t -edik időpontban becsült érték. Ebből megmutatható:

$$\hat{Y}_{t+1} = \alpha \sum_{h=0}^{\infty} (1 - \alpha)^h Y_{t-h} \quad (72)$$

- **Holt-Winters módszer:** Olyan idősorok esetén használjuk, amelyekben trend és/vagy szezonális mintázat is megfigyelhető. A módszer három egyenletből áll, amelyek a szint, a trend és a szezonális komponens becslésére szolgálnak. A három egyenlet a következőképpen írható fel:

$$\ell_t = \alpha(Y_t - s_{t-m}) + (1 - \alpha)(\ell_{t-1} + b_{t-1}), \quad (73)$$

$$b_t = \beta(\ell_t - \ell_{t-1}) + (1 - \beta)b_{t-1}, \quad (74)$$

$$s_t = \gamma(Y_t - \ell_t) + (1 - \gamma)s_{t-m}, \quad (75)$$

ahol ℓ_t a szint becslése, b_t a trend becslése, s_t a szezonális komponens becslése, α , β és γ a simítási paraméterek, amelyek értéke 0 és 1 között van, Y_t az idősor t -edik megfigyelése, és m a szezon hossza. Ekkor az előrejelzés az $t + h$ időpontban a következőképpen számítható:

$$\hat{Y}_{t+h} = \ell_t + hb_t + s_{t+h-m}, \quad (76)$$

ahol h a előrejelzés időtávja.

4.4.2.2 Sztochasztikus módszerek

A klasszikus sztochasztikus megközelítés alapját a Box-Jenkins módszertan képezi, amely az autoregresszív és mozgóátlag modellekre épül. Ezek a modellek nemcsak a determinista komponenseket, hanem a véletlen ingadozásokat is modellezzik. Ezek a módszerek feltételezik, hogy az idősor stacionárius, így gyakran szükséges az idősor differenciálása a stacionaritás eléréséhez.

- **Autoregresszív (AR) modellek:** Az AR modellekbe a jövőbeli értékek a múltbeli értékek lineáris kombinációjaként áll elő:

$$Y_t = c + \sum_{i=1}^p \varphi_i Y_{t-i} + \varepsilon_t, \quad (77)$$

ahol Y_t az idősor t -edik megfigyelése, c egy konstans, φ_i az autoregresszív paraméterek, p az autoregresszív rend, és ε_t a hiba.

- **Mozgóátlag (MA) modellek:** Az MA modellek, szemben a determinisztikus mozgóátlag modellekkel, azt feltételezik, hogy a jövőbeli értékek nem a múltbeli tényleges értékektől, hanem a múltbeli előrejelzések hibáitól függenek:

$$Y_t = c + \sum_{i=1}^q \theta_i \varepsilon_{t-i} + \varepsilon_t, \quad (78)$$

ahol Y_t az idősor t -edik megfigyelése, c egy konstans, θ_i a mozgóátlag paraméterek, q a mozgóátlag rend, és ε_t a hiba.

- **ARMA és ARIMA modellek:** Ezek a modellek az AR és MA modellek kombinációi, az ARMA(p,q) modellt stacionárius idősorokra alkalmazzuk, míg az ARIMA(p,d,q) modell alkalmas nem stacionárius idősorokra is, ebben az esetben differenciálás segítségével érjük el a stacionaritást. A ARMA(p,q) modell a következőképpen írható fel:

$$Y_t = c + \sum_{i=1}^p \varphi_i Y_{t-i} + \sum_{j=1}^q \theta_j \varepsilon_{t-j} + \varepsilon_t, \quad (79)$$

ahol Y_t az idősor t -edik megfigyelése, c egy konstans, φ_i az autoregresszív paraméterek, θ_j a mozgóátlag paraméterek, p az autoregresszív rend, q a mozgóátlag rend, és ε_t a hiba. Az ARIMA modell esetén alkalmazott differenciálás:

$$\Delta Y_t = Y_t - Y_{t-1}, \quad (80)$$

Majd ezekre a differenciált értékekre alkalmazzuk az ARMA modellt, tehát d -edik rendű differenciálás esetén:

$$\Delta^d Y_t = c + \sum_{i=1}^p \varphi_i \Delta^d Y_{t-i} + \sum_{j=1}^q \theta_j \varepsilon_{t-j} + \varepsilon_t, \quad (81)$$

ahol $\Delta^d Y_t$ a d -edik rendű differenciált idősor t -edik megfigyelése.

A szezonális modellezésére a SARIMA modellt használjuk, amely az ARIMA modell kiterjesztése, és a szezonális komponenseket is figyelembe veszi. Amennyiben más, külső tényezőket is szeretnénk figyelembe venni az előrejezés során, akkor az ARIMAX modellt használhatjuk, azonban ez csak akkor alkalmazható, ha lineáris kapcsolat van a külső tényezők és az idősor között, ami a gyakorlatban sokszor nem teljesül.

4.4.3 Gépi tanulási és mélytanulási módszerek idősorok elemzésére

Ahogy azt korábban láttuk a klasszikus idősor elemzési módszerek sok előfeltételezéssel élnek az adatokra vonatkozóan, például a stacionaritás feltételezése, valamint a lineáris kapcsolat feltételezése a külső tényezők és az idősor között. Ezek a feltételezések gyakran nem teljesülnek a valós adatok esetében, így ezek a módszerek nem mindig nyújtanak jó előrejelzéseket. Ezzel szemben a gépi tanulási (Machine Learning, ML) és mély tanulási (Deep Learning, DL) módszerek rugalmasabbak, képesek komplex, nemlineáris összefüggések modellezésére is. A gépi tanulási módszerek alkalmazásához az idősorokat általában felügyelt tanítási problémává alakítjuk, ahol a célváltozó a jövőbeli érték, a bemeneti változók pedig a múltbeli értékek és a külső tényezők:

$$Y_t = f(X_t) + \varepsilon_t, \quad (82)$$

ahol Y_t a jövőbeli érték, X_t a bemeneti változók, f a modell, és ε_t a hiba. A gépi tanulási módszerek (például a döntési fák, Random Forest, Gradient Boosting, Support Vector Machines) általában nem tudják értelmezni az idősorok időbeli függését, így új változókat kell bevezetni, amelyek kifejezik a múltbeli értékek hatását a jövőbeli értékekre, ilyen változók lehetnek például:

- *Késleltetett (Lag) változók*: Ezek a múltbeli értékek, például $Y_{t-1}, Y_{t-2}, \dots, Y_{t-p}$, ahol p a késleltetés rendje.
- *Mozgóátlag változók*: Ezek a múltbeli értékek átlagai, például $MA_p = \frac{Y_{t-1} + Y_{t-2} + \dots + Y_{t-p}}{p}$, ahol p a mozgóátlag rendje.

A gépi tanulási módszerek nagy előnye a klasszikus módszerekkel szemben, hogy képesek a nemlineáris összefüggések modellezésére, illetve képesek a változók közötti kölcsönhatások figyelembevételére is. A gépi tanulási módszerekkel szemben a mélytanulási módszerek képesek megragadni az adatok időbeliségét is, például a Recurrent Neural Networks (RNN) és a Long Short-Term Memory (LSTM) hálózatok.

- *Recurrent Neural Networks (RNN)*: Olyan neurális hálózatok, amelyek képesek az adatok időbeli függését modellezni egy belső, rekurzív állapot (h_t) segítségével:

$$h_t = \sigma(W_h h_{t-1} + W_x X_t + b), \quad (83)$$

ahol h_t a rekurzív állapot a t -edik időpontban, W_h és W_x a súlyok, b a torzítás (bias), és σ egy aktivációs függvény.

- *Long Short-Term Memory (LSTM) hálózatok*: Olyan RNN-ek, amelyek képesek hosszú távú függőségek modellezésére is, egy speciális cella struktúrával, amely

három kaput tartalmaz: a bemeneti kaput , a kimeneti kaput és a felejtési kaput. Ezek a kapuk szabályozzák az információ áramlását a cellában, így lehetővé téve a hosszú távú függőségek megragadását is.

$$i_t = \sigma(W_i[h_{t-1}, X_t] + b_i), \quad (84)$$

$$o_t = \sigma(W_o[h_{t-1}, X_t] + b_o), \quad (85)$$

$$f_t = \sigma(W_f[h_{t-1}, X_t] + b_f), \quad (86)$$

Bár a mélytanulási módszerek rendelkeznek a legnagyobb kapacitással, gyakran nagy mennyiségű adatot és számítási erőforrást igényelnek a tanításhoz és black-box jellegük miatt az eredmények értelmezése is nehéz lehet. Ezzel szemben a gépi tanulási módszerek gyakran jó kompromisszumot jelentenek, nem igénylik a klasszikus módszerek szigorú előfeltételezéseit és alkalmazásukhoz nem szükséges annyi adat és számítási erőforrás, mint a mélytanulási módszerek esetén, valamint az eredmények értelmezését is megkönnyítik a mélytanulási módszerekkel szemben, például a döntési fák esetén a változók fontosságának értékelésével.

5 Gyakorlati alkalmazások

Az előző fejezetekben bemutatott eszközök, mint a sztochasztikus differenciálegyenletek, a különböző ML és DL modellek lehetőséget adnak arra, hogy elemezzünk összetett, időben változó rendszereket és előrejelzéseket készítsünk. Ebben a fejezetben ezen módszerek gyakorlati alkalmazását vizsgálom meg bűnözési adatokon, elemezem a bűnözés időbeli mintázatát, a bűnözést befolyásoló demográfiai tényezőket, valamint a bűnözés előrejelzésére szolgáló modellek teljesítményét.

A bűnügyi statisztikák elemzése társadalmi és gazdasági szempontból is fontos, segíthet megérteni a bűnözést kiváltó okokat, és hozzájárulhat a hatékonyabb bűnmegelőzési stratégiák kidolgozásához. A bűncselekmények időbeli alakulásának vizsgálata lehetőséget ad a trendek, a szezonális és a hirtelen változások azonosítására, míg a demográfiai tényezők elemzése segíthet megérteni, hogy mely csoportok vannak nagyobb kockázatnak kitéve.

Elsőként korábban bemutatott geometriai Brown-mozgás segítségével modellezem a bűnözés időbeli alakulását, majd Random Forest modellt fogok alkalmazni a bűnözés előrejelzésére és a legfontosabb tényezők azonosítására.


5.1 Adatok bemutatása

A vizsgálathoz a Chicago városában elkövetett bűncselekmények adatait használok, amelyeket a Chicago Police Department tett közzé. Az adatbázis tartalmazza a bűncselekmények típusát, helyét, időpontját és egyéb jellemzőit. Az adatok a 2001-től 2025-ig terjedő időszakot ölelik fel, és több mint 6 millió bűncselekményt tartalmaznak. Minden egyes rekord egy bűncselekményt reprezentál és a legfontosabb jellemzői a következők:

- *ID*: Egyedi azonosító minden bűncselekményhez.
- *Dátum*: A bűncselekmény elkövetésének időpontja.
- *Primary Type*: A bűncselekmény típusa (pl. lopás, testi sértés, stb.).
- *Description*: Részletes leírás a bűncselekményről.
- *Arrest*: Jelzi, hogy történt-e letartóztatás a bűncselekmény kapcsán.
- *District*: A város melyik rendőri körzetében történt a bűncselekmény.
- *Community Area*: A város melyik területén történt a bűncselekmény.
- *Latitude* és *Longitude*: A bűncselekmény helyének földrajzi koordinátái.


ID	Date	Primary Type	Description	Location	Arrest
13974502	09/21/2025	CRIMINAL DAMAGE	TO PROPERTY	RESIDENCE - GARAGE	False
13975969	09/21/2025	THEFT	FROM MOTOR VEHICLE	RESIDENCE	False
13974043	09/21/2025	THEFT	OVER \$500	SIDEWALK	False
13976000	09/21/2025	DECEPTIVE PRACTICE	FINANCIAL IDENTITY THEFT	RESIDENCE	False
13976430	09/21/2025	CRIMINAL DAMAGE	TO VEHICLE	HOTEL / MOTEL	False

1. Táblázat: Chicago bűnügyi adatok (minta)




6. Ábra: Chicago bűnesemények típusai és gyakorisága

A 7. Ábra a Chicagóban elkövetett bűnesetek típusait és azok gyakoriságát mutatja be 2001 és 2025 között. A leggyakoribb bűncselekménytípusok közé tartozik a lopás (THEFT, több mint 1,7 millió eset), a testi sértés (BATTERY, több mint 1,5 millió eset) illetve fontos lehet még kiemelni a kábítószerrel kapcsolatos bűncselekmények magasabb számát is (NARCOTICS, több mint 700 ezer eset). Ezek az adatok fontosak lehetnek a bűnmegelőzési stratégiák kialakításához és a későbbi elemzések során vizsgálhatjuk azt is, hogy ezek a bűncselekménytípusok hogyan változnak időben és térben, valamint milyen demográfiai tényezők befolyásolják előfordulásukat.



7. Ábra: Chicago bűnözési sűrűségének térképe


A 8. Ábra a rendőri körzeteket mutatja Chicagóban a bűnözési sűrűség alapján színezve. Azonosíthatóak azok a körzetek, amik a leginkább érintettek, ezek a térképen a sötétebb színnel vannak jelölve.



8. Ábra: Chicago bűnözési sűrűségének térképe


A 9. Ábra a bűncselekmények eloszlását mutatja a hét napjaira lebontva. Az ábráról kivehető a napszaki és heti mintázat, például, hogy a legtöbb bűncselekményt a hét végén éjjel körül követik el, illetve a hétköznapokon is megfigyelhető egy kisebb csúcs a

délutáni órákban. Ezek az információk fontosak lehetnek a rendőri erőforrások hatékonyabb elosztásához.




9. Ábra: Leggyakoribb bűncselekménytípusok és letartóztatási arányuk

A 10. Ábra a leggyakoribb bűncselekménytípusokat mutatja be a letartóztatási arányukkal együtt. Az ábra alapján látható, hogy a leggyakoribb bűncselekménytípusok közül a lopás (THEFT) és a testi sértés (BATTERY) esetében a letartóztatási arány viszonylag alacsony, míg a kábítószerrel kapcsolatos bűncselekmények (NARCOTICS) esetében kiugróan magas.



10. Ábra: Bűncselekmények havi alakulása



11. Ábra: Bűncselekmények havi alakulása (összesítve)

A 11. Ábra és a 12. Ábra a bűncselekmények havi alakulását mutatja be. A 11. Ábra alapján látható a bűnözés éven belüli szezonális mintázata, jellemzően a nyári hónapokban a legmagasabb a bűncselekmények száma, míg a téli hónapokban egy jelentős csökkenés figyelhető meg. Bár a bűnözés csökkenő trendet mutat a 2001 és 2025 közötti időszakban, a szezonális mintázat továbbra is megfigyelhető. Ezeket a megfigyeléseket számszerűsíti a 12. Ábra, itt is megfigyelhető, hogy valóban a nyári hónapokban a legmagasabb a bűncselekmények száma, míg ez a szám a téli hónapokra csökken.

5.2 Bűnözés időbeli modellezése geometriai Brown-mozgással

Ebben a fejezetben a bűnözés időbeli alakulását modellezem geometriai Brown-mozgással. A felépített modell alapját Julia Calatayud és társai ([4]) 2023-ban megjelent tanulmánya adja, amelyben a bűnözés időbeli alakulását sztochasztikus differenciálegyenletekkel modellezték. A szerzők a spanyolországi Valencia város bűnözési adatait vizsgálták geometriai Brown-mozgás segítségével, de az általuk javasolt módszertan alkalmazható más városok, így Chicago bűnözési adatainak modellezésére is. A következőkben bemutatom hogyan készítettem elő az adatokat és hogyan határoztam meg a geometriai Brown-mozgás paramétereit, majd a modell segítségével előrejelzéseket készítek a bűnözés alakulására vonatkozóan.

5.2.1 Adatok előkészítése

Elsőként, hogy a modellt alkalmazni tudjam, a nyers adatokat megfelelő térbeli és időbeli felbontásra kellett hozni. Ahogy az 8. Ábra is mutatja, a bűnözési mintázat

jelentős eltéréseket mutat a városon belül, ezért az előrejelzéseket kerületenként készítem el (a 21-es és 31-es körzetre nem állt rendelkezésre elég információ, így azokat az elemzés során nem vettem figyelembe). Az időbeli felbontáshoz először minden körzetre és évre kiszámoltam a havi bűncselekmények számát, majd ebből az adatból kiszámoltam a bűncselekmények napi átlagos számát, így figyelembe tudtam venni, hogy az egyes hónapok különböző hosszúságúak. Tanító adathalmazként a 2001 és 2024 közötti időszakot, míg teszt adatként 2025 január és augusztus közötti időszakot használtam. Illetve még az adatelőkészítés során eltávolítottam azokat az oszlopokat amelyekre nem lesz szükség a modellépítés során, például a bűncselekmények pontos helyét jelző földrajzi koordinátákat, illetve a bűncselekmények típusát jelző oszlopokat is, mivel ezek nem relevánsak a bűnözés időbeli alakulásának modellezése szempontjából.

5.2.2 Paraméterek meghatározása

Elsőként a szimuláció alapparamétereit határoztam meg, ezek a következők voltak:

- dt : A szimuláció időlépése, amelyet 1 hónapra állítottam be, mivel a bűnözési adatokat havi szinten aggregáltam.
- T : A szimuláció teljes időtartama, amely az én esetemben 8 hónap volt, mivel a teszt adatok 2025 január és augusztus közötti időszakot ölelik fel.
- N : A szimuláció lépéseinek száma, amelyet a teljes időtartam és az időlépés alapján számoltam ki, így $N = \frac{T}{dt}$
- S_0 : A szimuláció kezdeti értéke, amely minden körzetre a 2024 decemberében elkövetett bűncselekmények napi átlagos számát jelenti, mivel ez az utolsó ismert adatpont a tanító adathalmazban.
- t : A szimuláció időtengelye, amely tartalmazza a szimuláció minden időpontját a kezdeti időponttól a teljes időtartam végéig, az időlépésnek megfelelően.

Majd ezt követően meghatároztam a geometriai Brown-mozgás paramétereit, amelyek a következők voltak:

- μ : A drift paraméter, amely a bűnözés hosszú távú trendjét jelenti. Ezt a paramétert minden körzetre külön-külön határoztam meg. Ehhez kiszámoltam a 2001 és 2024 közötti időszakban az egymást követő hónapok közötti relatív változást minden körzetre:

$$R = \frac{S_{t+1} - S_t}{S_t} \quad (87)$$

ahol S_t a bűncselekmények napi átlagos száma egy adott körzetben a t -edik hónapban. Ezután kiszámoltam ezen relatív változások átlagát minden körzetre, és ezt az értéket használtam a drift paraméterként.

- σ : A volatilitás paraméter, amely a bűnözés rövid távú ingadozásait jelenti. Ezt a paramétert szintén minden körzetre külön-külön határoztam meg. A σ kiszámolásához is a relatív változásokat használtam, de ezúttal a szórásukat számoltam ki minden körzetre, és ezt az értéket használtam a volatilitás paraméterként.

Minden körzetre két lehetséges scenáriót szimuláltam, úgy, hogy minden körzetre és minden időpontra generáltam egy véletlenszerű számot a standard normális eloszlásból. Ezután a sztochasztikus paraméter meghatározásához mindenkét scenárióban vettem a véletlen számok kommulált összegét és így kaptam meg a W paramétert. Végül a szimulációt a következő képlettel hajtottam végre minden körzetre és minden időpontra:

$$S_{t+1} = S_0 \cdot \exp \left(\left(\mu - \frac{\sigma^2}{2} \right) \cdot (dt) + \sigma \cdot \sqrt{dt} \cdot W_t \right) \quad (88)$$

ahol S_0 a szimuláció kezdeti értéke, μ a drift paraméter, σ a volatilitás paraméter, (dt) az időlépés, és W_t a sztochasztikus paraméter.


5.2.3 Eredmények és értékelés

A szimuláció eredményeként minden körzetre és minden időpontra két lehetséges scenáriót kaptam, az Táblázat 2 az első körzetre kapott előrejelzéseket mutatja be a két scenárióban.

Év	Hónap	Scenárió 1	Scenárió 2
2025	1	37.0	35.67
2025	2	32.85	32.35
2025	3	35.74	35.72
2025	4	39.74	38.98
2025	5	31.8	39.24
2025	6	27.4	44.56
2025	7	27.78	46.95
2025	8	26.78	42.55

2. Táblázat: Az első körzetre kapott előrejelzések a két scenárióban

Ahhoz, hogy ezeket a scenáriókat értékelni tudjam, összehasonlítottam őket a teszt adatokkal, amelyek 2025 január és augusztus közötti időszakot ölelik fel. A 14. Ábra mutatja a tényleges bűncselekmények napi átlagos számát a teszt időszakban, valamint a két scenárióban kapott előrejelzéseket.




12. Ábra: Tényleges bűncselekmények napi átlagos száma a teszt időszakban és a két scenárióban kapott előrejelzések

Már az ábra alapján is látható, hogy a két scenárióban kapott előrejelzések jelentős eltéréseket mutatnak, ami a sztochasztikus paraméter véletlenszerűségéből adódik. Az ábra alapján leolvasható, hogy a második scenárióban kapott előrejelzések közelebb állnak a tényleges adatokhoz. Ez azt jelzi, hogy a geometriai Brown-mozgás érzékeny a sztochasztikus paraméter értékére, ezért fontos lehet több scenáriót is szimulálni, hogy jobban megértsük a bűnözés időbeli alakulásának bizonytalanságát. A két scenárió összehasonlításához kiszámoltam az RMSE (Root Mean Square Error) értékét minden körzetre.

$$\text{RMSE} = \sqrt{\sum_{i=1}^n (y_i - (\hat{y})_i)^2} \quad (89)$$

így számszerűsíteni tudtam a két scenárió előrejelzéseinek pontosságát. Az RMSE értékek alapján a második scenárióban kapott előrejelzések a 25. körzet kivételével minden körzetben alacsonyabb RMSE értéket mutattak, ami megerősíti azt a megfigyelést, hogy a második scenárióban kapott előrejelzések közelebb állnak a tényleges adatokhoz. Az első körzet esetén a 15. Ábra mutatja a két RMSE értéket.



13. Ábra: Az első körzet esetén a két scenárió RMSE értékei


Az eredmények összefoglalását az alábbi táblázat mutatja:

RMSE	MAE	MAPE	Accuracy
2.43	1.93	6.92	93.08

)

3. Táblázat: Az eredmények összefoglalása

A táblázat alapján látható, hogy a modell 93,08%-os pontossággal (Accuracy) tudta előrejelezni a bűnözés alakulását a teszt időszakban, ami azt jelzi, hogy a geometriai Brown-mozgás jól alkalmazható a bűnözés időbeli modellezésére. Az RMSE és MAE (mean absolute error) értékek alapján is jól teljesített a modell, ezek az értékek azt mutatják, hogy a modell által előrejelzett értékek nem sehol nem térnek el kiugróan a tényleges értékektől.




(a) Előrejelzés hőtérképen

(b) Tényleges adatok hőtérképen

14. Ábra: Az előrejelzés és a tényleges adatok összehasonlítása hőtérképen

A 17. Ábra alapján is látható, hogy a két hőtérkép hasonló mintázatot mutat, látható, hogy a modell mind a kisebb mind a nagyobb esetszámú területeket jól azonosította, ami azt jelzi, hogy a modell képes volt megragadni a bűnözés nemcsak időbeli, de térbeli mintázatát is.



15. Ábra: Az előrejelzés és a tényleges adatok közötti különbség hőtérképen

Hogy vizuálisan is látható legyen a különbség a két hőtérkép között, készítettem egy külön hőtérképet, amely az előrejelzés és a tényleges adatok közötti különbséget mutatja be. A 18. Ábra alapján látható, hogy a különbségek nagy része kisebb értékek körül helyezkedik el, de megfigyelhető, hogy a 19-es, 14-es és 12-es körzetekben az abszolút átlagos hiba magasabb.

5.3 Bűnözés előrejelzése Random Forest modellel

A geometriai Brown-mozgás alkalmazásával sikerült feltárni a bűnözés időbeli alakulását és a sztochasztikus differenciálegyenletek segítségével megragadni az előrejelzés bizonytalanságát. Ez a megközelítés elsősorban a múltbeli adatból származtatott drift és volatilitás paraméterekre támaszkodik és vázolja fel a jövőbeli scenáriókat, azonban nem ismerjük meg az adatokban lévő struktúrákat és összefüggéseket. Ezért ebben a részben egy másik megközelítést alkalmazok, egy Random Forest modellt, amely képes megragadni az adatokban lévő nemlineáris összefüggéseket és interakciókat. A modell építése során a bűncselekmények számát jelzem előre minden körzetre és minden hónapra vonatkozóan, ugyanazt a tanító és teszt adathalmazatot használva, mint a geometriai Brown-mozgás esetében.

5.3.1 Adatok előkészítése

A Random Forest modell esetében is hasonlóan a geometriai Brown-mozgáshoz a 2001 és 2024 közötti időszakot használtam tanító adathalmazatként, míg a 2025 január és augusztus közötti időszakot teszt adathalmazatként. Az adatelőkészítés során azonban nem csak a bűncselekmények számát tartalmazó oszlopokat hagytam meg, hanem további jellemzőket is hozzáadtam, amelyek potenciálisan befolyásolhatják a bűnözés

alakulását. A célváltozó most is a bűncselekmények napi átlagos száma minden körzetre és minden hónapra vonatkozóan. Mivel a Random Forest modell nem tudja az időbeliséget megragadni, kiegészítettem az adatokat új bemeneti változókkal, amelyek az időbeli mintázatokat reprezentálják. Ezek a következők voltak:

- *Month*: A hónap száma (1-12)
- *Year index*: Az év indexe, amely a 2001-től kezdődő évek számát jelenti (pl. 2001 = 0, 2002 = 1, stb.)
- *Month sin*: A hónap szinusz transzformációja, amely segít megragadni a szezonális mintázatokat
- *Month cos*: A hónap koszinusz transzformációja, amely segít megragadni a szezonális mintázatokat
- *IsSummer*: Egy bináris változó, amely jelzi, hogy a hónap a nyári időszakban van-e (június, július, augusztus)
- *IsWinter*: Egy bináris változó, amely jelzi, hogy a hónap a téli időszakban van-e (december, január, február)

```
1 def year_indexing(df):  
2     df['Year_Index'] = 2025 - df['Year'] + 1  
3     return df
```

```
1 def prepare_month_data(df, col):  
2     df[col] = df[col].astype(float)  
3     df[f"{col}_Sin"] = df[col].apply(lambda x: (np.sin(((x-1) * 2 *  
4         np.pi / 12)+0.5)+1)/2)  
5     df[f"{col}_Cos"] = df[col].apply(lambda x: (np.cos(((x-1) * 2 *  
6         np.pi / 12)+0.5)+1)/2)  
7     df['Is_Winter'] = df['Month'].isin([12, 1, 2]).astype(int)  
8     df['Is_Summer'] = df['Month'].isin([6, 7, 8]).astype(int)  
9     df = year_indexing(df)  
10    return df
```

1. Listing: Az időbeli jellemzők előkészítése

Továbbá mivel a bűnözés jövőbeli rátája egy körzetben nagymértékben függ az elmúlt időszakok tendenciáitól és a hónapok kinyerése és átalakítása segít a szezonális modellezésében, de nem képes megragadni a folyamatos időbeli trendet. Tehát, hogy a

Random Forest modellt hatékonyan tudjam alkalmazni idősorok elmzésére, az adatelő-készítés során úgynevezett késleltetett változókat (lag features) is létrehoztam. Ezek a változók a bűncselekmények napi átlagos számát tartalmazzák az előző hónapokban minden körzetre vonatkozóan. Tehát így a modell képes lesz emlékezni a múltbeli értékekre.

```
1  def create_lagged_features(df, col, lag=1):  
2      df_lagged = df.copy()  
3      for i in range(1, lag + 1):  
4          df_lagged[f'{col} Lag {i}'] = df_lagged.groupby('District')  
              [col].shift(i)  
5      return df_lagged
```

2. Listing: Késleltetett változók létrehozása

A lag változók létrehozása mellett a múltbeli értékekből kiszámolt mozgóátlagot és mozgósórát is hozzáadtam az adatokhoz, hogy egy-egy kiugró érték ne befolyásolja túlzottan a modellt és hogy a modell a mozgósórás értékek alapján meg tudja ragadni a bűnözés ingadozásait.

```

1  def rolling_mean(df, idopontok):
2
3      for i in idopontok:
4
5          df[f'Rolling Mean {i}'] = (
6
7              df.groupby('District')['Number of Crimes Per Day']
8
9                  .transform(lambda s: s.shift(1).rolling(window=i).mean()))
10
11
12  return df

```

```

1  def rolling_std(df, idopontok):
2
3      for i in idopontok:
4
5          df[f'Rolling Std {i}'] = (df.groupby('District')['Number of
6      Crimes Per Day'].transform(lambda s:
7          s.shift(1).rolling(window=i).std()))
8
9
10  return df

```

3. Listing: Mozgóátlagok és mozgósórások létrehozása

5.3.2 Modellépítés és eredmények

Az adatok előkéazítása után a Random Forest modellek betanítása következett. Két különböző modellt építettem, az elsőben csak a késleltetett változókat használtam, míg a második modellben már a mozgóátlagokat és mozgósórásokat is hozzáadtam a bemeneti változókhoz.

5.3.2.1 Modell 1: Késleltetett változók

A modellben során használt bemeneti változók a következők voltak:

- *District*: A körzet azonosítója
- *Year Index*: Az év indexe
- *Month Sin*: A hónap szinusz transzformációja
- *Month Cos*: A hónap koszinusz transzformációja
- *Is Summer*: Bináris változó, amely jelzi, hogy a hónap a nyári időszakban van-e
- *Is Winter*: Bináris változó, amely jelzi, hogy a hónap a téli időszakban van-e

- *Number of Crimes Per Day Lag 1*: A bűncselekmények napi átlagos száma az előző hónapban
- *Number of Crimes Per Day Lag 2*: A bűncselekmények napi átlagos száma két hónappal ezelőtt

A késleltetett (lag) változók számának megválasztása során több különböző beállítást is kipróbáltam, az eredmények alapján a 2 hónapra visszamenő késleltetett változók adták a legjobb eredményeket, ezért ezeket használtam a modellben. Több lag-változó használata esetén a modell teljesítmény már nem mutatott javulást, ezt magyarázhatja, hogy a bűnözés alakulására leginkább az előző hónapok tendenciái vannak hatással, és a túl sok lag-változó használata már nem ad hozzá új információt a modell számára, viszont növeli a modell komplexitását és a túlillesztés kockázatát.

A Random Forest modell nem hónaponként készítette el az előrejelzést, hanem egyszerre, a 8 hónapra vonatkozóan. Így a modell egy adott időpont és körzet alapján egy teljes előrejelzési horizontot állított elő. Ennek előnye, hogy a több hónapra vonatkozó becslések egyszerre készülnek el, vagyis a modell nem kényszerül arra, hogy minden újabb hónap előrejelzéséhez az előző saját becslését használja fel. Ez csökkentheti a hibák továbbterjedését, amely a szekvenciális előrejelzéseknél gyakran problémát jelent.

A Random Forest modell hiperparamétereit RandomizedSearchCV segítségével hangoltam, amely egy véletlenszerű keresést hajt végre a megadott hiperparaméterek között, és a legjobb kombinációt választja ki a modell teljesítménye alapján. A legjobb hiperparaméterek a következők voltak:

- *n_estimators*: 521 (a döntési fák száma a Random Forest modellben)
- *max_depth*: 12 (a döntési fák maximális mélyse)
- *max_features*: '0.5' (a bemeneti változók aránya, amelyet minden döntési fa építésekor véletlenszerűen kiválasztanak)

A modell validálásához walk-forward cross-validation-t alkalmaztam, amely egy időbeli keresztvalidációs módszer. A módszer során a tanító adathalmazatot több részre osztottam, és minden részre külön-külön tanítottam a modellt, majd a következő részre vonatkozóan készítettem előrejelzést, így megőriztem az időbeli sorrendiséget. A keresztvalidáció során a következő eredményeket kaptam:

RMSE	MAPE	Accuracy
5.41	12.03	87.97


4. Táblázat: Walk-forward keresztvalidáció eredményei

A modell teljesítményét a teszt adathalmazaton is értékeltem, amely 2025 január és augusztus közötti időszakot öleli fel. A következő táblázat mutatja a teszt adathalmazaton kapott eredményeket:

RMSE	MAE	MAPE	Accuracy
3.11	2.53	9.18	90.82

5. Táblázat: Teszt adathalmazaton kapott eredmények

A táblázat alapján látható, hogy a modell 90,82%-os pontossággal (Accuracy) tudta előrejelezni a bűnözés alakulását a teszt időszakban, illetve az RMSE érték is viszonylag alacsony (3,11), ami azt jelenti, hogy az előrejelzett napi átlagos bűncselekményszám átlagosan kis mértékben tér el a tényleges értékektől. Akárcsak a geometriai Brown-mozgás esetében, a modell előrejelzéseit hő térképen is megjelenítettem, hogy vizuálisan is összehasonlítható legyen a tényleges adatokkal.




(a) Előrejelzés hő térképen

(b) Tényleges adatok hő térképen

16. Ábra: Az előrejelzés és a tényleges adatok összehasonlítása hő térképen

A 24. Ábra mutatja az előrejelzés és a tényleges adatok hő térképeit. Az eltérések vizuális megjelenítéséhez készítettem egy külön hő térképet, amely az előrejelzés és a tényleges adatok közötti különbséget mutatja be.



17. Ábra: Az előrejelzés és a tényleges adatok közötti különbség hő térképen

Az 25. Ábra alapján látható, hogy a különbségek nagy része nem jelentős, de megfigyelhető pár körzet, ahol az abszolút átlagos hiba magasabb, például a 14, 25 és 19-es körzetekben, ahol 4 fölötti átlagos hibát kaptam.

5.3.3 Modell 2: Késleltetett változók, mozgóátlagok és mozgósórások

A második modellben a bemeneti változókat még kiegészítettem a mozgóátlagokkal és mozgósórásokkal, így a bemeneti változók a következők voltak:

- *District*: A körzet azonosítója
- *Year Index*: Az év indexe
- *Month Sin*: A hónap szinusz transzformációja
- *Month Cos*: A hónap koszinusz transzformációja
- *Is Summer*: Bináris változó, amely jelzi, hogy a hónap a nyári időszakban van-e
- *Is Winter*: Bináris változó, amely jelzi, hogy a hónap a téli időszakban van-e
- *Number of Crimes Per Day Lag 1*: A bűncselekmények napi átlagos száma az előző hónapban
- *Number of Crimes Per Day Lag 2*: A bűncselekmények napi átlagos száma két hónappal ezelőtt
- *Rolling Mean 3*: A bűncselekmények napi átlagos számának 3 hónapos mozgóátlaga
- *Rolling Mean 4*: A bűncselekmények napi átlagos számának 4 hónapos mozgóátlaga
- *Rolling Std {k}*: A bűncselekmények napi átlagos számának k hónapos mozgósórása, ahol $k = 3, 4, 5, 6, 9$

A modell felépítése és a hiperparaméterek hangolása ugyanúgy történt, mint az első modell esetében. A keresztvalidáció során a következő eredményeket kaptam:

RMSE	MAPE	Accuracy
14.03	28.86	71.14


6. Táblázat: Walk-forward keresztvalidáció eredményei

A teszt adathalmazaton kapott eredményeket a következő táblázat mutatja:

RMSE	MAE	MAPE	Accuracy
3.26	2.69	9.78	90.22

7. Táblázat: Teszt adathalmazaton kapott eredmények

A táblázat alapján látható, hogy a modell 92,71%-os pontossággal jelzett előre, ebből is látszik, hogy a mozgóátlagok és mozgósórások hozzáadása javította a modell teljesítményét, hiszen az első modellben 90,82%-os pontossággal tudta előrejelezni a bűnözés alakulását. Az RMSE érték is csökkent (2,44), ami azt jelenti, hogy az előrejelzett napi átlagos bűncselekményszám átlagosan kisebb mértékben tér el a tényleges értékektől, mint az első modell esetében. Ebben az esetben is elkészítettem a hőtérképeket:




(a) Előrejelzés hőtérképen

(b) Tényleges adatok hőtérképen

18. Ábra: Az előrejelzés és a tényleges adatok összehasonlítása hőtérképen

Továbbá a különbség hőtérképet is elkészítettem:



19. Ábra: Az előrejelzés és a tényleges adatok közötti különbség hőtérképen

5.4 Bűnözést befolyásoló demográfiai tényezők elemzése és előrejelzés készítése

6 Irodalomjegyzék

- [1] S. E. Shreve, *Stochastic Calculus for Finance II: Continuous-Time Models*. Springer, 2004.
- [2] M. Pitera, „Stochastic Processes – Lecture Notes”. 2020.
- [3] F. Herzog, „Stochastic Differential Equations”. 2013.
- [4] J. M. Julia Calatayud Marc Jornet, „Spatio-temporal stochastic differential equations for crime incidence modeling”, *Stochastic Environmental Research and Risk Assessment*, köt. 37, o. 1839–1854, 2023, doi: 10.1007/s00477-022-02369-x.
- [5] B. Øksendal, *Stochastic Differential Equations: An Introduction with Applications*. Springer, 2003.
- [6] T. Hastie, R. Tibshirani, és J. Friedman, *The Elements of Statistical Learning*. Springer, 2009.
- [7] B. C. Csáji, „Data Mining and Machine Learning”. 2025.
- [8] G. James, D. Witten, T. Hastie, és R. Tibshirani, *An Introduction to Statistical Learning*, 2. kiad. Springer, 2021.
- [9] G. E. P. Box és G. M. Jenkins, *Time Series Analysis: Forecasting and Control*. Holden-Day, 1970.
- [10] R. J. Hyndman és G. Athanasopoulos, *Forecasting: Principles and Practice*, 2. kiad. OTexts, 2018.