

EÖTVÖS LORÁND TUDOMÁNYEGYETEM
Természettudományi Kar

Győrfi Enikő

BÚNÖZÉSI GYAKORISÁG MODELLEZÉSE

Szakdolgozat
Matematika alapszak

Témavezető:
Maga Balázs



ELTE | TTK
TERMÉSZETTUDOMÁNYI KAR

Budapest, 2026

Tartalomjegyzék

1 Bevezetés	1
2 A Sztochasztikus Folyamatok Elméleti Alapjai	1
2.1 Definíciók és alapfogalmak	1
2.2 Sztochasztikus folyamatok	2
2.3 Brown-mozgás	4
3 Sztochasztikus differenciálegyenletek	6
3.1 Bevezetés	6
3.2 Itô-integrál	7
3.3 Geometriai Brown-mozgás	12
4 A gépi tanulás elméleti hátttere	15
4.1 A gépi tanulás alapjai	15
4.2 Döntési fák	19
4.2.1 A döntési fák tanítása	21
4.3 Ensemble módszerek	21
4.3.1 Random Forest	22
4.4 Idősorok elemzése	23
4.4.1 Alapfogalmak	24
4.4.2 Klasszikus idősoelemzési módszerek	25
4.4.2.1 Determinisztikus és simításos módszerek	25
4.4.2.2 Sztochasztikus módszerek	25
4.4.3 Gépi tanulási és mélytanulási módszerek idősorok elemzésére	27
5 Gyakorlati alkalmazások	29
5.1 Adatok bemutatása	29
5.2 Bűnözés időbeli modellezése geometriai Brown-mozgással (Korrelált Brown-mozgás)	33
5.2.1 Adatok előkészítése	33
5.2.2 Paraméterek meghatározása	34
5.2.2.1 A korrelációs mátrix meghatározása és scenáriók generálása	35
5.2.3 Eredmények és értékelés	37
5.3 Bűnözés előrejelzése Random Forest modellel	39
5.3.1 Adatok előkészítése	39
5.3.2 Modellépítés és eredmények	41
5.3.2.1 Modell 1: Késleltetett változók	41
5.3.3 Modell 2: Késleltetett változók, mozgóátlagok és mozgósórások	44
5.3.4 Összefoglalás	46
5.4 Bűnözést befolyásoló demográfiai tényezők elemzése és előrejelzés készítése	48
5.4.1 Adatok előkészítése	48
5.4.2 Eredmények és értékelés	49
5.4.2.1 Összesített modell	49
5.4.2.2 Bűncselekménytípusok szerinti elemzés	51
5.4.2.2.0.1 Lopás	52
5.4.2.2.1 Testi sértés	54

5.4.2.2 Rongálás	56
5.4.2.3 Összefoglalás	58
6 Irodalomjegyzék	61

1 Bevezetés

2 A Sztochasztikus Folyamatok Elméleti Alapjai

2.1 Definíciók és alapfogalmak

Definíció 2.1.1

Egy valószínűségi tér $(\Omega, \mathcal{F}, P)$ hármasa tartalmazza:

- Ω (**eseménytér**): a lehetséges kimenetek halmaza.
- $\mathcal{F}$ (**σ -algebra**): Ω részhalmazainak olyan rendszere, amely tartalmazza az $\emptyset$ üres halmazt; komplementerre zárt; és megszámlálható unióra zárt. Az $(\Omega, \mathcal{F})$ párost mérhető térnek nevezzük.
- P (**valószínűségi mérték**): egy $P : \mathcal{F} \rightarrow \mathbb{R}$ függvény, amely kielégíti a $P(\emptyset) = 0$ és $P(\Omega) = 1$ feltételeket, és megszámlálható additivitással rendelkezik diszjunkt halmazok esetén.

Definíció 2.1.2

Legyen X egy Ω -n értelmezett függvényekből álló halmaz. Az X által generált σ -algebra a legkisebb σ -algebra, amelyre vonatkozóan ezen függvények mind mérhetőek. Jelölése: $\sigma(X)$.

Definíció 2.1.3

[1] Tegyük fel, hogy adott két valószínűségi mérték $\mathcal{P}$ és $\mathcal{Q}$ ugyanazon mérhető téren $(\Omega, \mathcal{F})$. Azt mondjuk, hogy a $\mathcal{Q}$ mérték abszolút folytonos a $\mathcal{P}$ -re nézve, ha létezik egy integrálható véletlen változó $f : \Omega \rightarrow \mathbb{R}$, melyre minden $A \in \mathcal{F}$ esetén

$$\mathcal{Q}(A) = \int_A f(\omega) d\mathcal{P}(\omega) \quad (1)$$

teljesül.

Ekkor f a $\mathcal{Q}$ mérték $\mathcal{P}$ -re vonatkozó sűrűségfüggvénye.

Megjegyzés. Ebben az esetben, ha $E^{\mathcal{P}}$ és $E^{\mathcal{Q}}$ a két mérték szerinti várható értékek, akkor minden $\mathcal{Q}$ szerint integrálható véletlen változóra X :

$$E^{\mathcal{Q}}[X] = \int_{\Omega} X d\mathcal{Q} = \int_{\Omega} X f d\mathcal{P} = E^{\mathcal{P}}[Xf]. \quad (2)$$

Definíció 2.1.4

[1] Legyen Ω egy nemüres halmaz. Legyen T egy rögzített pozitív szám, és tegyük fel, hogy minden $t \in [0, T]$ esetén adott egy $\mathcal{F}(t)$ σ -algebra. Tegyük fel továbbá, hogy ha $s \leq t$, akkor minden halmaz, amely eleme $\mathcal{F}(s)$ -nek, eleme $\mathcal{F}(t)$ -nek is. Ekkor a $0 \leq t \leq T$ paraméterű $\mathcal{F}(t)$ σ -algebrák gyűjteményét filtrációnak nevezzük.

Definíció 2.1.5

[1] Legyen X egy nem üres Ω mintatéren értelmezett valószínűségi változó. Legyen $\mathcal{G}$ az Ω részhalmazainak egy σ -algebrája. Ha a $\sigma(X)$ minden halmaza eleme $\mathcal{G}$ -nek is, akkor azt mondjuk, hogy X $\mathcal{G}$ -mérhető.

Definíció 2.1.6

[1] Legyen $f(t)$ egy $[0, T]$ intervallumon értelmezett függvény. Az f kvadratikus variációját a $[0, T]$ intervallumon a következő határértékkel definiáljuk:

$$[f, f](T) = \lim_{\|\Pi\| \rightarrow \infty} \sum_{i=0}^{n-1} (f(t_{i+1}) - f(t_i))^2, \quad (3)$$

ahol $\Pi = \{0 = t_0 < t_1 < \dots < t_n = T\}$ egy partíciója a $[0, T]$ intervallumnak, és $\|\Pi\| = \max_{0 \leq i \leq n-1} (t_{i+1} - t_i)$.

2.2 Sztochasztikus folyamatok

Definíció 2.2.1

[1] Legyen $(\Omega, \mathcal{F}, P)$ egy valószínűségi tér és T egy rögzített pozitív szám. Ekkor az $X = (X_t)_{t \in [0, T]}$ családot sztochasztikus folyamatnak nevezzük, ha minden $t \in [0, T]$ esetén X_t egy valószínűségi változó.

Definíció 2.2.2

[1] Legyen $(\Omega, \mathcal{F}, P)$ egy valószínűségi tér és $(\mathcal{F}(t))_{0 \leq t \leq T}$ filtráció. Legyen $X(t)$ egy valószínűségi változókból álló család, amelyet $t \in [0, T]$ paraméter indexel. Azt mondjuk, hogy $X(t)$ egy adaptált sztochasztikus folyamat az $\mathcal{F}(t)$ -re nézve, ha minden t -re az $X(t)$ valószínűségi változó $\mathcal{F}(t)$ -mérhető.

Definíció 2.2.3

[1] Legyen $(\Omega, \mathcal{F}, P)$ egy valószínűségi mező, legyen T egy rögzített pozitív szám, és legyen $(\mathcal{F}(t))_{0 \leq t \leq T}$ a $\mathcal{F}$ σ -algebráinak egy filtrációja. Tekintsünk egy adaptált sztochasztikus folyamatot $M(t)$ -t, $0 \leq t \leq T$.

(i) Ha $E[M(t) \mid \mathcal{F}(s)] = M(s)$ minden $0 \leq s \leq t \leq T$ esetén, akkor a folyamat **martingálnak** nevezzük.

(ii) Ha $E[M(t) \mid \mathcal{F}(s)] \geq M(s)$ minden $0 \leq s \leq t \leq T$ esetén, akkor a folyamat **szubmartingál**.

(iii) Ha $E[M(t) \mid \mathcal{F}(s)] \leq M(s)$ minden $0 \leq s \leq t \leq T$ esetén, akkor a folyamat **szupermartingál**.

Definíció 2.2.4

[1] Legyen $(\Omega, \mathcal{F}, P)$ egy valószínűségi mező, legyen T egy rögzített pozitív szám és legyen $(\mathcal{F}(t))_{0 \leq t \leq T}$ a $\mathcal{F}$ σ -algebráinak egy filtrációja. Az $X(t)_{0 \leq t \leq T}$ adaptált sztochasztikus folyamatot Markov-folyamatnak nevezzük, ha minden $0 \leq s < t \leq T$ és minden nemnegatív, Borel-mérhető f függvény esetén létezik egy g Borel-mérhető függvény, amelyre teljesül:

$$E[f(X(t)) \mid \mathcal{F}(s)] = g(X(s)) \quad (4)$$

Megjegyzés. Tehát a Markov-folyamat jövőbeli állapota csak a jelenlegi állapottól függ, és független a múltbeli állapotoktól. Ebből következik, hogy az együttes valószínűségi sűrűség feltételes formája felírható átmeneti sűrűségek szorzataként:

$$p(x_n, t_n \dots x_2, t_2 \mid x_1, t_1) = p(x_n, t_n \mid x_{n-1}, t_{n-1}) \dots p(x_2, t_2 \mid x_1, t_1). \quad (5)$$

Definíció 2.2.5

Egy folytonos Markov-folyamat időben homogén, ha az átmeneti sűrűsége csak az időbeli különbségektől függ:

$$p(x, t \mid y, s) = p(x, t - s \mid y, 0). \quad (6)$$

2.3 Brown-mozgás

Definíció 2.3.1

[2] Egy $B = (B_t)_{t \geq 0}$ sztochasztikus folyamatot Brown-mozgásnak (vagy Wiener-folyamatnak) nevezünk, ha az alábbi négy tulajdonságnak tesz eleget:

- A folyamat a $t = 0$ időpontban a nullából indul, 1 valószínűséggel, azaz $B_0 = 0$.
- A folyamat pályái, azaz a $t \mapsto B_t(\omega)$ leképezések minden egyes ω elemi eseményre, majdnem biztosan folytonosak.
- Bármely $0 \leq s_1 < t_1 \leq s_2 < t_2$ időpontosorozatra a $B_{t_1} - B_{s_1}$ és $B_{t_2} - B_{s_2}$ valószínűségi változók függetlenek egymástól.
- Bármely $s < t$ időpontpárra a $B_t - B_s$ növekmény normális eloszlású, 0 várható értékkel és $t - s$ szórásnégyzettel. Formálisan: $B_t - B_s \sim N(0, t - s)$.

Megjegyzés. A független növekmények tulajdonságából adódóan a Brown-mozgás egy Gauss–Markov-folyamat. Továbbá, mivel az átmeneti sűrűsége csak az időbeli különbségtől függ, egyben időben homogén Markov-folyamat is.

Definíció 2.3.2

[1] Legyen $(\Omega, \mathcal{A}, P)$ egy valószínűségi mező, amelyen a $B(t)$, $t \geq 0$ Brown-mozgás definiálva van. A $B(t)$ -hez tartozó filtráció egy $\mathcal{F}(t)$ szigma-algebrákból álló család, amelyre a következő feltételek teljesülnek:

- Az információ halmazodik: $\mathcal{F}(s) \subset \mathcal{F}(u)$ minden $0 \leq s < u$ esetén, vagyis az idő előrehaladtával az elérhető információ mennyisége nem csökken.
- Adaptivitás: minden $t \geq 0$ esetén a $B(t)$ $\mathcal{F}(t)$ -mérhető.
- A jövőbeli növekmények függetlensége: minden $0 \leq s < u$ esetén a $B(u) - B(s)$ növekmény független $\mathcal{F}(s)$ -től.

Tétel 2.3.3

[1] Legyen $(\Omega, \mathcal{A}, P)$ egy valószínűségi mező, amelyen a $B(t)$, $t \geq 0$ Brown-mozgás definiálva van. Ekkor a következő állítások teljesülnek:

- $B(t)$ martingál a fenti definícióban definiált filtrációval.

Bizonyítás. Elég azt bizonyítani, hogy a $B(t)$ folyamat martingál. Legyen $0 \leq s < t$ adott, és tekintsük a következő várható értéket:

$$E[B(t) \mid \mathcal{F}(s)] = E[B(t) - B(s) + B(s) \mid \mathcal{F}(s)]. \quad (7)$$

Mivel a Brown-mozgás növekményei függetlenek a múltbeli információtól, ezért

$$E[B(t) - B(s) \mid \mathcal{F}(s)] = E[B(t) - B(s)] = 0. \quad (8)$$

Ezenkívül, mivel $B(s)$ már ismert a $\mathcal{F}(s)$ -ben, ezért

$$E[B(s) \mid \mathcal{F}(s)] = B(s). \quad (9)$$

Ezeket az eredményeket összevonva kapjuk, hogy

$$E[B(t) \mid \mathcal{F}(s)] = 0 + B(s) = B(s). \quad (10)$$

Ez pontosan a martingál feltétel, így a $B(t)$ folyamat martingál. ■

3 Sztochasztikus differenciálegyenletek

3.1 Bevezetés

Egy közönséges differenciálegyenlet az alábbi formában írható fel:

$$\frac{dx(t)}{dt} = f(t, x(t)). \quad (11)$$

ahol $x(t)$ a vizsgált mennyiség időbeli változása, és $f(t, x(t))$ egy determinisztikus függvény, amely meghatározza a rendszer dinamikáját.

Integrál formában és $x(0) = x_0$ kezdeti értékkel ez az egyenlet a következőképpen néz ki:

$$x(t) = x_0 + \int_0^t f(s, x(s)) ds. \quad (12)$$

Egy SDE akkor jön létre, ha a differenciálegyenlet egy együtthatója determinisztikus paraméter helyett sztochasztikus paraméterré válik. Például tekintsük a következő KDE-t:

$$\frac{dx(t)}{dt} = a(t)x(t). \quad (13)$$

Amennyiben feltesszük, hogy $a(t)$ egy sztochasztikus folyamat, akkor az egyenlet sztochasztikus differenciálegyenletté alakul. Ekkor az $a(t)$ a következő formában írható fel:

$$a(t) = f(t) + h(t)\xi(t), \quad (14)$$

ahol $\xi(t)$ egy fehér zaj folyamat.

Ekkor az SDE a következőképpen néz ki:

$$\frac{dx(t)}{dt} = (f(t) + h(t)\xi(t))x(t) \quad (15)$$

Legyen $dB(t) = \xi(t) dt$, ahol $dB(t)$ a Brown-mozgás differenciálját jelöli, ekkor az SDE differenciál formában a következőképpen írható fel:

$$dx(t) = f(t)x(t) dt + h(t)x(t) dB(t). \quad (16)$$

Általánosabban egy Itô-típusú sztochasztikus differenciálegyenlet a következő formában írható fel:

$$dx(t, \omega) = f(t, x(t, \omega)) dt + g(t, x(t, \omega)) dB(t). \quad (17)$$

Egy általános, Itô-típusú SDE a következő szimbolikus formában írható fel:

$$dX(t) = \mu(t, X(t)) dt + \sigma(t, X(t)) dB(t). \quad (18)$$

Ez az egyenlet valójában egy integrálegyenlet rövidítése, és két fő részből áll:

- **Drift tag:** a folyamat változásának determinisztikus, előre jelezhető komponense egy infinitezimális dt időlépés alatt.
- **Diffúziós tag** $(\sigma(X_t, t) dB_t)$: ez a sztochasztikus, előre nem látható komponenst képviseli. A hatásának nagyságát a $\sigma(X_t, t)$ volatilitás- vagy diffúziós függvény skálázza, amely függhet a rendszer aktuális állapotától és az időtől is. Ez a tag visz véletlenszerűséget a rendszer leírásába.

3.2 Itô-integrál

Amikor a modellezett rendszerben véletlen hatások jelennek meg, a klasszikus integrálfogalom már nem elegendő. Számos alkalmazási területen, például pénzügyi matematikában, fizikai rendszerek leírásában vagy biológiai folyamatok vizsgálatában, a modellek természetes módon vezetnek sztochasztikus folyamatokhoz. A Brown-mozgás pályái 1 valószínűséggel folytonosak, de sehol sem differenciálhatók, így nem rendelkeznek jól definiált deriváltakkal. Emiatt a hagyományos Riemann- vagy Lebesgue-integrál közvetlenül nem alkalmazható olyan kifejezésekre, mint például

$$\int_0^t X(s) dB(s). \quad (19)$$

Az ilyen típusú integrálok értelmezéséhez egy új integrálfogalom bevezetése szükséges. Az Itô-integrál lehetővé teszi, hogy Brown-mozgásra vonatkozóan értelmezzük a sztochasztikus integrálokat.

Az előbbi kifejezésben az integrál egyik összetevője egy $B(t)$, $t \geq 0$ Brown-mozgás, valamint az ehhez tartozó $\mathcal{F}(t)$, $t \geq 0$ filtráció. Az integrandus $X(t)$ egy adaptált sztochasztikus folyamat, amely azt jelenti, hogy minden $t \geq 0$ esetén $X(t)$ $\mathcal{F}(t)$ -mérhető. Az adaptáltság biztosítja, hogy $X(t)$ értéke csak a t időpontig ismert információtól függ.

Definíció 3.2.1

[1] Legyen a $0 = t_0 < t_1 < \dots < t_n = T$ egy partíciója a $[0, T]$ intervallumnak, és legyen $\Delta(t)$ konstans minden $t \in [t_i, t_{i+1})$ intervallumon. Ekkor $\Delta(t)$ -t elemi folyamatnak nevezzük.

Ez analóg a Lebesgue-integrál lépcsős függvényeivel, ahol a függvény értéke egy adott intervallumon állandó.

Definíció 3.2.2

[1] Egy elemi folyamat Itô-integrálja a következőképpen definiálható:

$$I(t) = \int_0^T \Delta(s) dB(s) = \sum_{j=0}^n \Delta(t_j)(B(t_j) - B(t_{j-1})) + \Delta(t_n)(B(T) - B(t_n)). \quad (20)$$

Tétel 3.2.3

[1] Legyen $\Delta(t)$ egy elemi folyamat, ekkor az Itô-izometria a következőképpen írható fel:

$$E \left[\left(\int_0^t \Delta(s) dB(s) \right)^2 \right] = E \left[\int_0^t \Delta^2(s) ds \right]. \quad (21)$$

Az elemi folyamatok integráljának felhasználásával az Itô-integrál kiterjeszthető általános adaptált sztochasztikus folyamatokra, amelyek kielégítik a megfelelő feltételeket:

- $X(t)$ adaptált a $\mathcal{F}(t)$ filtrációhoz.
- $X(t)$ kvadratikusán integrálható, azaz $\int_0^t E[X^2(s)] ds < \infty$ minden $t \geq 0$ esetén.

Az integrál definiálásához az $X(t)$ folyamatot elemi folyamatokkal közelítjük. Vesszük a $[0, T]$ intervallum egy partícióját: $0 = t_0 < t_1 < \dots < t_n = T$, és a $[t_j, t_{j+1}]$ intervallumon a közelítő $\Delta(t)$ elemi folyamat értékét az $X(t_j)$ értékére állítjuk. Így a felosztás finomításával az elemi folyamat egyre jobb közelítést ad az $X(t)$ folyamatnak. Választható tehát elemi folyamatok sorozata $\Delta_n(t)$ úgy, hogy a következő konvergencia teljesüljön, ha $n \rightarrow \infty$:

$$E \int_0^t |X(s) - \Delta_n(s)|^2 ds \rightarrow 0. \quad (22)$$

Ekkor az Itô-integrál a következőképpen definiálható:

$$\int_0^t X(s) dB(s) = \lim_{n \rightarrow \infty} \int_0^t \Delta_n(s) dB(s), \quad 0 \leq t \leq T. \quad (23)$$

Az integrál tulajdonságait a következő tétel foglalja össze:

Tétel 3.2.4

[1] Legyen T egy pozitív konstans, és legyen $X(t), 0 \leq t \leq T$ egy adaptált sztochasztikus folyamat, amely kielégíti a fentebb írt feltételeket. Ekkor az

$$I(t) = \int_0^t X(s) dB(s) \quad (24)$$

folyamat a következő tulajdonságokkal rendelkezik:

- **Folytonosság:** $I(t)$ pályái folytonosak.
- **Adaptáltság:** minden t -re az $I(t)$ folyamat $\mathcal{F}(t)$ -mérhető.
- **Linearitás:** ha $I(t) = \int_0^t X(s) dB(s)$ és $J(t) = \int_0^t Y(s) dB(s)$, akkor $I(t) + J(t) = \int_0^t (X(s) + Y(s)) dB(s)$. Továbbá minden c konstansra $I(t) = \int_0^t c dB(s)$.
- **Martingál tulajdonság:** az $I(t)$ folyamat martingál.
- **Itô-izometria:** $E[I^2(t)] = E\left[\int_0^t X^2(u) du\right]$.
- **Kvadratikus variáció:** $[I, I](t) = \int_0^t X^2(u) du$.

Eddig azt vizsgáltuk, hogyan lehet értelmezni egy Brown-mozgásra vonatkozó integrált, és milyen tulajdonságokkal rendelkezik ez az integrál. Most vizsgáljuk meg, hogyan lehet értelmezni egy Brown-mozgás által meghatározott folyamat megváltozását. Tekintsük a következő kifejezést:

$$\frac{d}{dt} f(B(t)). \quad (25)$$

Ez a kifejezés nem értelmezhető a klasszikus analízisben használt láncszabály szerint, mivel a Brown-mozgás pályái sehol sem differenciálhatók. Ennek értelmezéséhez az Itô–Doebelin-formula alkalmazására van szükség, amely egy sztochasztikus változókra vonatkozó általánosított láncszabály.

Tétel 3.2.5

[1] Legyen $f(t, x)$ függvény, melynek parciális deriváltjai f_t , f_x és f_{xx} léteznek és folytonosak. Legyen továbbá $B(t)$ egy Brown-mozgás. Ekkor minden $T \geq 0$ esetén teljesül a következő egyenlőség:

$$\begin{aligned} f(T, B(T)) &= f(0, B(0)) + \int_0^T f_t(t, B(t)) dt \\ &+ \int_0^T f_x(t, B(t)) dB(t) + \frac{1}{2} \int_0^T f_{xx}(t, B(t)) dt. \end{aligned} \quad (26)$$

Ahhoz, hogy megértsük az Itô–Doebelin-formula jelentőségét, tekintsük a következő példát. Legyen $f(x) = \frac{1}{2}x^2$, ekkor f nem függ az időtől, így $f_t = 0$, és a parciális deriváltakak $f_x = x$ és $f_{xx} = 1$. Legyen x_{j-1} és x_j két szomszédos pont egy partícióban, és tekintsük a Taylor-sor első két tagját:

$$f(x_j) - f(x_{j-1}) = f_x(x_{j-1})(x_j - x_{j-1}) + \frac{1}{2}f_{xx}(x_{j-1})(x_j - x_{j-1})^2. \quad (27)$$

Továbbá legyen $T > 0$ egy rögzített pozitív szám, és legyen a $[0, T]$ intervallum egy partíciója $\mathcal{P} = \{t_0, t_1, \dots, t_n\}$. Az $f(B(t))$ folyamat változását 0 és T között a következőképpen írhatjuk fel:

$$\begin{aligned} f(B(T)) - f(B(0)) &= \sum_{j=1}^n f_x(B(t_{j-1}))(B(t_j) - B(t_{j-1})) + \\ &\quad \frac{1}{2} \sum_{j=1}^n f_{xx}(B(t_{j-1}))(B(t_j) - B(t_{j-1}))^2. \end{aligned} \quad (28)$$

Ha ebbe behelyettesítjük a parciális deriváltakak értékét, akkor a következő egyenlőséget kapjuk:

$$\begin{aligned} f(B(T)) - f(B(0)) &= \sum_{j=1}^n B(t_{j-1})(B(t_j) - B(t_{j-1})) + \\ &\quad \frac{1}{2} \sum_{j=1}^n (B(t_j) - B(t_{j-1}))^2. \end{aligned} \quad (29)$$

A partíció finomításával, azaz ha $\|\mathcal{P}\| \rightarrow 0$, akkor a következő konvergencia teljesül:

$$\sum_{j=1}^n B(t_{j-1})(B(t_j) - B(t_{j-1})) \rightarrow \int_0^T B(t) dB(t) \quad (30)$$

és

$$\sum_{j=1}^n (B(t_j) - B(t_{j-1}))^2 \rightarrow [B, B](T) = T. \quad (31)$$

Ezeket az eredményeket összevonva kapjuk, hogy

$$f(B(T)) - f(B(0)) = \int_0^T B(t) dB(t) + \frac{1}{2}T. \quad (32)$$

Ez pontosan az Itô–Doebelin-formula egy speciális esete, amelyben a függvény csak a Brown-mozgás értékétől függ, és nem függ az időtől.

Eddig az Itô–Doebelin-formulát egy speciális esetre vizsgáltuk, nevezetesen a Brown-mozgásra. Azonban ez a formula általánosítható tetszőleges Itô-folyamatokra is.

Definíció 3.2.6

[1] Legyen $B(t)$ egy Brown mozgás és $\mathcal{F}$ a $B(t)$ -hez tartozó filtráció. Az $X(t)$ folyamatot Itô-folyamatnak nevezzük, ha felírható a következő alakban:

$$X(t) = X(0) + \int_0^t \mu(s) ds + \int_0^t \sigma(s) dB(s), \quad (33)$$

ahol $\mu(s)$ és $\sigma(s)$ adaptált sztochasztikus folyamatok, amelyek kielégítik a megfelelő integrálhatósági feltételeket, és $X(0)$ egy adott kezdeti érték.

Tekintsünk egy általános Itô-folyamatot $X(t)$ -t, amely kielégíti a következő SDE-t:

$$dX(t) = \mu(t) dt + \sigma(t) dB(t). \quad (34)$$

Ekkor az Itô–Doeblin-formula kiterjeszthető az $X(t)$ folyamatra is, és a következőképpen írható fel:

Tétel 3.2.7

[1] Legyen $X(t)$ egy Itô-folyamat, amely kielégíti a következő SDE-t:

$$dX(t) = \mu(t, X(t)) dt + \sigma(t, X(t)) dB(t), \quad (35)$$

és legyen $f(t, x) \in C^2([0, \infty) \times \mathbb{R})$. Ekkor az $Y(t) = f(t, X(t))$ folyamatra teljesül a következő egyenlőség:

$$dY(t) = \frac{\partial f(t, X(t))}{\partial t} dt + \frac{\partial f(t, X(t))}{\partial x} dX(t) + \frac{1}{2} \frac{\partial^2 f(t, X(t))}{\partial x^2} (dX(t))^2. \quad (36)$$

A fenti tételben a $(dX(t))^2$ kifejezés a következőképpen értelmezendő:

$$(dX(t))^2 = (\mu(t, X(t)) dt + \sigma(t, X(t)) dB(t))^2. \quad (37)$$

A következő egyenlőségek teljesülnek:

- $(dt)^2 = 0$,
- $dt dB(t) = 0$,
- $(dB(t))^2 = dt$.

Ezeket az eredményeket összevonva kapjuk, hogy

$$(dX(t))^2 = \sigma^2(t, X(t)) dt. \quad (38)$$

Ezt az eredményt visszahelyettesítve a tétel állításába kapjuk, hogy

$$dY(t) = \frac{\partial f(t, X(t))}{\partial t} dt + \frac{\partial f(t, X(t))}{\partial x} dX(t) + \frac{1}{2} \frac{\partial^2 f(t, X(t))}{\partial x^2} \sigma^2(t, X(t)) dt. \quad (39)$$

3.3 Geometriai Brown-mozgás

A pénzügyi modellezésben és más területeken, ahol a vizsgált mennyiségek (például árak vagy populációk mérete) nem vehetnek fel negatív értéket, és a növekedésük arányos a jelenlegi méretükkel, a leggyakrabban használt modell a geometriai Brown-mozgás (GBM).

Definíció 3.3.1

[1] Legyen $B(t)$ Brown-mozgás. Az $S(t)$ folyamatot geometriai Brown-mozgásnak nevezzük, ha kielégíti a következő sztochasztikus differenciálegyenletet:

$$dS(t) = \mu S(t) dt + \sigma S(t) dB(t), \quad (40)$$

ahol μ és σ konstansok.

A következő tétel megmutatja, hogy a geometriai Brown-mozgás explicit megoldással rendelkezik, amely egy exponenciális függvény formájában írható fel.

Tétel 3.3.2

[3] Legyen $S(t)$ egy geometriai Brown-mozgás, amely kielégíti a következő SDE-t:

$$dS(t) = \mu S(t) dt + \sigma S(t) dB(t), \quad (41)$$

ahol μ és σ konstansok. Ekkor az $S(t)$ folyamat explicit megoldása a következőképpen írható fel:

$$S(t) = S(0) \exp\left(\left(\mu - \frac{1}{2}\sigma^2\right)t + \sigma B(t)\right). \quad (42)$$

Bizonyítás. Legyen $Y(t) = \Phi(t, S(t)) = \ln(S(t))$. A parciális deriváltak a következők:

$$\frac{\partial \Phi(t, S)}{\partial S} = \frac{1}{S}, \quad \frac{\partial^2 \Phi(t, S)}{\partial S^2} = -\frac{1}{S^2}, \quad \frac{\partial \Phi(t, S)}{\partial t} = 0. \quad (43)$$

Ekkor az Itô–Doebelin-formula alkalmazásával kapjuk, hogy:

$$dY(t) = \left(\frac{\partial \Phi(t, S)}{\partial t} + \mu S(t) \frac{\partial \Phi(t, S)}{\partial S} + \frac{1}{2} \sigma^2 S^2(t) \frac{\partial^2 \Phi(t, S)}{\partial S^2} \right) dt + \sigma S(t) \frac{\partial \Phi(t, S)}{\partial S} dB(t). \quad (44)$$

Ebbe a parciális deriváltak értékét behelyettesítve kapjuk, hogy

$$dY(t) = \left(\mu - \frac{1}{2}\sigma^2 \right) dt + \sigma dB(t). \quad (45)$$

Integrálva ezt az egyenletet 0 és t között kapjuk, hogy:

$$Y(t) = Y_0 + \int_0^t \left(\mu - \frac{1}{2}\sigma^2 \right) ds + \int_0^t \sigma dB, \quad (46)$$

$$Y(t) = Y_0 + \left(\mu - \frac{1}{2}\sigma^2 \right)t + \sigma B(t). \quad (47)$$

Visszahelyettesítve $Y(t) = \ln(S(t))$, kapjuk az $S(t)$ folyamat explicit megoldását:

$$\ln(S(t)) = \ln(S(0)) + \left(\mu - \frac{1}{2}\sigma^2 \right)t + \sigma B(t), \quad (48)$$

$$S(t) = S(0) \exp\left(\left(\mu - \frac{1}{2}\sigma^2 \right)t + \sigma B(t) \right). \quad (49)$$

■

Mivel $\ln S(t)$ normális eloszlású, ezért a geometriai Brown-mozgás eloszlásáról a következő állítás tehető:

Állítás 3.3.3

[3] A geometriai Brown-mozgás $S(t)$ minden $t > 0$ esetén lognormális eloszlású.

Állítás 3.3.4

[3] Legyen $S(t)$ egy geometriai Brown-mozgás, amely kielégíti a következő SDE-t:

$$dS(t) = \mu S(t) dt + \sigma S(t) dB(t), \quad (50)$$

ahol μ és σ konstansok. Ekkor az $S(t)$ folyamat várható értéke a következőképpen írható fel:

$$E[S(t)] = S(0) \exp(\mu t). \quad (51)$$

Bizonyítás. Az $S(t)$ folyamat explicit megoldása a következőképpen írható fel:

$$S(t) = S(0) \exp\left(\left(\mu - \frac{1}{2}\sigma^2 \right)t + \sigma B(t) \right). \quad (52)$$

Mivel $B(t)$ normális eloszlású, ezért $\sigma B(t)$ is normális eloszlású, 0 várható értékkel és $\sigma^2 t$ szórásnegyzettel. Ezért a következő egyenlőség teljesül:

$$E[\exp(\sigma B(t))] = \exp\left(\frac{1}{2}\sigma^2 t \right). \quad (53)$$

Ezt az eredményt felhasználva kapjuk, hogy

$$E[S(t)] = S(0) \exp\left(\left(\mu - \frac{1}{2}\sigma^2 \right)t \right) E[\exp(\sigma B(t))] = S(0) \exp(\mu t). \quad (54)$$

Állítás 3.3.5

[3] Legyen $S(t)$ egy geometriai Brown-mozgás, amely kielégíti a következő SDE-t:

$$dS(t) = \mu S(t) dt + \sigma S(t) dB(t), \quad (55)$$

ahol μ és σ konstansok. Ekkor az $S(t)$ folyamat varianciája a következőképpen írható fel:

$$\text{Var}[S(t)] = S^2(0) \exp(2\mu t) (\exp(\sigma^2 t) - 1). \quad (56)$$

Bizonyítás. A második momentum kiszámításához felhasználjuk a 42. egyenlet szerinti $S(t)$ explicit megoldást:

$$S^2(t) = S^2(0) \exp\left(2\left(\mu - \frac{1}{2}\sigma^2\right)t + 2\sigma B(t)\right). \quad (57)$$

Ekkor:

$$E[S^2(t)] = S^2(0) \exp\left(2\left(\mu - \frac{1}{2}\sigma^2\right)t\right) E[\exp(2\sigma B(t))]. \quad (58)$$

Mivel $2\sigma B(t)$ normális eloszlású, 0 várható értékkel és $4\sigma^2 t$ szórásnégyzettel, ezért

$$E[\exp(2\sigma B(t))] = \exp(2\sigma^2 t). \quad (59)$$

Ezt felhasználva kapjuk, hogy

$$\begin{aligned} E[S^2(t)] &= S^2(0) \exp\left(2\left(\mu - \frac{1}{2}\sigma^2\right)t\right) E[\exp(2\sigma B(t))] = \\ &= S^2(0) \exp(2\mu t + \sigma^2 t). \end{aligned} \quad (60)$$

A variancia definíciója szerint:

$$\begin{aligned} \text{Var}[S(t)] &= E[S^2(t)] - (E[S(t)])^2 = \\ &= S^2(0) \exp(2\mu t + \sigma^2 t) - (S(0) \exp(\mu t))^2 = \\ &= S^2(0) \exp(2\mu t) (\exp(\sigma^2 t) - 1). \end{aligned} \quad (61)$$

4 A gépi tanulás elméleti háttére

A gépi tanulás fontos szerepet játszik a tudomány, a gazdaság és a technológia számos területén. Például az orvostudományban a gépi tanulás segíthet a betegségek korai felismerésében és betegségekkel járó kockázatok azonosításában. A pénzügyi szektorban a gépi tanulás alkalmazható a kockázatkezelésben, a csalásfelderítésben és a kereskedési stratégiák optimalizálásában.

A gépi tanulás lehetővé teszi a nagy adathalmazok elemzését és a mintázatok felismerését ezért bűnügyi adatok elemzésére is használható, például a bűnözési mintázatok felismerésére és bűnügyi előrejelzések készítésére.

4.1 A gépi tanulás alapjai

A gépi tanulás algoritmusait három fő csoportba sorolhatjuk:

- Felügyelt tanulás: ahol a modell egy címkézett adathalmazon tanul, azaz minden bemeneti adathoz (X) tartozik egy kimeneti címke (y). A modell célja, egy olyan függvény megtanulása, amely képes egy új, ismeretlen bemeneti adat (X) alapján helyesen megjósolni a hozzá tartozó kimeneti címkét (y).
- Felügyelet nélküli tanulás: ahol a modell egy címkézetlen adathalmazon tanul, azaz csak bemeneti adatok (X) állnak rendelkezésre, de nincs hozzájuk tartozó kimeneti címke (y). A modell célja, hogy feltárja az adat szerkezetét, megtalálja a rejtett mintázatokat.
- Megerősítéses tanulás: ahol a modell egy környezetben tanul, és a tanulási folyamat során visszajelzést kap a környezettől, amely alapján maximalizálni igyekszik egy célfüggvényt.

A szakdolgozat keretein belül elsősorban a felügyelt tanulás alapjaival foglalkozunk, különös tekintettel a regressziós problémákra, ahol a cél egy folytonos kimeneti érték előrejelzése.

A felügyelt tanulás esetén formálisan a következőképpen tekinthetünk az adatra:

$$D = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}. \quad (62)$$

ahol $x_i \in \mathbb{R}$ a bemeneti változókat tartalmazó vektor és $y_i \in \mathbb{R}$ a hozzá tartozó célváltozó értéke. A statisztikai tanulási modell általános alakja a következőképpen írható fel:

$$Y = f(X) + \varepsilon, \quad (63)$$

ahol f az ismeretlen függvény, amit becsülni szeretnénk, míg ε egy véletlen zaj, amely a modell hibáját reprezentálja és független a bemeneti változóktól. Továbbá feltételezzük, hogy $E[\varepsilon] = 0$.

Két fő kérdésre keresünk választ a gépi tanulás során:

- Egy új bemeneti adat (x) esetén mennyi lesz a célváltozó (y) értéke?
Ez a predikciós kérdés. Ebben az esetben a függvény úgynevezett „fekete doboz” modellként működik, ahol nem a függvény pontos alakja a lényeg, hanem a predikciós teljesítménye. Az előrejelzés pontossága két hibatenyezőtől függ, egy csökkenthető hibától, amely a függvény becslésének pontosságából adódik, és egy nem csökkenthető hibától, amely egy felső korlátot szab az előrejelzés pontosságának.
- Hogyan befolyásolja a bemeneti változó (X) értéke a célváltozó (Y) értékét?
Ez a magyarázó kérdés. Vizsgálhatjuk, hogy a bemeneti változók közül melyik az néhány legfontosabb, amely a legnagyobb hatással van a célváltozó értékére. Ilyenkor a függvény pontos alakja is fontos, nem viselkedhet „fekete doboz” modellként.


A változóknak két fő típusát különböztetjük meg, lehetnek kvalitatív (minőségi) vagy kvantitatív (mennyiségi) változók. A kvalitatív változók kategóriákba, osztályokba sorolhatóak, például a nem, a szín vagy a márka. Ezzel szemben a kvantitatív változók számszerű értékeket vesznek fel, ilyen például a magasság, a súly vagy az ár. A célváltozó típusa alapján a gépi tanulási problémák lehetnek klasszifikációs vagy regressziós problémák. Klasszifikáció esetén a célváltozó kvalitatív, és a modell célja, hogy egy adott bemeneti adat alapján megállapítsa a hozzá tartozó kategóriát. Regresszió esetén a célváltozó kvantitatív, és a modell célja, hogy egy adott bemeneti adat alapján megjósolja a hozzá tartozó számértéket. A határvonal a klasszifikációs és regressziós módszerek között azonban nem mindig éles. A legkisebb négyzetek módszerét mennyiségi meghatározásra használjuk, a logisztikus regressziót pedig kvalitatív meghatározásra, de a KNN (K-Nearest Neighbors) algoritmust, a döntési fákat mind a két probléma esetén használhatjuk.

Mindkét probléma esetén fontos vizsgálni a modell teljesítményét, hibáját. A várható hiba egy x_0 pontban a következőképpen írható fel:

$$\begin{aligned}
 E\left[\left(y_0 - \hat{f}(x_0)\right)^2\right] &= E\left[\left(f(x_0) + \varepsilon - \hat{f}(x_0)\right)^2\right] = \\
 E\left[\left(f(x_0) - \hat{f}(x_0)\right)^2 + \varepsilon^2 + 2\left(f(x_0) - \hat{f}(x_0)\right)\varepsilon\right] &= \\
 E\left[\left(f(x_0) - \hat{f}(x_0)\right)^2\right] + E[\varepsilon^2] + 2E\left[\left(f(x_0) - \hat{f}(x_0)\right)\varepsilon\right] &= \quad (64) \\
 E\left[\left(f(x_0) - \hat{f}(x_0)\right)^2\right] + \text{Var}[\varepsilon] + 2E[\varepsilon]E\left[f(x_0) - \hat{f}(x_0)\right] &= \\
 E\left[\left(f(x_0) - E[\hat{f}(x_0)] + E[\hat{f}(x_0)] - \hat{f}(x_0)\right)^2\right] + \text{Var}[\varepsilon] &= \\
 E\left[\left(f(x_0) - E[\hat{f}(x_0)]\right)^2\right] + E\left[\left(E[\hat{f}(x_0)] - \hat{f}(x_0)\right)^2\right] + \text{Var}[\varepsilon] &= \\
 \left(E[\hat{f}(x_0)] - f(x_0)\right)^2 + \text{Var}[\hat{f}(x_0)] + \text{Var}[\varepsilon] &
 \end{aligned}$$

ahol $\hat{f}(x_0)$ a modell által adott előrejelzés, $f(x_0)$ a valódi értéke, és ε a nem csökkenthető hiba. Tehát a várható hiba három összetevőből épül fel: a becslés varianciájából ($\text{Var}[\hat{f}(x_0)]$), a becslés torzításának négyzetéből ($\left(E[\hat{f}(x_0)] - f(x_0)\right)^2$) és a hibatag varianciájából ($\text{Var}[\varepsilon]$).

Ahhoz, hogy a várható hiba értékét minimalizáljuk, olyan módszert kell választanunk, amely egyszerre biztosít alacsony variációt és alacsony torzítást. A variancia azt mutatja meg, hogy a modell előrejelzése mennyire érzékeny a tanító adathalmaz változásaira. Általában elmondható, hogy a komplexebb modellek nagyobb variációval rendelkeznek. A torzítás pedig abból fakad, hogy a modell nem képes pontosan megragadni a valódi függvény alakját, ez akkor fordulhat elő ha egy bonyolult problémát egy egyszerűbb modellel közelítünk. Például ha a változók közötti kapcsolat erősen nemlineáris, de egy lineáris modellt használunk, akkor a modell torzított lesz. Általában a kevésbé komplex modellek nagyobb torzítással rendelkeznek. Tehát láthatjuk, hogy a modell komplexitásának növelése csökkenti a torzítást, de növeli a variációt. Ez az úgynevezett torzítás-variancia kompromisszum (bias-variance tradeoff).



1. Ábra: Torzítás-variancia kompromisszum illusztrációja


Az 1. Ábra alapján látható, hogy a modell komplexitásának növelésével a torzítás csökken, de a variancia nő. Az ábrán is látható, hogy kezdetben a modell komplexitásának növelésével a torzítás gyorsabban csökken, mint ahogy a variancia nő, így a teljes hiba csökken. Azonban egy bizonyos pont után a variancia növekedése gyorsabb lesz, mint a torzítás csökkenése, így a teljes hiba növekedni kezd. Az optimális pont ott van, ahol a teljes hiba minimális. Valós helyzetben, mivel a valódi függvény nem ismert, nem tudjuk explicit módon kiszámolni a torzítást és a variációt, ezért gyakran keresztvalidációs módszereket alkalmazunk a modell teljesítményének értékelésére.

Ahhoz, hogy kiértékeljük egy modell teljesítményét, szükségünk van egy mérőszámra, amely megmutatja, hogy a modell mennyire jól teljesít a tanító adathalmazon vagy egy új, ismeretlen adathalmazon. A regressziós problémák esetén a leggyakrabban használt mérőszámok közé tartozik az átlagos négyzetes hiba (MSE):

$$\text{MSE} = \sum_{i=1}^n \frac{(y_i - \hat{f}(x_i))^2}{n} \quad (65)$$

ahol y_i a valódi érték, $\hat{f}(x_i)$ a modell által adott előrejelzés, és n a minta mérete. Minél kisebb az MSE értéke, annál jobb a modell teljesítménye. Ezt az értéket a tanító adatra tudjuk kiszámolni, de a modell választásánál az új, ismeretlen adatokon való teljesítmény a fontosabb. Mivel a tanító adaton való teljesítmény nem feltétlenül tükrözi az új adatokon való teljesítményt, nem választhatjuk a legkisebb MSE-vel rendelkező módszert. Sőt, ha a tanító adaton túl jól teljesít egy módszer, akkor fennáll a veszélye annak, hogy a modell túltanult (overfitting), vagyis a modell nemcsak a valódi mintázatot tanulta meg, hanem a tanító adathalmaz zaját is, így az új adatokon való teljesítménye gyenge lesz.

Tehát ebben az esetben is fennáll a torzítás-variancia kompromisszum esetéhez hasonló összefüggés: a modell komplexitásának növelésével a tanító adaton az MSE monoton csökken, azonban a teszt adaton az MSE egy bizonyos pont után növekedni kezd, mivel a modell túltanul. (2. Ábra)




2. Ábra: Túllillesztés illusztrációja

A gyakorlatban a tanító adaton az MSE értékét meg tudjuk határozni, de a teszt adaton az MSE értékét nem, mivel a teszt adaton a valódi értékek nem ismertek. A minimumpont meghatározására a gyakorlatban az egyik legelterjedtebb módszer a keresztvalidáció, amely során a tanító adatot több részre osztjuk, és a modell teljesítményét ezekre a részekre értékeljük. Ez lehetővé teszi, hogy becslést kapjunk a modell új adatokon való teljesítményére, és segítséget nyújt a megfelelő modell komplexitásának kiválasztásában.

4.2 Döntési fák

A fa-alapú módszerek egy jelentős és széles körben használt osztálya a gépi tanulási algoritmusoknak. Ezek a módszerek könnyen értelmezhető modelleket hoznak létre, amelyek jól teljesítenek mind klasszifikációs, mind regressziós problémák esetén. Ezek a módszerek a bemeneti változók terét egyszerű, jellemzően téglalap alakú régiókra osztják fel, rétegzik azokat. Ha egy új megfigyelést szeretnénk osztályozni vagy a hozzá tartozó értéket előrejelezni, akkor a modell megvizsgálja, hogy a megfigyelés melyik régióba esik, és a régióba eső tanuló adatok között előforduló leggyakoribb osztályt vagy a régióba eső tanuló adatok átlagát használja a predikcióhoz. A modell struktúrája:


- Gyökércsomópont: A legfelső szint, ami a teljes adatot reprezentálja.
- Belső csomópontok: Egy-egy bemeneti változó (feature) alapján végzett döntést reprezentálnak, amelyek az adatot két vagy több részre osztják.
- Élek: A tesztek eredményét reprezentálják, amelyek a bemeneti változó értékétől függően vezetnek a következő csomóponthoz.
- Levélcsomópontok: Az osztályokat vagy a regressziós értékeket reprezentálják, amelyek a modell végső döntését adják meg.



3. Ábra: Döntési fa példa

A 3. Ábra egy döntési fa példáját mutatja be: lakások árát becsüli meg különböző jellemzők alapján. A döntési fa struktúrája a következő:

- A gyökércsomópontban az elhelyezkedés szerepel, ez a döntési folyamat kiindulópontja. A modell a tanítás során ezt a változót találta a legfontosabbnak, ez bontja fel legjobban az adatokat.
- Élek: A lehetséges állapotokat jelölik.
- Belső csomópontok: Ha az „elhelyezkedés” értéke alapján nem tudunk dönteni, további változókat kell vizsgálnunk. Például, ha a lakás a belvárosban helyezkedik el, akkor a következő változó, amit megvizsgálunk, a „Méret”.
- Levélcsomópontok: Ezek a végső döntéseket jelölik, például ha a lakás a belvárosban helyezkedik el és a mérete „Nagy”, akkor a modell szerint a lakás ára 95 millió forint.



4. Ábra: A bemeneti tér régiókra bontása a regressziós döntési fa szerint.

A 4. Ábra a regressziós döntési fa által létrehozott régiókat szemlélteti. Minden színezett tartomány egy levélcsomópontnak felel meg, és az ott szereplő szám az adott régióhoz rendelt becsült célérték.

4.2.1 A döntési fák tanítása

A fák építése mind a klasszifikációs, mind a regressziós problémák esetében rekurzív módon történik. A fák építése „mohó” módon történik, felülről lefelé haladva választjuk ki a legjobb vágást, amely az adott pillanatban a legjobban szétválasztja az adatokat. A legjobb vágás kiválasztásához különböző mérőszámokat használunk, ezek a következők lehetnek:

- *Gini-index*: Klasszifikációs problémák esetén használjuk. Azt méri, hogy mekkora eséllyel osztályoznánk félre egy véletlenszerűen kiválasztott elemet, ha a részhalmaz eloszlása alapján osztályoznánk. Minél kisebb a Gini-index, annál tisztább a részhalmaz.

$$G(m) = \sum_{k=1}^K p_{mk}(1 - p_{mk}) = 1 - \sum_{k=1}^K p_{mk}^2, \quad (66)$$

ahol p_{mk} a k -adik osztályba tartozó elemek aránya a m -edik részhalmazban.

- *Entrópia*: Szintén klasszifikációs problémák esetén használjuk. Azt méri, hogy mekkora információt nyerünk egy adott vágással. Minél nagyobb az entrópia csökkenése, annál jobb a vágás.

$$H(m) = - \sum_{k=1}^K p_{mk} \log(p_{mk}), \quad (67)$$

ahol p_{mk} a k -adik osztályba tartozó elemek aránya a m -edik részhalmazban.

- *Négyzetes hiba*: Regressziós problémák esetén használjuk. Azt mérjük, hogy a vágás utáni részhalmazban mekkora az a tényleges válaszértékek és a részhalmaz átlaga közötti eltérések négyzetösszege. Minél kisebb ez az érték, annál jobb a vágás.

$$\text{MSE}(m) = \frac{1}{n_m} \sum_{i=1}^m (y_i - \hat{y}_m)^2, \quad (68)$$

ahol n_m a m -edik részhalmazban lévő elemek száma, y_i a tényleges válaszérték, és $\hat{y}_m$ a részhalmaz átlaga.

A döntési fák esetén ügyelni kell arra, hogy a fa ne nőjön túl mélyre, mert ez túltanuláshoz vezethet. Erre megoldás lehet a fa vágása (pruning). Kétfő vágási módszert alkalmaznak a gyakorlatban:

- *Előmetés (prepruning)*: A fa építése során már a vágás kiválasztásánál figyelembe vesszük a vágás utáni részhalmazok méretét, és csak akkor hajtjuk végre a vágást, ha a részhalmazok mérete egy bizonyos küszöbérték fölött van.
- *Utólagos metés (postpruning)*: Először egy teljes fát építünk, majd utólagosan, alulról felfelé haladva metszük vissza a fát.


4.3 Ensemble módszerek

Az ensemble módszerek használata során több gyenge modellt kombinálunk egy erősebb modell létrehozásához. Két fő típusát különböztetjük meg:

- *Bagging*: A bagging során a tanító adatból bootstrap (visszatevéses mintavétellel) több új adathalmazt hozunk létre, majd mindegyiket tanítunk egy gyenge modellt (például egy metszés nélküli döntési fát). Majd egyesítjük a modellek előrejelzéseit, klasszifikáció esetén többségi szavazással, regresszió esetén pedig átlagolással. Mivel egy mély fának alacsony a torzítása, de magas a varianciája, ezért a bagging segítségével csökkenthetjük a varianciát anélkül, hogy a torzítást növelnénk.
- *Boosting*: Míg a bagging egymástól függetlenül, párhuzamosan épít fákat, addig a boosting során szekvenciálisan építjük a fákat. Minden új fa a korábbi fák információit használja fel és a korábbi fák által helytelenül osztályozott vagy előrejelzett megfigyelésekre helyezi a hangsúlyt, azaz ezeket a megfigyeléseket nagyobb súllyal veszi figyelembe a tanítás során.

4.3.1 Random Forest

Ensemble módszer, amely a bagging elvén alapul és nagyszámú, egymástól független döntési fát épít. A módszer regressziós és klasszifikációs problémák esetén is használható. A Random Forest során minden egyes fa építésekor a változók egy véletlenszerű részhalmazát választjuk ki, és csak ezek közül választjuk ki a legjobb vágást. (5. Ábra)



5. Ábra: Random Forest módszer vázlatos ábrája

Minden fát a lehető legnagyobbra növesztünk, azaz metszés nélkül építjük. A bagging esetében előfordulhat, hogyha van egy nagyon erős változó, akkor a tanított fák közül sok ezt az erős változót fogja választani a legelső vágáshoz, így a fák hasonlóak lesznek egymáshoz, nem lesznek függetlenek, így a variancia csökkentése sem lesz olyan hatékony. A Random Forest esetében viszont csak csak egy véletlen m elemű részhalmazt választunk a p változóból, így

a vágások $\frac{p-m}{p}$ arányában a legerősebb változó nem lesz kiválasztva, így a fák nagyobb mértékben lesznek különbözőek és függetlenek, így a variancia csökkentése is hatékonyabb lesz. A modell hiperparaméterei közé tartozik a minimális csomópontok száma és a változókból kiválasztott részhalmaz mérete. Az m paraméter értékét gyakran a gyakorlatban $\sqrt{p}$ -re (klasszifikációs problémák esetén) vagy $\frac{p}{3}$ -ra (regressziós problémák esetén) állítják be, de ez a probléma jellegétől függően változhat. A minimális csomópontok számát klasszifikációs problémák esetén gyakran 1-re, regressziós problémák esetén pedig 5-re állítják be, de ez is a probléma jellegétől függően változhat. A Random Forest módszer nagy előnye, hogy nem érzékeny a fák számára, így általában a nagy számú fa építése nem vezet túltanuláshoz, ahogy egyre több fát adunk a modellhez, a hibaartás csökken, és egy bizonyos pont után stabilizálódik.

Random Forest esetén, mivel minden fa egy bootstrap mintán tanul, a tanító adathalmaz körülbelül egyharmada minden fa esetében kimarad a tanításból, ezeket a kimaradt pontokat nevezzük out-of-bag (OOB) pontoknak. Ezt felhasználva a modell teljesítményét is értékelhetjük, anélkül, hogy külön teszt adathalmazt kellene fenntartanunk. A hibabecsléshez minden egyes megfigyelés esetén kiszámoljuk a fák előrejelzését, amelyek nem tanultak az adott megfigyelésen (azaz azok a fák, amelyeknél az adott megfigyelés OOB pont), majd ezeket az előrejelzéseket átlagoljuk (regresszió esetén) vagy többségi szavazással egyesítjük (klasszifikáció esetén), és összehasonlítjuk a valódi értékekkel. A hagyományos döntési fákkal szemben a Random Forest kevésbé átlátható, de többféle mutatóval is értékelhetjük a változók fontosságát, például a csomópontok tisztaságának növekedése alapján, vagy az OOB hibabecslés alapján, amely megmutatja, hogy egy adott változó kizárása hogyan befolyásolja a modell teljesítményét.

4.4 Idősorok elemzése

Idősornak tekinthetünk minden olyan adatot, amelyet időpontokhoz rendelünk és a megfigyelések között időbeli függés van, például a bűnügyi statisztikák is jellemzően idősorok. Az idősorok elemzése olyan módszereket foglal magában, amelyekkel az adatokból mintázatokat, trendeket lehet felismerni, valamint előrejelzéseket készíthetünk. Az idősorok elemzésének két fő célja van: a múltbeli adatok megértése és a jövőbeli értékek előrejelzése. Az idősorok egyik legfontosabb jellemzője, hogy az egymást követő megfigyelések nem függetlenek. Ez a függőség lehet rövid távú, amikor a közelmúlt megfigyelései befolyásolják a jövőbeli értékeket, vagy hosszútávú, amikor trendek vagy szezonális mintázatok figyelhetők meg az adatokban. Akkor beszélhetünk trendről, ha az adatokban hosszú távú növekedés vagy csökkenés figyelhető meg, míg szezonális mintázat esetében az adatsort valamilyen ismétlődő ciklus jellemzi, például éves, havi vagy heti szinten. Ezek alapján az idősorok több, egymástól független komponensből állhatnak, tehát egy Y_t idősor felírható a következőképpen:

$$Y_t = f(S_t, T_t, \varepsilon_t) \quad (69)$$

ahol S_t a szezonális komponens, T_t a trendkomponens, és ε_t a maradéktag.

4.4.1 Alapfogalmak

Definíció 4.4.1.1

Egy idősor kovarianciája a következőképpen definiálható:

$$\text{Cov}(X_t, X_{t+k}) = E[(X_t - E[X_t])(X_{t+k} - E[X_{t+k}])], \quad (70)$$

ahol X_t az idősor t -edik megfigyelése, $E[X_t]$ az idősor t -edik megfigyelésének várható értéke, és k a késleltetés (lag) értéke.

Definíció 4.4.1.2

Egy idősor autokovarianciája a következőképpen definiálható: $\gamma(h) = \text{Cov}(X_t, X_{t+h})$, ahol X_t az idősor t -edik megfigyelése, és h a késleltetés (lag) értéke.

Definíció 4.4.1.3

Egy idősor autokorrelációja a következőképpen definiálható: $\rho(h) = \frac{\gamma(h)}{\gamma(0)}$,

Definíció 4.4.1.4

Egy idősor gyengén stacionáris, ha teljesül az alábbi három feltétel:

1. Az idősor várható értéke időben állandó, azaz $E[X_t] = \mu$ minden t -re.
2. $E[X_t^2] < \infty$ minden t -re.
3. Két megfigyelés közötti kovariancia csak a köztük lévő időkülönbségtől (h) függ és nem a konkrét t időponttól, azaz $\text{Cov}(X_t, X_{t+h}) = \gamma(h)$.

Definíció 4.4.1.5

Egy idősor erősen stacionáris, ha minden h és minden $t_1, t_2, \dots, t_n$ esetén teljesül, hogy $(X_{t_1}, X_{t_2}, \dots, X_{t_n})$ és $(X_{t_1+h}, X_{t_2+h}, \dots, X_{t_n+h})$ azonos eloszlásúak.

A (gyenge) stacionaritás fontos fogalom az idősoelemzésben, mivel a legtöbb klasszikus idősoelemzési módszer feltételezi, hogy az idősor (gyengén)stacionáris. A stacionaritás azt jelenti, hogy az idősor statisztikai tulajdonságai időben állandóak, így a múltbeli adatok alapján megbízhatóan előrejelezhetjük a jövőbeli értékeket.

4.4.2 Klasszikus idősorelemzési módszerek

A klasszikus idősorelemzési módszereket két nagy csoportra oszthatjuk: determinisztikus és sztochasztikus módszerekre.

4.4.2.1 Determinisztikus és simítási módszerek

Ezek a módszerek az adatokban lévő véltlen ingadozás kiszűrésére, a mögöttes trendek és szezonális mintázatok kiemelésére szolgálnak. Ezek a módszerek olyan rekurzív becslésnek tekinthetők, amely során a múltbeli megfigyelések egy súlyozott kombinációját használjuk a jövőbeli érték becslésére. A súlyok meghatározása alapján különböző simítási módszereket különböztetünk meg:

- **Egyszerű exponenciális simítás:** Olyan idősorok esetén használjuk, amelyekben nincs trend vagy szezonális mintázat. A módszer lényege, hogy a jövőbeli értéket a múltbeli értékek súlyozott átlagaként becsljük, ahol a súlyok exponenciálisan csökkennek a múltbeli értékekre vonatkozóan. Az alapegyenlete a következőképpen írható fel:

$$\hat{Y}_{t+1} = \alpha Y_t + (1 - \alpha) \hat{Y}_t, \quad (71)$$

ahol α a simítási paraméter, amely értéke 0 és 1 között van, Y_t az idősor t -edik megfigyelése, és $\hat{Y}_t$ a t -edik időpontban becsült érték. Ebből megmutatható:

$$\hat{Y}_{t+1} = \alpha \sum_{h=0}^{\infty} (1 - \alpha)^h Y_{t-h} \quad (72)$$

- **Holt-Winters módszer:** Olyan idősorok esetén használjuk, amelyekben trend és/vagy szezonális mintázat is megfigyelhető. A módszer három egyenletből áll, amelyek a szint, a trend és a szezonális komponens becslésére szolgálnak. A három egyenlet a következőképpen írható fel:

$$\ell_t = \alpha(Y_t - s_{t-m}) + (1 - \alpha)(\ell_{t-1} + b_{t-1}), \quad (73)$$

$$b_t = \beta(\ell_t - \ell_{t-1}) + (1 - \beta)b_{t-1}, \quad (74)$$

$$s_t = \gamma(Y_t - \ell_t) + (1 - \gamma)s_{t-m}, \quad (75)$$

ahol ℓ_t a szint becslése, b_t a trend becslése, s_t a szezonális komponens becslése, α , β és γ a simítási paraméterek, amelyek értéke 0 és 1 között van, Y_t az idősor t -edik megfigyelése, és m a szezon hossza. Ekkor az előrejelzés az $t + h$ időpontban a következőképpen számítható:

$$\hat{Y}_{t+h} = \ell_t + hb_t + s_{t+h-m}, \quad (76)$$

ahol h a előrejelzés időtávja.

4.4.2.2 Sztochasztikus módszerek

A klasszikus sztochasztikus megközelítés alapját a Box-Jenkins módszertan képezi, amely az autoregresszív és mozgóátlag modellekre épül. Ezek a modellek nemcsak a determinista komponenseket, hanem a véletlen ingadozásokat is modellezik. Ezek a módszerek feltételezik, hogy az idősor stacionáris, így gyakran szükséges az idősor differenciálása a stacionaritás eléréséhez.

- **Autoregresszív (AR) modellek:** Az AR modellekbe a jövőbeli értékek a múltbeli értékek lineáris kombinációjaként áll elő:

$$Y_t = c + \sum_{i=1}^p \varphi_i Y_{t-i} + \varepsilon_t, \quad (77)$$

ahol Y_t az idősor t -edik megfigyelése, c egy konstans, φ_i az autoregresszív paraméterek, p az autoregresszív rend, és ε_t a hiba.

- **Mozgóátlag (MA) modellek:** Az MA modellek, szemben a determinisztikus mozgóátlag modellekkel, azt feltételezik, hogy a jövőbeli értékek nem a múltbeli tényleges értékektől, hanem a múltbeli előrejelzések hibáitól függenek:

$$Y_t = c + \sum_{i=1}^q \theta_i \varepsilon_{t-i} + \varepsilon_t, \quad (78)$$

ahol Y_t az idősor t -edik megfigyelése, c egy konstans, θ_i a mozgóátlag paraméterek, q a mozgóátlag rend, és ε_t a hiba.

- **ARMA és ARIMA modellek:** Ezek a modellek az AR és MA modellek kombinációi, az ARMA(p,q) modellt stacionárius idősorokra alkalmazzuk, míg az ARIMA(p,d,q) modell alkalmas nem stacionárius idősorokra is, ebben az esetben differenciálás segítségével érjük el a stacionaritást. A ARMA(p,q) modell a következőképpen írható fel:

$$Y_t = c + \sum_{i=1}^p \varphi_i Y_{t-i} + \sum_{j=1}^q \theta_j \varepsilon_{t-j} + \varepsilon_t, \quad (79)$$

ahol Y_t az idősor t -edik megfigyelése, c egy konstans, φ_i az autoregresszív paraméterek, θ_j a mozgóátlag paraméterek, p az autoregresszív rend, q a mozgóátlag rend, és ε_t a hiba. Az ARIMA modell esetén alkalmazott differenciálás:

$$\Delta Y_t = Y_t - Y_{t-1}, \quad (80)$$

Majd ezekre a differenciált értékekre alkalmazzuk az ARMA modellt, tehát d -edik rendű differenciálás esetén:

$$\Delta^d Y_t = c + \sum_{i=1}^p \varphi_i \Delta^d Y_{t-i} + \sum_{j=1}^q \theta_j \varepsilon_{t-j} + \varepsilon_t, \quad (81)$$

ahol $\Delta^d Y_t$ a d -edik rendű differenciált idősor t -edik megfigyelése.

A szezonális modellezésére a SARIMA modellt használjuk, amely az ARIMA modell kiterjesztése, és a szezonális komponenseket is figyelembe veszi. Amennyiben más, külső tényezőket is szeretnénk figyelembe venni az előrejelzés során, akkor az ARIMAX modellt használhatjuk, azonban ez csak akkor alkalmazható, ha lineáris kapcsolat van a külső tényezők és az idősor között, ami a gyakorlatban sokszor nem teljesül.

4.4.3 Gépi tanulási és mélytanulási módszerek idősorok elemzésére

Ahogy azt korábban láttuk a klasszikus idősor elemzési módszerek sok előfeltételezéssel élnek az adatokra vonatkozóan, például a stacionaritás feltételezése, valamint a lineáris kapcsolat feltételezése a külső tényezők és az idősor között. Ezek a feltételezések gyakran nem teljesülnek a valós adatok esetében, így ezek a módszerek nem mindig nyújtanak jó előrejelzéseket. Ezzel szemben a gépi tanulási (Machine Learning, ML) és mély tanulási (Deep Learning, DL) módszerek rugalmasabbak, képesek komplex, nemlineáris összefüggések modellezésére is. A gépi tanulási módszerek alkalmazásához az idősorokat általában felügyelt tanítási problémává alakítjuk, ahol a célváltozó a jövőbeli érték, a bemeneti változók pedig a múltbeli értékek és a külső tényezők:

$$Y_t = f(X_t) + \varepsilon_t, \quad (82)$$

ahol Y_t a jövőbeli érték, X_t a bemeneti változók, f a modell, és ε_t a hiba. A gépi tanulási módszerek (például a döntési fák, Random Forest, Gradient Boosting, Support Vector Machines) általában nem tudják értelmezni az idősorok időbeli függését, így új változókat kell bevezetni, amelyek kifejezik a múltbeli értékek hatását a jövőbeli értékekre, ilyen változók lehetnek például:

- *Késleltetett (Lag) változók*: Ezek a múltbeli értékek, például $Y_{t-1}, Y_{t-2}, \dots, Y_{t-p}$, ahol p a késleltetés rendje.
- *Mozgóátlag változók*: Ezek a múltbeli értékek átlagai, például $MA_p = \frac{Y_{t-1} + Y_{t-2} + \dots + Y_{t-p}}{p}$, ahol p a mozgóátlag rendje.

A gépi tanulási módszerek nagy előnye a klasszikus módszerekkel szemben, hogy képesek a nemlineáris összefüggések modellezésére, illetve képesek a változók közötti kölcsönhatások figyelembevételére is. A gépi tanulási módszerekkel szemben a mélytanulási módszerek képesek megragadni az adatok időbeliségét is, például a Recurrent Neural Networks (RNN) és a Long Short-Term Memory (LSTM) hálózatok.

- *Recurrent Neural Networks (RNN)*: Olyan neurális hálózatok, amelyek képesek az adatok időbeli függését modellezni egy belső, rekurzív állapot (h_t) segítségével:

$$h_t = \sigma(W_h h_{t-1} + W_x X_t + b), \quad (83)$$

ahol h_t a rekurzív állapot a t -edik időpontban, W_h és W_x a súlyok, b a torzítás (bias), és σ egy aktivációs függvény.

- *Long Short-Term Memory (LSTM) hálózatok*: Olyan RNN-ek, amelyek képesek hosszú távú függőségek modellezésére is, egy speciális cella struktúrával, amely három kaput tartalmaz: a bemeneti kaput, a kimeneti kaput és a felejtési kaput. Ezek a kapuk szabályozzák az információ áramlását a cellában, így lehetővé téve a hosszú távú függőségek megragadását is.

$$i_t = \sigma(W_i[h_{t-1}, X_t] + b_i), \quad (84)$$

$$o_t = \sigma(W_o[h_{t-1}, X_t] + b_o), \quad (85)$$

$$f_t = \sigma(W_f[h_{t-1}, X_t] + b_f), \quad (86)$$

Bár a mélytanulási módszerek rendelkeznek a legnagyobb kapacitással, gyakran nagy mennyiségű adatot és számítási erőforrást igényelnek a tanításhoz és black-box jellegük miatt az eredmények értelmezése is nehéz lehet. Ezzel szemben a gépi tanulási módszerek gyakran jó kompromisszumot jelentenek, nem igénylik a klasszikus módszerek szigorú előfeltételezéseit és alkalmazásukhoz nem szükséges annyi adat és számítási erőforrás, mint a mélytanulási módszerek esetén, valamint az eredmények értelmezését is megkönnyítik a mélytanulási módszerekkel szemben, például a döntési fák esetén a változók fontosságának értékelésével.

5 Gyakorlati alkalmazások

Az előző fejezetekben bemutatott eszközök, mint a sztochasztikus differenciálegyenletek, a különböző ML és DL modellek lehetőséget adnak arra, hogy elemezzünk összetett, időben változó rendszereket és előrejelzéseket készítsünk. Ebben a fejezetben ezen módszerek gyakorlati alkalmazását vizsgálom meg bűnözési adatokon, elemezem a bűnözés időbeli mintázatát, a bűnözést befolyásoló demográfiai tényezőket, valamint a bűnözés előrejelzésére szolgáló modellek teljesítményét.

A bűnügyi statisztikák elemzése társadalmi és gazdasági szempontból is fontos, segíthet megérteni a bűnözést kiváltó okokat, és hozzájárulhat a hatékonyabb bűnmegelőzési stratégiák kidolgozásához. A bűncselekmények időbeli alakulásának vizsgálata lehetőséget ad a trendek, a szezonális és a hirtelen változások azonosítására, míg a demográfiai tényezők elemzése segíthet megérteni, hogy mely csoportok vannak nagyobb kockázatnak kitéve.

Elsőként korábban bemutatott geometriai Brown-mozgás segítségével modellezem a bűnözés időbeli alakulását, majd Random Forest modellt fogok alkalmazni a bűnözés előrejelzésére és a legfontosabb tényezők azonosítására.


5.1 Adatok bemutatása

A vizsgálathoz a Chicago városában elkövetett bűncselekmények adatait használom, amelyeket a Chicago Police Department tett közzé. Az adatbázis tartalmazza a bűncselekmények típusát, helyét, időpontját és egyéb jellemzőit. Az adatok a 2001-től 2025-ig terjedő időszakot ölelik fel, és több mint 6 millió bűncselekményt tartalmaznak. Minden egyes rekord egy bűncselekményt reprezentál és a legfontosabb jellemzői a következők:

- *ID*: Egyedi azonosító minden bűncselekményhez.
- *Dátum*: A bűncselekmény elkövetésének időpontja.
- *Primary Type*: A bűncselekmény típusa (pl. lopás, testi sértés, stb.).
- *Description*: Részletes leírás a bűncselekményről.
- *Arrest*: Jelzi, hogy történt-e letartóztatás a bűncselekmény kapcsán.
- *District*: A város melyik rendőri körzetében történt a bűncselekmény.
- *Community Area*: A város melyik területén történt a bűncselekmény.
- *Latitude és Longitude*: A bűncselekmény helyének földrajzi koordinátái.


ID	Date	Primary Type	Description	Location	Arrest
13974502	09/21/2025	CRIMINAL DAMAGE	TO PROPERTY	RESIDENCE - GARAGE	False
13975969	09/21/2025	THEFT	FROM MOTOR VEHICLE	RESIDENCE	False
13974043	09/21/2025	THEFT	OVER \$500	SIDEWALK	False
13976000	09/21/2025	DECEPTIVE PRACTICE	FINANCIAL IDENTITY THEFT	RESIDENCE	False
13976430	09/21/2025	CRIMINAL DAMAGE	TO VEHICLE	HOTEL / MO-TEL	False

1. Táblázat: Chicago bűnügyi adatok (minta)




6. Ábra: Chicago bűnesemények típusai és gyakorisága

A 7. Ábra a Chicagóban elkövetett bűnesetek típusait és azok gyakoriságát mutatja be 2001 és 2025 között. A leggyakoribb bűncselekménytípusok közé tartozik a lopás (THEFT, több mint 1,7 millió eset), a testi sértés (BATTERY, több mint 1,5 millió eset) illetve fontos lehet még kiemelni a kábítószerrel kapcsolatos bűncselekmények magasabb számát is (NARCOTICS, több mint 700 ezer eset). Ezek az adatok fontosak lehetnek a bűnmegelőzési stratégiák kialakításához és a későbbi elemzések során vizsgálhatjuk azt is, hogy ezek a bűncselekménytípusok hogyan változnak időben és térben, valamint milyen demográfiai tényezők befolyásolják előfordulásukat.




7. Ábra: Chicago bűnözési sűrűségének térképe

A 8. Ábra a rendőri körzeteket mutatja Chicagóban a bűnözési sűrűség alapján színezve. Azonosíthatóak azok a körzetek, amik a leginkább érintettek, ezek a térképen a sötétebb színnel vannak jelölve.




8. Ábra: Chicago bűnözési sűrűségének térképe

A 9. Ábra a bűncselekmények eloszlását mutatja a hét napjaira lebontva. Az ábráról kivehető a napszaki és heti mintázat, például, hogy a legtöbb bűncselekményt a hét végén éjjel körül követik el, illetve a hétköznapiakon is megfigyelhető egy kisebb csúcs a délutáni órákban. Ezek az információk fontosak lehetnek a rendőri erőforrások hatékonyabb elosztásához.




9. Ábra: Leggyakoribb bűncselekménytípusok és letartóztatási arányuk

A 10. Ábra a leggyakoribb bűncselekménytípusokat mutatja be a letartóztatási arányukkal együtt. Az ábra alapján látható, hogy a leggyakoribb bűncselekménytípusok közül a lopás (THEFT) és a testi sértés (BATTERY) esetében a letartóztatási arány viszonylag alacsony, míg a kábítószerrel kapcsolatos bűncselekmények (NARCOTICS) esetében kiugróan magas.



10. Ábra: Bűncselekmények havi alakulása



11. Ábra: Bűncselekmények havi alakulása (összesítve)

A 11. Ábra és a 12. Ábra a bűncselekmények havi alakulását mutatja be. A 11. Ábra alapján látható a bűnözés éven belüli szezonális mintázata, jellemzően a nyári hónapokban a legmagasabb a bűncselekmények száma, míg a téli hónapokban egy jelentős csökkenés figyelhető meg. Bár a bűnözés csökkenő trendet mutat a 2001 és 2025 közötti időszakban, a szezonális változások továbbra is megfigyelhetők. Ezeket a megfigyeléseket számszerűsíti a 12. Ábra, itt is megfigyelhető, hogy valóban a nyári hónapokban a legmagasabb a bűncselekmények száma, míg ez a szám a téli hónapokra csökken.

5.2 Bűnözés időbeli modellezése geometriai Brown-mozgással (Korrelált Brown-mozgás)

Ebben a fejezetben a bűnözés időbeli alakulását modellezem geometriai Brown-mozgással. A felépített modell alapját Julia Calatayud és társai ([4]) 2023-ban megjelent tanulmánya adja, amelyben a bűnözés időbeli alakulását sztochasztikus differenciálegyenletekkel modellezték. A módszer lényege, hogy a különböző területekhez tartozó Brown-mozgások nem függetlenek, hanem korreláltak, így a modell képes figyelembe venni a térségek közötti együttmozgást is. A szerzők a spanyolországi Valencia város bűnözési adatait vizsgálták geometriai Brown-mozgás segítségével, de az általuk javasolt módszertan alkalmazható más városok, így Chicago bűnözési adatainak modellezésére is. A következőkben bemutatom hogyan készítettem elő az adatokat és hogyan határoztam meg a geometriai Brown-mozgás paramétereit, majd a modell segítségével előrejelzéseket készítek a bűnözés alakulására vonatkozóan.

5.2.1 Adatok előkészítése

Elsőként, hogy a modellt alkalmazni tudjam, a nyers adatokat megfelelő térbeli és időbeli felbontásra kellett hozni. Ahogy az 8. Ábra is mutatja, a bűnözési mintázat jelentős eltéréseket

mutat a városon belül, ezért az előrejelzéseket kerületenként készítem el (a 21-es és 31-es körzetre nem állt rendelkezésre elég információ, így azokat az elemzés során nem vettem figyelembe). Az időbeli felbontáshoz először minden körzetre és évre kiszámoltam a havi bűncselekmények számát, majd ebből az adatból kiszámoltam a bűncselekmények napi átlagos számát, így figyelembe tudtam venni, hogy az egyes hónapok különböző hosszúságúak. Tanító adathalmazként a 2001 és 2024 közötti időszakot, míg teszt adatként 2025 január és augusztus közötti időszakot használtam. Illetve még az adatelőkészítés során eltávolítottam azokat az oszlopokat amelyekre nem lesz szükség a modellépítés során, például a bűncselekmények pontos helyét jelző földrajzi koordinátákat, illetve a bűncselekmények típusát jelző oszlopokat is, mivel ezek nem relevánsak a bűnözés időbeli alakulásának modellezése szempontjából.

5.2.2 Paraméterek meghatározása

Elsőként a szimuláció alapparamétereit határoztam meg, ezek a következők voltak:

- dt : A szimuláció időlépése, amelyet 1 hónapra állítottam be, mivel a bűnözési adatokat havi szinten aggregáltam.
- T : A szimuláció teljes időtartama, amely az én esetemben 8 hónap volt, mivel a teszt adatok 2025 január és augusztus közötti időszakot ölelik fel.
- N : A szimuláció lépéseinek száma, amelyet a teljes időtartam és az időlépés alapján számoltam ki, így $N = \frac{T}{dt}$
- S_0 : A szimuláció kezdeti értéke, amely minden körzetre a 2024 decemberében elkövetett bűncselekmények napi átlagos számát jelenti, mivel ez az utolsó ismert adatpont a tanító adathalmazban.
- t : A szimuláció időtengelye, amely tartalmazza a szimuláció minden időpontját a kezdeti időponttól a teljes időtartam végéig, az időlépésnek megfelelően.

A körzetek idősorait geometriai Brown-mozgással modelleztem. Jelölje $S_{i,t}$ az i -edik körzetben a bűncselekmények napi átlagos számát a t -edik időpontban. Ekkor az i -edik körzet idősora a következő sztochasztikus differenciálegyenlettel írható le:

$$dS_{i,t} = S_{i,t}\mu_i dt + \sigma_i S_{i,t} dW_{i,t} \quad (87)$$

ahol μ_i az i -edik körzet drift paramétere, σ_i a volatilitás paramétere, és $W_{i,t}$ az i -edik körzethez tartozó Brown-mozgás. A megoldás az alábbi alakban adható meg:

$$S_{i,t} = S_{i,0} \cdot \exp\left(\left(\mu_i - \frac{\sigma_i^2}{2}\right) \cdot t + \sigma_i \cdot W_{i,t}\right) \quad (88)$$

A modell minden körzetre külön-külön határozza meg a drift és volatilitás paramétereit, de a körzetek közötti Brown-mozgások között korrelációt feltételez:

$$\text{Corr}(W_{i,t}, W_{j,t}) = \rho_{i,j} \quad (89)$$

ahol $\rho_{i,j}$ a körzetek közötti korrelációs együttható. Ez azt fejezi ki, hogy a különböző körzetek bűnözési mintázatai nem függetlenek, tehát ha két körzet bűnözése hasonlóan változott az

elmúlt években, akkor a modell a jövőben is figyelembe fogja ezt venni. A drift és volatilitás paraméterek számítását az alábbi módon végeztem:

- μ : A drift paraméter, amely a bűnözés hosszú távú trendjét jelenti. Ezt a paramétert minden körzetre külön-külön határoztam meg. Ehhez először kiszámoltam az i -edik körzetben minden egymást követő hónap közötti loghozamot:

$$\mu_{i,t} = \log \left(\frac{S_{i,t+1}}{S_{i,t}} \right) \quad (90)$$

majd kiszámoltam a loghozamok átlagát és szórását és a drift paramétert a következő képlettel számoltam ki:

$$\mu_i = \overline{\mu_{i,t}} + 0.5 \cdot \text{sd}(\mu_{i,t})^2 \quad (91)$$

- σ : A volatilitás paraméter, amely a bűnözés rövid távú ingadozásait jelenti. Ezt a paramétert szintén minden körzetre külön-külön határoztam meg. A σ kiszámolásához is a loghozamokat használtam, kiszámoltam minden körzetre a szórásukat, és ezt az értéket használtam a volatilitás paraméterként:

$$\sigma_i = \text{sd}(\mu_{i,t}) \quad (92)$$

5.2.2.1 A korrelációs mátrix meghatározása és scenáriók generálása

A loghozamok alapján kiszámoltam a körzetek közötti korrelációs mátrixot, amely megmutatja, hogy a különböző körzetek bűnözési mintázatai mennyire mozognak együtt. Ha i, j jelöl két körzetet, akkor a korrelációs együttható a következő képlettel számolható ki:

$$\rho_{i,j} = \frac{\text{Cov}(\mu_{i,t}, \mu_{j,t})}{\sigma_i} \cdot \sigma_j \quad (93)$$

ahol $\text{cov}(\mu_{i,t}, \mu_{j,t})$ az i -edik és j -edik körzet loghozamainak kovarianciája, σ_i és σ_j pedig a volatilitás paraméterek. Így a korrelációs mátrix a következő alakú lesz:

$$R = (\rho_{i,j}) \quad (94)$$

A korrelált Brown-mozgások előállításához a körzetek korrelációs mátrixának Cholesky-felbontását használtam:

$$R = LL^T \quad (95)$$

ahol R a korrelációs mátrix, L pedig egy alsó háromszögmátrix. Ekkor a független standard normál eloszlású változókból előállíthatók a korrelált valószínűségi változók a következő módon:

$$\Delta W_t = \sqrt{dt} LZ_t \quad (96)$$

ahol Z_t egy független standard normál eloszlású vektor, és ΔW a korrelált Brown-mozgások vektora. Ezután a Brown-pályákat a következő módon állítottam elő:

$$W_{t_k} = \sum_{l=1}^k \Delta W_{t_l} \quad (97)$$


Tehát így minden körzethez és scenárióhoz egy összefüggő Brown-pálya tartozik, amely figyelembe veszi a körzetek közötti korrelációt is. Majd az így kapott paramétereket és pályákat behelyettesítettem a geometriai Brown-mozgás megoldásába és így kaptam meg a bűnözés előrejelzéseit minden körzetre és minden időpontra vonatkozóan.

Tehát például három scenárió generálása esetén a következő eredményt kaptam az első körzetre vonatkozóan:

Month	Scenario 1	Scenario 2	Scenario 3
1	36.97	42.54	33.58
2	42.28	42.5	35.67
3	42.8	41.44	38.76
4	41.17	34.13	38.45
5	43.38	35.93	37.63
6	45.48	36.97	31.57
7	48.75	39.39	31.36
8	48.43	46.5	40.91

2. Táblázat: Az első körzetre kapott előrejelzések a három scenárióban

A táblázat alapján látható, hogy a három scenárióban kapott előrejelzések jelentős eltéréseket mutatnak, ami a sztochasztikus paraméter véletlenszerűségéből adódik. Ez azt jelzi, hogy a geometriai Brown-mozgás érzékeny a sztochasztikus paraméter értékére, ezért fontos lehet több scenáriót is szimulálni, hogy jobban megértsük a bűnözés időbeli alakulásának bizonytalanságát. A scenáriók eredményeit a valós adatokkal is összehasonlítottam:




12. Ábra: Tényleges bűncselekmények napi átlagos száma a teszt időszakban és a három scenárióban kapott előrejelzések

A különbségek számszerűsítéséhez kiszámoltam az RMSE értékeket is:

$$\text{RMSE} = \sqrt{\sum_{i=1}^n (y_i - (\hat{y})_i)^2} \quad (98)$$

és ábrázoltam a három scenárióra:



13. Ábra: Az első körzet esetén a három scenárió RMSE értékei

5.2.3 Eredmények és értékelés


A tényleges szimuláció során 10.000 scenáriót generáltam és ahogy azt a három scenáriót tartalmazó példán is bemutattam, ezek a scenáriók eltérő viselkedést mutatnak. Ahhoz, hogy kiválasszam azt a scenáriót, ami minden körzet esetén a legjobb előrejelzést adja, kiszámoltam az RMSE értékeket minden scenárióra és minden körzetre vonatkozóan, majd kiválasztottam azt a scenáriót, amelyik a legkisebb átlagos RMSE értéket adta. Az eredmények összefoglalását az alábbi táblázat mutatja:

RMSE	MAE	MAPE	Accuracy
3.34	2.64	8.93	91.07

)

3. Táblázat: Az eredmények összefoglalása

A táblázat alapján látható, hogy a modell 91,07%-os pontossággal (Accuracy) tudta előrejelezni a bűnözés alakulását a teszt időszakban, ami azt jelzi, hogy a geometriai Brown-mozgás jól alkalmazható a bűnözés időbeli modellezésére. Az RMSE és MAE (mean absolute error) értékek alapján is jól teljesített a modell, ezek az értékek azt mutatják, hogy a modell által előrejelzett értékek sehol nem térnek el kiugóan a tényleges értékektől.




(a) Előrejelzés hő térképen

(b) Tényleges adatok hő térképen

14. Ábra: Az előrejelzés és a tényleges adatok összehasonlítása hő térképen

A 17. Ábra alapján is látható, hogy a két hő térkép hasonló mintázatot mutat, látható, hogy a modell mind a kisebb mind a nagyobb esetszámú területeket jól azonosította, ami azt jelzi, hogy a modell képes volt megragadni a bűnözés nemcsak időbeli, de térbeli mintázatát is.



15. Ábra: Az előrejelzés és a tényleges adatok közötti különbség hő térképen

Hogy vizuálisan is látható legyen a különbség a két hő térkép között, készítettem egy külön hő térképet, amely az előrejelzés és a tényleges adatok közötti különbséget mutatja be. A 18. Ábra alapján látható, hogy a különbségek nagy része kisebb értékek körül helyezkedik el, de megfigyelhető, hogy a 19-es, 14-es és 12-es körzetekben az abszolút átlagos hiba magasabb.

5.3 Bűnözés előrejelzése Random Forest modellel

A geometriai Brown-mozgás alkalmazásával sikerült feltárni a bűnözés időbeli alakulását és a sztochasztikus differenciálegyenletek segítségével megragadni az előrejelzés bizonytalanságát. Ez a megközelítés elsősorban a múltbeli adatból származtatott drift és volatilitás paraméterekre támaszkodik és vázolja fel a jövőbeli scenáriókat, azonban nem ismerjük meg az adatokban lévő struktúrákat és összefüggéseket. Ezért ebben a részben egy másik megközelítést alkalmazok, egy Random Forest modellt, amely képes megragadni az adatokban lévő nemlineáris összefüggéseket és interakciókat. A modell építése során a bűncselekmények számát jelzem előre minden körzetre és minden hónapra vonatkozóan, ugyanazt a tanító és teszt adathalmazatot használva, mint a geometriai Brown-mozgás esetében.

5.3.1 Adatok előkészítése

A Random Forest modell esetében is hasonlóan a geometriai Brown-mozgáshoz a 2001 és 2024 közötti időszakot használtam tanító adathalmazatként, míg a 2025 január és augusztus közötti időszakot teszt adathalmazatként. Az adatelőkészítés során azonban nem csak a bűncselekmények számát tartalmazó oszlopokat hagytam meg, hanem további jellemzőket is hozzáadtam, amelyek potenciálisan befolyásolhatják a bűnözés alakulását. A célváltozó most is a bűncselekmények napi átlagos száma minden körzetre és minden hónapra vonatkozóan. Mivel a Random Forest modell nem tudja az időbeliséget megragadni, kiegészítettem az adatokat új bemeneti változókkal, amelyek az időbeli mintázatokat reprezentálják. Ezek a következők voltak:

- *Month*: A hónap száma (1-12)
- *Year index*: Az év indexe, amely a 2001-től kezdődő évek számát jelenti (pl. 2001 = 0, 2002 = 1, stb.)
- *Month sin*: A hónap szinusz transzformációja, amely segít megragadni a szezonális mintázatokat
- *Month cos*: A hónap koszinusz transzformációja, amely segít megragadni a szezonális mintázatokat
- *IsSummer*: Egy bináris változó, amely jelzi, hogy a hónap a nyári időszakban van-e (június, július, augusztus)
- *IsWinter*: Egy bináris változó, amely jelzi, hogy a hónap a téli időszakban van-e (december, január, február)

```

1  def year_indexing(df):
2      df['Year_Index'] = 2025 - df['Year'] + 1
3      return df

```

```

1  def prepare_month_data(df, col):
2      df[col] = df[col].astype(float)
3      df[f"{col}_Sin"] = df[col].apply(lambda x: (np.sin(((x-1) * 2 *
      np.pi / 12)+0.5)+1)/2)
4      df[f"{col}_Cos"] = df[col].apply(lambda x: (np.cos(((x-1) * 2 *
      np.pi / 12)+0.5)+1)/2)
5      df['Is_Winter'] = df['Month'].isin([12, 1, 2]).astype(int)
6      df['Is_Summer'] = df['Month'].isin([6, 7, 8]).astype(int)
7      df = year_indexing(df)
8      return df

```

1. Listing: Az időbeli jellemzők előkészítése

Továbbá mivel a bűnözés jövőbeli rátája egy körzetben nagymértékben függ az elmúlt időszakok tendenciáitól és a hónapok kinyerése és átalakítása segít a szezonális modellezésében, de nem képes megragadni a folyamatos időbeli trendet. Tehát, hogy a Random Forest modellt hatékonyan tudjam alkalmazni idősorok elmozdítására, az adatelőkészítés során úgynevezett késleltetett változókat (lag features) is létrehoztam. Ezek a változók a bűncselekmények napi átlagos számát tartalmazzák az előző hónapokban minden körzetre vonatkozóan. Tehát így a modell képes lesz emlékezni a múltbeli értékekre.

```

1  def create_lagged_features(df, col, lag=1):
2      df_lagged = df.copy()
3      for i in range(1, lag + 1):
4          df_lagged[f'{col} Lag {i}'] = df_lagged.groupby('District')
          [col].shift(i)
5      return df_lagged

```

2. Listing: Késleltetett változók létrehozása

A lag változók létrehozása mellett a múltbeli értékekből kiszámolt mozgóátlagot és mozgószórást is hozzáadtam az adatokhoz, hogy egy-egy kiugró érték ne befolyásolja túlzottan a modellt és hogy a modell a mozgószórás értékek alapján meg tudja ragadni a bűnözés ingadozásait.

```
1  def rolling_mean(df, idopontok):  
2  
3      for i in idopontok:  
4  
5          df[f'Rolling Mean {i}'] = (  
6  
7              df.groupby('District')['Number of Crimes Per Day']  
8  
9                  .transform(lambda s: s.shift(1).rolling(window=i).mean()))  
10  
11  
12      return df
```

```
1  def rolling_std(df, idopontok):  
2  
3      for i in idopontok:  
4  
5          df[f'Rolling Std {i}'] = (df.groupby('District')['Number of  
6      Crimes Per Day'].transform(lambda s:  
7          s.shift(1).rolling(window=i).std()))  
8  
9  
10     return df
```

3. Listing: Mozgóátlagok és mozgószórások létrehozása

5.3.2 Modellépítés és eredmények

Az adatok előkéazítése után a Random Forest modellek betanítása következett. Két különböző modellt építettem, az elsőben csak a késleltetett változókat használtam, míg a második modellben már a mozgóátlagokat és mozgószórásokat is hozzáadtam a bemeneti változókhoz.

5.3.2.1 Modell 1: Késleltetett változók

A modellben során használt bemeneti változók a következők voltak:

- *District*: A körzet azonosítója
- *Year Index*: Az év indexe

- *Month Sin*: A hónap szinusz transzformációja
- *Month Cos*: A hónap koszinusz transzformációja
- *Is Summer*: Bináris változó, amely jelzi, hogy a hónap a nyári időszakban van-e
- *Is Winter*: Bináris változó, amely jelzi, hogy a hónap a téli időszakban van-e
- *Number of Crimes Per Day Lag 1*: A bűncselekmények napi átlagos száma az előző hónapban
- *Number of Crimes Per Day Lag 2*: A bűncselekmények napi átlagos száma két hónappal ezelőtt

A késleltetett (lag) változók számának megválasztása során több különböző beállítást is kipróbáltam, az eredmények alapján a 2 hónapra visszamenő késleltetett változók adták a legjobb eredményeket, ezért ezeket használtam a modellben. Több lag-változó használata esetén a modell teljesítmény már nem mutatott javulást, ezt magyarázhatja, hogy a bűnözés alakulására leginkább az előző hónapok tendenciái vannak hatással, és a túl sok lag-változó használata már nem ad hozzá új információt a modell számára, viszont növeli a modell komplexitását és a túlillesztés kockázatát.

A Random Forest modell nem hónaponként készítette el az előrejelzést, hanem egyszerre, a 8 hónapra vonatkozóan. Így a modell egy adott időpont és körzet alapján egy teljes előrejelzési horizontot állított elő. Ennek előnye, hogy a több hónapra vonatkozó becslések egyszerre készülnek el, vagyis a modell nem kényszerül arra, hogy minden újabb hónap előrejelzéséhez az előző saját becslését használja fel. Ez csökkentheti a hibák továbbterjedését, amely a szekvenciális előrejelzéseknél gyakran problémát jelent.

A Random Forest modell hiperparamétereit RandomizedSearchCV segítségével hangoltam, amely egy véletlenszerű keresést hajt végre a megadott hiperparaméterek között, és a legjobb kombinációt választja ki a modell teljesítménye alapján. A legjobb hiperparaméterek a következők voltak:

- *n_estimators*: 521 (a döntési fák száma a Random Forest modellben)
- *max_depth*: 12 (a döntési fák maximális mélyse)
- *max_features*: '0.5' (a bemeneti változók aránya, amelyet minden döntési fa építésekor véletlenszerűen kiválasztanak)

A modell validálásához walk-forward cross-validation-t alkalmaztam, amely egy időbeli keresztvalidációs módszer. A módszer során a tanító adathalmazatot több részre osztottam, és minden részre külön-külön tanítottam a modellt, majd a következő részre vonatkozóan készítettem előrejelzést, így megőriztem az időbeli sorrendiséget. A keresztvalidáció során a következő eredményeket kaptam:

RMSE	MAPE	Accuracy
5.41	12.03	87.97


4. Táblázat: Walk-forward keresztvalidáció eredményei

A modell teljesítményét a teszt adathalmazaton is értékeltem, amely 2025 január és augusztus közötti időszakot öleli fel. A következő táblázat mutatja a teszt adathalmazaton kapott eredményeket:

RMSE	MAE	MAPE	Accuracy
3.11	2.53	9.18	90.82

5. Táblázat: Teszt adathalmazaton kapott eredmények

A táblázat alapján látható, hogy a modell 90,82%-os pontossággal (Accuracy) tudta előrejelezni a bűnözés alakulását a teszt időszakban, illetve az RMSE érték is viszonylag alacsony (3,11), ami azt jelenti, hogy az előrejelzett napi átlagos bűncselekményszám átlagosan kis mértékben tér el a tényleges értékektől. Akárcsak a geometriai Brown-mozgás esetében, a modell előrejelzéseit hő térképen is megjelenítettem, hogy vizuálisan is összehasonlítható legyen a tényleges adatokkal.




(a) Előrejelzés hő térképen

(b) Tényleges adatok hő térképen

16. Ábra: Az előrejelzés és a tényleges adatok összehasonlítása hő térképen

A 24. Ábra mutatja az előrejelzés és a tényleges adatok hő térképeit. Az eltérések vizuális megjelenítéséhez készítettem egy külön hő térképet, amely az előrejelzés és a tényleges adatok közötti különbséget mutatja be.



17. Ábra: Az előrejelzés és a tényleges adatok közötti különbség hőtérképen

Az 25. Ábra alapján látható, hogy a különbségek nagy része nem jelentős, de megfigyelhető pár körzet, ahol az abszolút átlagos hiba magasabb, például a 14, 25 és 19-es körzetekben, ahol 4 fölötti átlagos hibát kaptam.

5.3.3 Modell 2: Késleltetett változók, mozgóátlagok és mozgósórások

A második modellben a bemeneti változókat még kiegészítettem a mozgóátlagokkal és mozgósórásokkal, így a bemeneti változók a következők voltak:

- *District*: A körzet azonosítója
- *Year Index*: Az év indexe
- *Month Sin*: A hónap szinusz transzformációja
- *Month Cos*: A hónap koszinusz transzformációja
- *Is Summer*: Bináris változó, amely jelzi, hogy a hónap a nyári időszakban van-e
- *Is Winter*: Bináris változó, amely jelzi, hogy a hónap a téli időszakban van-e
- *Number of Crimes Per Day Lag 1*: A bűncselekmények napi átlagos száma az előző hónapban
- *Number of Crimes Per Day Lag 2*: A bűncselekmények napi átlagos száma két hónappal ezelőtt
- *Rolling Mean 3*: A bűncselekmények napi átlagos számának 3 hónapos mozgóátlaga
- *Rolling Mean 4*: A bűncselekmények napi átlagos számának 4 hónapos mozgóátlaga
- *Rolling Std {k}*: A bűncselekmények napi átlagos számának k hónapos mozgósórása, ahol $k = 3, 4, 5, 6$

A modell felépítése és a hiperparaméterek hangolása ugyanúgy történt, mint az első modell esetében. A keresztvalidáció során a következő eredményeket kaptam:

RMSE	MAPE	Accuracy
14.03	28.86	71.14


6. Táblázat: Walk-forward keresztvalidáció eredményei

A teszt adathalmazaton kapott eredményeket a következő táblázat mutatja:

RMSE	MAE	MAPE	Accuracy
3.23	2.12	7.29	92.71

7. Táblázat: Teszt adathalmazaton kapott eredmények

A táblázat alapján látható, hogy a modell 92,71%-os pontossággal jelzett előre, ebből is látszik, hogy a mozgóátlagok és mozgószórások hozzáadása javította a modell teljesítményét, hiszen az első modellben 90,82%-os pontossággal tudta előrejelezni a bűnözés alakulását. Az RMSE érték is csökkent (2,44), ami azt jelenti, hogy az előrejelzett napi átlagos bűncselekményszám átlagosan kisebb mértékben tér el a tényleges értékektől, mint az első modell esetében. Ebben az esetben is elkészítettem a hő térképeket:




(a) Előrejelzés hő térképen

(b) Tényleges adatok hő térképen

18. Ábra: Az előrejelzés és a tényleges adatok összehasonlítása hő térképen

Továbbá a különbség hő térképet is elkészítettem:



19. Ábra: Az előrejelzés és a tényleges adatok közötti különbség hőtérképen

Az ábráról leolvasható, hogy az eltérések értékei kis tartományban mozognak, de megfigyelhető, hogy a 12-es körzetben jelentős eltérés van, ahol az átlagos hiba 10 fölötti érték, ami kiugróan magas. Ez magyarázható azzal, hogy a körzetben a bűncselekmények száma növekedett a teszt időszakban, míg a tanító adathalmazban csökkenő tendencia volt megfigyelhető, így a modell nem tudta jól megragadni ezt a változást.

5.3.4 Összefoglalás

A bűnözés előrejelzésére több különböző megközelítést alkalmaztam és hasonlítottam össze. Elsőként geometriai Brown-mozgással modelleztem a bűncselekmények időbeli alakulását, majd Random Forest modelleket építettem, amelyek már több bemeneti változót is figyelembe vettek. Az összehasonlítás érdekében egy egyszerű baseline modellt is készítettem, amely a 3 hónapos mozgóátlagon alapult.

A baseline modell célja, hogy egy egyszerű, könnyen érthető előrejelzést adjon, amelyhez a komplexebb modellek teljesítményét viszonyítani lehet. Ennél a módszernél az előrejelzés minden körzet esetén a 2024-es év utolsó három hónapjának (október, november, december) bűncselekményszámának átlagát jelenti. A baseline modell nem tanul külön paramétereket, hanem kizárólag a legutóbbi rövid távú trendet veszi figyelembe. Ezért alkalmas annak vizsgálatára, hogy a geometriai Brown-mozgás és a Random Forest modellek valóban többlet-információt tudnak-e kinyerni az adatokból egy egyszerű mozgóátlagos előrejelzéshez képest.

Az eredményeket az alábbi táblázat foglalja össze:

Modell	RMSE	MAE	MAPE	Accuracy
Random Forest (rolling features)	3.23	2.12	7.29	92.71
Baseline (rolling mean)	3.19	2.51	8.81	91.19
Geometriai Brown mozgás	3.34	2.64	8.93	91.07
Random Forest (lag)	3.11	2.53	9.18	90.82

8. Táblázat: Modellek teljesítményének összehasonlítása

A táblázat alapján látható, hogy a különböző hibamutatók nem teljesen ugyanazt a sorrendet adják. RMSE alapján a Random Forest kizárólag késleltetett változókat használó változata érte el a legalacsonyabb hibát, ugyanakkor a MAPE és az Accuracy alapján a rolling feature-ökkel kiegészített Random Forest modell teljesített a legjobban. A MAPE relatív hibát mér, az Accuracy pedig ebből származtatott mutató, ez alapján összességében a Random Forest rolling feature-ökkel kiegészített változata tekinthető a legkedvezőbb modellnek.

A geometriai Brown-mozgás teljesítménye valamivel gyengébb lett, mint a Random Forest rolling feature-ökkel kiegészített változatáé és a baseline modellé. Ennek oka lehet, hogy a geometriai Brown-mozgás elsősorban a múltbeli trendből, a volatilitásból és a korrelált véletlen ingadozásokból indul ki, míg a Random Forest modellek további időbeli jellemzőket, például szezonalitást, lag-változókat, mozgóátlagokat és mozgószórásokat is figyelembe vesznek.

Összességében az eredmények azt mutatják, hogy a bűncselekmények előrejelzésében a múltbeli trend, a rövid távú mozgóátlagok és az időbeli késleltetett változók kiemelten fontos szerepet játszanak. A Random Forest rolling feature-ökkel kiegészített változata azért teljesített jól, mert egyszerre tudta figyelembe venni a múltbeli értékeket, az ingadozásokat és a szezonális mintázatokat.

5.4 Bűnözést befolyásoló demográfiai tényezők elemzése és előrejelzés készítése

Az előző fejezetekben a bűnözés időbeli alakulását vizsgáltam geometriai Brown-mozgás, illetve Random Forest modellek segítségével. Ezekben a modellekben a fő cél az volt, hogy a múltbeli bűnözési adatok alapján minél pontosabb előrejelzést készítssek a következő hónapokra. A modellek elsősorban az idősoros mintázatokra, a szezonálisra, a lag-változókra és a mozgóátlagokra épültek. Ebben a fejezetben egy ettől eltérő megközelítést vizsgállok. Itt nemcsak maga az előrejelzés a cél, hanem annak vizsgálata is, hogy mely társadalmi-demográfiai jellemzők állhatnak kapcsolatban a bűnözés alakulásával és az egyes bűncselekménytípusok esetében milyen tényezők lehetnek meghatározóak.

További különbség az eddigi fejezetekhez képest, hogy az elemzést már nem körzetekre végzem, hanem úgynevezett community area szinten, amely egy kisebb területi egység, illetve nem havi szinten, hanem éves szinten vizsgálom a bűnözés alakulását. Ennek oka, hogy a társadalmi-demográfiai jellemzők általában éves szinten állnak rendelkezésre és community area szinten aggregálható.

5.4.1 Adatok előkészítése

Ebben a fejezetben tanító adatként a 2013 és 2023 közötti időszakot használtam, míg az előrejelzést a 2024-es évre készítettem el, az előző fejezethez képest az eltérés oka, hogy erre a periódusra állnak rendelkezésre a legfrissebb társadalmi-demográfiai adatok.

A demográfiai és társadalmi-gazdasági jellemzők adatainak forrása a U.S. Census Bureau által publikált American Community Survey (ACS) 5 éves becslései voltak, amelyek évente frissülnek és részletes információkat tartalmaznak a lakosság összetételéről, jövedelmi viszonyairól, foglalkoztatottságáról, oktatási szintjéről és egyéb társadalmi-gazdasági jellemzőiről. Az ACS 5 éves becslések nem egyetlen év pontos állapotát, hanem több év adataiból képzett becslést reprezentálnak. Emiatt ezek a változók inkább a városrészek tartósabb társadalmi-gazdasági jellemzőit írják le, nem pedig hirtelen éves változásokat. Ez ugyanakkor előnyös is lehet a bűnözési mintázatok vizsgálatában, mert a demográfiai tényezők hatása jellemzően nem egyik évről a másikra, hanem hosszabb időtávon jelenik meg.

Az elemzéshez a 2013 és 2023 közötti adatokat használtam fel. Az adatok eredetileg census tract szinten álltak rendelkezésre, amely egy kisebb területi egység, mint a community area. Ezért először a census tract-eket aggregáltam community area szintre. A feldolgozás során több társadalmi és gazdasági mutatót képeztem illetve a nyers adatok helyett arányszámokat alkalmaztam, a jobb összehasonlíthatóság érdekében. Az elemzés során a következő mutatókat használtam:

- *Teljes népesség:* A community area teljes lakossága
- *Munkanélküliek aránya:* A munkanélküliek aránya a teljes munkaerőhöz képest
- *Egy főre jutó jövedelem:* A community area egy főre jutó jövedelme
- *Iskolázottsági mutatók:* A középiskolát végzettek aránya, a diplomások aránya illetve a középiskolai végzettség nélküli lakosok aránya

- *Szegénységi ráta*: A szegénységi küszöb alatt élők aránya
- *Fiatal férfiak aránya*: A 15-34 éves férfiak aránya a teljes lakossághoz képest

Mivel az ACS-adatok csak 2023-ig álltak rendelkezésre, a 2024-es előrejelzéshez a jellemzőket becsülni kellett. Ehhez Community Area-nként negyedfokú polinomiális extrapolációt alkalmaztam, amely a múltbeli értékek alapján egy negyedfokú polinomot illesztett az adatokra, majd ezt a polinomot használva becsültem meg a 2024-es értékeket.

A bűnözési adatok előkészítése során az adatokat community area szintre aggregáltam és éves szinten összesítettem. Elsőként az összes bűncselekményt egyben vizsgáltam, majd külön-külön elemeztem a leggyakoribb bűncselekménytípusokat is, mint például a lopás, testi sértés. A feldolgozás során az előző fejezetekhez hasonlóan létrehoztam késleltetett változókat, mozgóátlagokat és mozgószorásokat is, hogy a modell ne csak a társadalmi-demográfiai jellemzőket, hanem a bűnözés múltbeli alakulását is figyelembe vegye az előrejelzés során.

5.4.2 Eredmények és értékelés

A demográfiai adatok bevonásával végzett elemzést két lépésben készítettem el. Elsőként egy összesített modellt építettem, amelyben az adott Community Area-ban és évben előforduló összes bűncselekmény számát vizsgáltam. Ennek célja az volt, hogy általános képet kapjak arról, mely társadalmi-gazdasági és demográfiai jellemzők kapcsolódnak leginkább a bűnözés teljes szintjéhez.

Ezt követően a leggyakoribb bűncselekménytípusokat külön-külön is elemeztem, hogy megvizsgáljam, hogy a különböző bűncselekménytípusok esetében milyen tényezők lehetnek meghatározóak. Erre azért volt szükség, mert például egy vagyon elleni bűncselekmény, egy erőszakos bűncselekmény vagy egy kábítószerrel kapcsolatos eset mögött eltérő társadalmi és gazdasági mintázatok állhatnak.

5.4.2.1 Összesített modell


Tehát elsőként az összes bűncselekmény együttes esetszámát vizsgáltam, a célváltozó ennek megfelelően a bűncselekmények éves száma volt minden Community Area-ban. Az előrejelzés pedig egy évre előre készült, a 2024-es évre vonatkozóan. A modell célja egyrészt az volt, hogy vizsgáljam, hogy a társadalmi-gazdasági és demográfiai jellemzők bevonása javítja-e az előrejelzés pontosságát, másrészt pedig hogy megvizsgáljam, hogy mely tényezők állnak leginkább kapcsolatban a bűnözés alakulásával.

Ennek megfelelően két modellt építettem, az elsőben csak a bűnözés múltbeli alakulását figyelembe vevő változókat használtam, míg a második modellben már a társadalmi-gazdasági és demográfiai jellemzőket is bevontam. A két modell összehasonlítás azért is fontos, mert az előző fejezetekben tárgyalt modellek, amik csak a bűnözés időbeli alakulását használták fel, is jó előrejelzéseket adtak, így a demográfiai adatok hozzáadott értéke csak akkor mutatható ki, ha a második modell a korábbi bűnözési szint figyelembevételével is javítja az előrejelzési teljesítményt. Az értékelés során a korábban már ismertetett metrikákat használtam: RMSE, MAE, MAPE és Accuracy. Az eredményeket az alábbi táblázat foglalja össze:


Model	RMSE	MAE	MAPE	Accuracy
Demográfiai adatokkal + Rolling Mean	358.51	263.54	9.86	90.14
Csak Rolling Mean	434.68	323.62	11.25	88.75

9. Táblázat: Összesített modell eredményei

A táblázat alapján látható, hogy a társadalmi-gazdasági és demográfiai jellemzők bevonása javította az előrejelzés pontosságát, 88,74%-ról 90,14%-ra nőtt az Accuracy értéke. Tehát az új jellemzők hozzáadása valóban többletinformációt adott a modellnek, ugyanakkor a javulás mértéke nem volt ugrásszerű. Ennek oka lehet egyrészt, hogy a demográfiai tényezők csak lassan, általában hosszabb időszak alatt mutatnak jelentős változást, így a 2024-es évre vonatkozóan a becslt értékek nem térnek el jelentősen a 2023-as értékektől, másrészt pedig az idősoros jellemzők, mint például a lag-változók és a mozgóátlagok, már önmagukban is sok információt tartalmaznak, a modell már önmagában is viszonylag jó előrejelzést tud adni, így a további jellemzők hozzáadása ehhez képest már csak kisebb mértékben javítja a teljesítményt. További magyarázat lehet, hogy a 2024-es adatra a társadalmi-gazdasági és demográfiai jellemzők nem közvetlen megfigyelésből származnak, hanem becslt értékek, így ezek is hibával terheltek, ami csökkentheti a modell teljesítményét.




(a) Csak idősoros jellemzőket használó modell előrejelzése



(b) Idősoros jellemzőket és társadalmi-gazdasági, demográfiai jellemzőket is használó modell előrejelzése

20. Ábra: Az előrejelzések és a tényleges adatok összehasonlítása szórásdiagramon

Az ábrán is látható, hogy mindkét modell előrejelzései jól követik a tényleges aatokat, tehát a pontok nagy része a 45 fokos egyenes közelében helyezkedik el, illetve az ábrán is látható, hogy a magasabb esetszámnál a társadalmi-gazdasági és demográfiai jellemzőket is tartalmazó modell előrejelzései jobban követik a tényleges adatokat.



21. Ábra: A társadalmi-gazdasági és demográfiai jellemzőket is tartalmazó modell feature importance értékei

Az 33. Ábra ábra alapján látható, hogy a legfontosabb jellemzők között elsősorban a bűnözés múltbeli alakulását leíró változók szerepelnek, a társadalmi-gazdasági és demográfiai jellemzők közül pedig teljes népesség illetve a fiat férfiak aránya tűnik a legfontosabbnak.

5.4.2.2 Bűncselekménytípusok szerinti elemzés

Az összesített modell után a bűncselekménytípusok elemzésével folytattam. A típusonkénti modellben a célváltozó minden esetben a kiválasztott bűncselekménytípus éves esetszáma volt minden Community Area-ban. A modell célja elsősorban az volt, hogy vizsgáljam, hogy az egyes bűncselekménytípusok esetében milyen társadalmi-gazdasági és demográfiai tényezők lehetnek meghatározóak, illetve hogy ezek a tényezők mennyire járulnak hozzá a modell előrejelzési teljesítményéhez. Ennek megfelelően ebben a fejezetben nem használtam a mozgóátlagokat, hanem csak a demográfiai és társadalmi-gazdasági jellemzőket, hogy a modellek értelmezése során egyértelműen meg lehessen vizsgálni, hogy mely tényezők járulnak hozzá leginkább az előrejelzéshez.

A modellek értelmezéséhez minden típus esetében elkészítettem háromféle ábrát:

- *Feature importance*: Random Forest beépített feature importance értéke azt mutatja meg, hogy a döntési fák építése során az adott változó milyen mértékben járult hozzá a célváltozó jobb szétválasztásához
- *SHAP értékek*: Az adott bűncselekménytípus esetében a legfontosabb jellemzők SHAP értékei, amelyek megmutatják, hogy az egyes jellemzők milyen irányban és milyen mértékben befolyásolják a modell előrejelzését
- *Permutation importance*: Ennél a módszernél egy-egy változó értékeit véletlenszerűen összekeverjük, majd megvizsgáljuk, hogy ez mennyire rontja a modell teljesítményét. Ha egy változó összekeverése jelentősen növeli az előrejelzési hibát, akkor az azt jelzi, hogy a modell erősen támaszkodott erre a változóra.

Az eddigi fejezetektől eltérően itt a modell értékeléséhez WMAPE-t (Weighted Mean Absolute Percentage Error) használtam, mivel az egyes bűncselekménytípusok esetszáma nagyon eltérő


lehet. Egy gyakori bűncselekménytípus, például a lopás esetében sokkal nagyobb esetszámok jelennek meg, míg ritkább típusoknál bizonyos Community Area-kban akár nagyon alacsony vagy nulla értékek is előfordulhatnak. Ilyen esetekben a hagyományos MAPE használata problémás lehet, mert az minden megfigyelésnél külön-külön oszt a tényleges értékkel. Ha a tényleges érték nagyon kicsi, akkor már egy kisebb abszolút hiba is aránytalanul nagy százalékos hibát eredményezhet, nulla érték esetén pedig a MAPE nem is értelmezhető.

$$\text{WMAPE} = \frac{\sum_{i=1}^n |y_i - \hat{y}_i|}{\sum_{i=1}^n |y_i|} \cdot 100 \quad (99)$$

A típusonkénti elemzés során minden bűncselekménycategóriánál külön értelmeztem az ábrákat. Elsőként a feature importance alapján megvizsgáltam, mely változók kapták a legnagyobb súlyt a modellben. Ezt követően a permutation importance eredményeivel ellenőriztem, hogy ezek a változók valóban hozzájárultak-e a modell prediktív teljesítményéhez. Végül a SHAP-ábrák segítségével részletesebben elemeztem, hogyan hatottak a legfontosabb változók az előrejelzett bűncselekményszámokra. A három leggyakrabban előforduló bűncselekménytípus esetében részletesen is bemutatom ezeket az elemzéseket.

5.4.2.2.0.1 Lopás

A leggyakrabban előforduló bűncselekménytípus a lopás volt. Az alábbi ábrák a lopás esetében mutatják be a feature importance értékeket, a permutation importance eredményeit és a SHAP értékeket:



(a) Lopás esetében a feature importance értékek

(b) Lopás esetében a permutation importance értékek

22. Ábra: Lopás esetében a feature importance és permutation importance értékek összehasonlítása




23. Ábra: Lopás esetében a feature importance értékek

Az ábrák alapján látható, hogy a lopás esetében a következők voltak a legfontosabb változók:

- *Fiat férfiak aránya*: Ez a változó a legmagasabb feature importance értéket kapta, és a permutation importance alapján is ez a változó volt a legfontosabb. A SHAP-ábrán is látható, hogy a magasabb fiatal férfi arány általában magasabb lopásszámot eredményez.
- *Teljes népesség*: Ez a változó is magas feature importance értéket kapott, és a permutation importance alapján is ez volt a második legfontosabb változó. A SHAP-ábrán is látható, hogy a nagyobb népességű körzetekben általában magasabb lopásszámot jósolt a modell.
- *Egy főre jutó jövedelem*: Ez a változó is viszonylag magas feature importance értéket kapott, és a permutation importance alapján ez volt a harmadik legfontosabb változó. Az SHAP alapján látható, hogy ha magasabb volt az egy főre jutó jövedelem, akkor az bizonyos esetekben magasabb lopásszámot eredményezett, ami magyarázható azzal, hogy a magasabb jövedelmű körzetekben gyakrabban lehet a lopás.
- *Középiskolai végzettség nélküli lakosok aránya (25 év felett)*: Ez a változó is viszonylag magas feature importance értéket kapott, és a permutation importance alapján is meghatározó volt. Az SHAP-ábra alapján elsősorban az figyelhető meg, hogyha csökken az alacsony iskolázottságú lakosok aránya, akkor az általában alacsonyabb lopásszámot eredményezett.
- *Szegénységi ráta*: Ez a változó is viszonylag magas feature importance értéket kapott, és a permutation importance alapján is meghatározó volt. Az SHAP-ábra alapján látható, hogy a magasabb szegénységi ráta általában magasabb lopásszámot eredményezett.

A lopás esetében a modell WMAPE értéke 20,28% volt, ami azt jelenti, hogy az előrejelzések átlagosan 20,28%-kal tértek el a tényleges értékektől.




24. Ábra: Lopás esetében az előrejelzések és a tényleges adatok összehasonlítása

Az ábrán látható, hogy a lopás esetében a modell előrejelzései viszonylag jól követik a tényleges adatokat, bár a magasabb esetszámoknál néhány pont jelentősen eltér a 45 fokos egyenestől, ami azt jelzi, hogy a modell néhány esetben alul- vagy túlbecsülte a lopásszámot.

5.4.2.2.1 Testi sértés


A második leggyakoribb bűncselekménytípus a testi sértés volt. Az alábbi ábrák a testi sértés esetében mutatják be a feature importance értékeket, a permutation importance eredményeit és a SHAP értékeket:



(a) Testi sértés esetében a feature importance értékek

(b) Testi sértés esetében a permutation importance értékek

25. Ábra: Testi sértés esetében a feature importance és permutation importance értékek összehasonlítása




26. Ábra: Testi sértés esetében a feature importance értékek

Az ábrák alapján látható, hogy a testi sértés esetében a legfontosabb változók hasonlóak voltak, mint a lopás esetében:

- *Népesség*: Ez a változó a legmagasabb feature importance értéket kapta, és a permutation importance alapján is ez a változó volt a legfontosabb. A SHAP-ábrán is látható, hogy a nagyobb népességű körzetekben általában magasabb testi sértés számot jósolt a modell.
- *Szegénységi ráta*: Ez a változó is magas feature importance értéket kapott, és a permutation importance alapján is ez volt a második legfontosabb változó. Az SHAP-ábrán is látható, hogy a magasabb szegénységi ráta általában magasabb testi sértés számot eredményezett.
- *Fiatal férfiak aránya*: Ez a változó is viszonylag magas feature importance értéket kapott, és a permutation importance alapján is meghatározó volt. A SHAP ábra alapján a magasabb arány kisebb mértékben, de alacsonyabb testi sértés számot eredményezett.

Ebben az esetben a modell WMAPE értéke 23,07% volt, ami azt jelenti, hogy az előrejelzések átlagosan 23,07%-kal tértek el a tényleges értékektől.




27. Ábra: Testi sértés esetében az előrejelzések és a tényleges adatok összehasonlítása

Az ábrán látható, hogy a testi sértés esetében már a kisebb esetszámoknál is több pont helyezkedik el a 45 fokos egyenestől távol, a modell előrejelzései kevésbé pontosak, mint a lopás esetében.

5.4.2.2.2 Rongálás


A harmadik leggyakoribb bűncselekménytípus a rongálás volt. Az alábbi ábrák a rongálás esetében mutatják be a feature importance értékeket, a permutation importance eredményeit és a SHAP értékeket:



(a) Rongálás esetében a feature importance értékek

(b) Rongálás esetében a permutation importance értékek

28. Ábra: Rongálás esetében a feature importance és permutation importance értékek összehasonlítása




29. Ábra: Rongálás esetében a feature importance értékek

Az ábrák alapján megállapítható, hogy a itt sem tértek el jelentősen a legfontosabb változók a lopás és testi sértés esetében megfigyelhető változóktól:

- *Népesség*: Ez a változó a legmagasabb feature importance értéket kapta, és a permutation importance alapján is ez a változó volt a legfontosabb. A SHAP-ábrán is látható, hogy a nagyobb népességű körzetekben általában magasabb rongálás számot jósolt a modell
- *Szegénységi ráta*: Ez a változó is magas feature importance értéket kapott, és a permutation importance alapján is ez volt a második legfontosabb változó. Az SHAP-ábrán is látható, hogy a magasabb szegénységi ráta általában magasabb rongálás számot eredményezett, illetve a csökkenés a rongálási számot is meghatározóan csökkentette.
- *Foglalkoztatottsági ráta*: Ez a változó is viszonylag magas feature importance értéket kapott, de a permutation importance alapján nem volt olyan meghatározó. A SHAP-ábra alapján látható, hogyha csökken a foglalkoztatottsági ráta, akkor az általában magasabb rongálás számot eredményezett.
- *Fiatal férfiak aránya*: Ez a változó is viszonylag magas feature importance értéket kapott, de a permutation importance alapján nem volt annyira meghatározó. A SHAP ábra alapján a magasabb arány kisebb mértékben, de alacsonyabb rongálás számot eredményezett.

A rongálás esetében a modell WMAPE értéke 21,48% volt, ami azt jelenti, hogy az előrejelzések átlagosan 21,48%-kal tértek el a tényleges értékektől.



30. Ábra: Rongálás esetében az előrejelzések és a tényleges adatok összehasonlítása


Az ábrán látható, hogy a rongálás esetében a modell előrejelzései a kisebb esetszámoknál viszonylag jól követik a tényleges adatokat, de a közepes és magasabb esetszámoknál már több pont helyezkedik el a 45 fokos egyenestől távol.

5.4.2.2.3 Összefoglalás

A bűncselekménytípusonkénti modellek részletesebb képet adtak arról, hogy a különböző kategóriák milyen demográfiai jellemzőkkel állnak kapcsolatban. A három leggyakoribb bűncselekménytípus, a lopás, a testi sértés és a rongálás esetében is hasonló társadalmi-gazdasági és demográfiai tényezők bizonyultak meghatározónak. A legfontosabb változók között minden típus esetében szerepelt a teljes népesség, a szegénységi ráta és a fiatal férfiak aránya. Ez azt jelzi, hogy ezek a tényezők általánosan fontos szerepet játszanak a bűnözés alakulásában, függetlenül attól, hogy milyen típusú bűncselekményről van szó.


Fontos hangsúlyozni, hogy az eredmények nem oksági kapcsolatokat bizonyítanak. A változófontossági és SHAP-eredmények azt mutatják meg, hogy a modell előrejelzése szempontjából mely változók bizonyultak informatívnak. Ez alapján következtethetünk arra, hogy bizonyos társadalmi-gazdasági jellemzők kapcsolatban állhatnak egyes bűncselekménytípusok előfordulásával.

Minden típushoz külön feature importance, permutation importance és SHAP-ábra tartozik, ezek egyenkénti bemutatása a főszövegben túlzottan részletes lenne. Ezért a főbb tendenciák szemléltetésére a 20 leggyakoribb bűncselekménytípus alapján készítettem összesítő ábrákat.




31. Ábra: A 20 leggyakoribb bűncselekménytípus esetében a feature importance értékek

Az ábrán a 20 leggyakoribb bűncselekménytípus esetében mutatja, hogy a permutation importance alapján mely társadalmi-gazdasági és demográfiai jellemzők voltak a leggyakrabban a legfontosabb változók között. Az ábra alapján látható, hogy a teljes népesség, a szegénységi ráta és a fiatal férfiak aránya voltak a leggyakoribb fontos változók, ami megerősíti azt a megállapítást, hogy ezek a tényezők általánosan fontos szerepet játszanak a bűnözés alakulásában.



32. Ábra: A 20 leggyakoribb bűncselekménytípus esetében a feature importance értékek hő térképen



33. Ábra: A 20 leggyakoribb bűncselekménytípus esetében a feature importance értékek hőterképen

6 Irodalomjegyzék

- [1] S. E. Shreve, *Stochastic Calculus for Finance II: Continuous-Time Models*. Springer, 2004.
- [2] M. Pitera, „Stochastic Processes – Lecture Notes”. 2020.
- [3] F. Herzog, „Stochastic Differential Equations”. 2013.
- [4] J. M. Julia Calatayud Marc Jornet, „Spatio-temporal stochastic differential equations for crime incidence modeling”, *Stochastic Environmental Research and Risk Assessment*, köt. 37, o. 1839–1854, 2023, doi: 10.1007/s00477-022-02369-x.
- [5] B. Øksendal, *Stochastic Differential Equations: An Introduction with Applications*. Springer, 2003.
- [6] T. Hastie, R. Tibshirani, és J. Friedman, *The Elements of Statistical Learning*. Springer, 2009.
- [7] B. C. Csáji, „Data Mining and Machine Learning”. 2025.
- [8] G. James, D. Witten, T. Hastie, és R. Tibshirani, *An Introduction to Statistical Learning*, 2. kiad. Springer, 2021.
- [9] G. E. P. Box és G. M. Jenkins, *Time Series Analysis: Forecasting and Control*. Holden-Day, 1970.
- [10] R. J. Hyndman és G. Athanasopoulos, *Forecasting: Principles and Practice*, 2. kiad. OTexts, 2018.